

ランダム現象 と状態推定

吉田勝俊 著

2017.10.3 版

はじめに

実験のたびに結果が変化してしまい、結果の予測が困難であるような現象を、ランダム現象という。このようなランダム現象を解析するには、確率論が有効であると、何となく想像できる諸君は多いと思う。その際、確率論というと、平均とか分散などのデータ集計を想起するのではないだろうか？

しかしながら、例えば機械力学的な視点で、ランダムな物体運動を扱おうとすると、データ集計レベルの方法では歯が立たない。ランダムな運動方程式や状態方程式を、具体的にどう立てて、どう計算すればよいか等が、全く分からない。

そこで本書では、学部教育では省かれがちな、ランダム現象の動的な記述、推定、制御の方法論をなるべく初等的に解説してみようと思う。本書の特色として、難解を理由にしばしば省かれる、現代確率論の土台部分を、“ガチャ”の例で片付けるところから始める。

目次

はじめに	i
1 状態推定とノイズの小話	1
1.1 変位の測定と速度の推定	1
1.2 状態推定と濾波	5
1.3 確率論のすすめ	6
2 確率空間	8
2.1 見本空間 Ω	8
2.2 事象の代数 \mathcal{F}	9
2.3 確率 P	10
2.4 確率変数 $X(\omega)$	13
3 ランダム現象の例	17
3.1 射撃実験	17
3.2 確率変数	18
3.3 事象と確率	20
3.4 見本空間のタイプ	22
4 確率分布	24
4.1 分布関数と密度関数	24
4.2 代表的な確率分布	27
4.3 数値例	29
5 多変数の確率分布	31
5.1 確率ベクトル	31
5.2 2次元の分布	31
5.3 独立性	34
5.4 多次元の分布	37
6 期待値	40
6.1 確率変数の期待値	40
6.2 確率ベクトルの期待値	42
6.3 条件付き期待値	44
6.4 共分散と相関	45
6.5 ベクトルと行列の期待値	47
7 確率ベクトルの変換	49
7.1 確率変数の加法とスカラ倍	49
7.2 ガウス確率変数の加法とスカラ倍	50
7.3 共分散行列と多変数ガウス分布	52
7.4 ガウス確率ベクトルの線形変換	53

8	推定問題と直交写像	56
8.1	最小二乗法	56
8.2	確率変数の線形代数	58
8.3	ベクトルの近似	61
8.4	確率変数の推定	63
9	確率ベクトルの推定	66
9.1	条件付き期待値	66
9.2	確率ベクトルの推定	67
9.3	確率ベクトルの線形回帰	68
10	確率過程	73
10.1	確率過程	73
10.2	確率的な状態方程式	75
10.3	期待値と共分散行列の推移則	77
10.4	モンテカルロ法による数値例	79
11	カルマンフィルタ	82
11.1	線形確率システム	82
11.2	状態推定問題	83
11.3	カルマンフィルタの導出	84
11.4	カルマンフィルタ	89
11.5	数値例	92
12	連続時間カルマンフィルタ	95
12.1	連続時間の状態方程式	95
12.2	連続時間確率システム	98
12.3	Kalman-Bucy フィルタ	98
13	LQG 制御	103
13.1	制御入力考慮したカルマンフィルタ	103
13.2	LQG レギュレータ	105
13.3	分離定理	106
13.4	数値例	108

1

状態推定とノイズの小話

ある機械振動系の状態推定と制御を例に，本書の動機を述べる．

1.1 変位の測定と速度の推定

図 1.1 のように，1 自由度機械振動系の計測と制御を考える． m は質量， k はばね




図 1.1 1 自由度機械振動系の計測と制御

定数， c は減衰係数とし，質点の実際の変位を x で表す． F は質点を受ける外力である．床との摩擦など， F 以外の外力は無視できるとする．

簡単のため， $m = 1 \text{ kg}$ とし， $u = F$ の場合を考える（制御入力外力そのもの）．このとき，この系の運動方程式は $\ddot{x} = -kx - c\dot{x} + u$ となる． $x_1 := x$ ， $x_2 := \dot{x}$ において一階化すると，次の状態方程式を得る．

$$\dot{x} = Ax + Bu, \quad x := \begin{pmatrix} x \\ \dot{x} \end{pmatrix}, \quad A = \begin{pmatrix} 0 & 1 \\ -k & -c \end{pmatrix}, \quad B = \begin{pmatrix} 0 \\ 1 \end{pmatrix} \quad (1.1)$$

1.1.1 変位の測定

(a) ノイズがない場合 図 1.1 のセンサを変位センサとする．もし，このセンサには誤差がなく，センサ出力 y と実際の変位 x が等しいなら，出力は，

$$y = Cx = x_1 = x, \quad C = (1, 0) \quad (1.2)$$

と表せる．これを，制御工学では，観測方程式または出力方程式と呼ぶ^{a)}．

図 1.2a は，このような出力 y の一例である．条件は $k = c = 1$ ， $x(0) = (1, 0)^T$ とし，制御はなし $u = 0$ とした．

^{a)} センサが速度センサの場合は， $C = (0, 1)$ で表せる．




図 1.2 センサ出力 y の例: (a) ノイズなし, (b) ノイズあり

(b) ノイズがある場合 次に、何らかの原因で測定値にノイズが混入し、図 1.2b のようなセンサ出力が得られた場合を考える。こうした状況は、次のように表わせる。

$$y = Cx + v = x + v \quad (1.3)$$

右辺に、ノイズを表す v を追加した。 C は (a) と共通である。

1.1.2 数値微分 (ND) による速度の推定

図 1.2 の振動波形から分かるように、この振動系は不足減衰 (減衰振動) の条件にある。その結果、 $y = x = 0$ を横切るオーバーシュートが、複数回生じている。このオーバーシュートを解消するために、観測値 y に基づくフィードバック制御器を付加することを試みる。

まず、 K をフィードバックゲインとして、観測値をそのままフィードバックすると、

$$u := -Ky = -Kx \quad (1.4)$$

となる。すなわち、変位 x のフィードバックが実現する。しかし、これではオーバーシュートは解消できない。なぜなら、解消のためには、振動系の減衰特性を強める必要がある。それには、速度 \dot{x} のフィードバックが必要である。

しかし、この制御系のセンサから速度 \dot{x} の情報は得られない。得られるセンサ出力は変位 $y = x$ のみである。したがって、速度フィードバックを実現するには、変位 $y = x$ の情報から、速度 \dot{x} を推定する必要がある。一般に、測っていない状態量を、測った状態量から推定することを、状態推定という。

ここでは、最も単純に、数値微分 (ND: numerical differentiation) によって速度を推定してみる。いま、 $y(t)$ のサンプル列 y_0, y_1, y_2, \dots が得られたとする。すなわち、

$$y_i := y(t_i), \quad t_i = t_0 + i\Delta t \quad (i = 0, 1, 2, \dots) \quad (1.5)$$

が得られたとする． Δt はサンプリング間隔である．このとき，時刻 $t = t_i$ の速度 \dot{y}_i の推定値を次のように定める．

$$\dot{y}_i \approx \frac{\Delta y}{\Delta t}(t_i) := \frac{y(t_i) - y(t_{i-1})}{\Delta t} \quad (t = 1, 2, \dots) \quad (1.6)$$




図 1.3 数値微分による速度推定: (a) ノイズなし, (b) ノイズあり．緑が真値，青が測定値，赤が推定値

(a) ノイズがない場合 ノイズがない図 1.1a の y について，(1.6) で推定した速度の推定値を，図 1.3a に赤で示す． $\Delta t = 0.25$ s とした．赤の推定値は，緑の真値とよく一致している．

このように，測定値がノイズを含まない場合は，数値微分 (1.6) の方法は有効である．

(b) ノイズがある場合 同様にして，ノイズのある図 1.1b の y から推定した速度を図 1.3b に赤で示す．測定値 y (青) の擾乱が，速度推定値 $\Delta y/\Delta t$ (赤) で，さらに増幅されている．

一般に，数値微分 (1.6) はハイパスフィルタとして機能する．したがって，測定値

が図 1.1b のような高周波ノイズを含む場合、それを数値微分 (1.6) すると、ノイズの効果は増幅される。その結果、図 1.3b の速度推定値から、真値の傾向を知ることがは、ほとんど不可能となっている。

▶▶ 信号の低周波成分を除去し、高周波成分を通過させるものをハイパスフィルタという。その逆をローパスフィルタという。

このように、測定値がノイズを含む場合 (特に周波数が高いもの)、数値微分 (1.6) による速度の推定は容易に破綻する。

演習 1.1 数値微分するとノイズの効果が増幅されるメカニズムを、振動波形の模式図を描いて説明せよ。

1.1.3 推定値による制御

数値微分による速度の推定値 $\Delta y/\Delta t$ を用いて、近似的な微分制御を行う。すなわち、制御入力を、

$$u = -K\dot{y} \approx -K \frac{\Delta y}{\Delta t} \quad (1.7)$$

とする。このときのブロック線図を図 1.4 に示す。図 1.5 が制御結果である。 $K =$




図 1.4 数値微分による微分制御




図 1.5 数値微分による微分制御の結果: 緑がノイズなし、黒がノイズあり

0.45 とした。図 1.5 上段が質点の変位 x 、同じく下段が速度 \dot{x} である。図 1.3b の赤

のような制御入力 u が外力として加わった結果、質点の変位 x や速度 \dot{x} に擾乱が見られる．特に、速度 \dot{x} の正負が激しく切り替わっていることから、制御中の質点は、小刻みに激しく振動していることが分かる．

1.2 状態推定と濾波

このような不具合を解消するために、濾波（フィルタリング）という信号処理がよく用いられる．その目的は、図 1.2b のような測定結果の擾乱成分を除去して、図 1.2a のような真値を取り出すことである．

濾波の最も単純な方法に、移動平均（MA: moving average）がある．(1.5) のサンプル列 y_i の高周波成分を除去するために、 y_i と過去の y_{i-1}, y_{i-2}, \dots の平均をとる．

$$\hat{y}_i := \frac{1}{s} \sum_{j=0}^{s-1} y_{i-j} \quad (1.8)$$

図 1.6 に移動平均 \hat{y} とその数値微分 $\Delta\hat{y}/\Delta t$ を示す．元データは図 1.2b の y である




図 1.6 移動平均による濾波結果 \hat{y} とその数値微分 $\Delta\hat{y}/\Delta t$ ($s = 20$): 緑が真値、青が測定値、赤が濾波値

る． $s = 20$ とした．移動平均による濾波値 \hat{y} には次の特徴が見られる．

- 高周波成分が除去される．
- 元の波形 $y(t)$ (青) に対して、濾波値 \hat{y} (赤) が遅れる．

2 つめの特徴は、過去と平均を取ったためである．こうした遅れを解消するには、過去と未来をバランス良く平均すればよいが、制御には使えない．なぜなら、 y_i の測定時に、未来のデータ y_{i+1}, y_{i+2}, \dots は得られていない．

図 1.4 の制御系の y を、移動平均値 \hat{y} で置き換えたときの制御結果を図 1.7 に示す．このように、あまり良い結果は得られない．高周波の（小刻みな）振動は解消した




図 1.7 移動平均 ($s = 20$) + 数値微分による制御結果: 緑がノイズなし, 黒がノイズあり

が, 目標値 $x = \dot{x} = 0$ まわりの揺らぎは, かえって増大してしまっている.

このように, 移動平均や数値微分のようなデータ処理 (四則演算) だけでは, センサにノイズが乗ってしまった系を, 上手く制御することはできない.

1.3 確率論のすすめ

まだ学習前なので説明は省くが, 12.3 節 p98 で導入する Kalman-Bucy フィルタを用いると, 驚くほどよい制御が得られる. まず, 濾波の結果を図 1.8 に示す. 濾

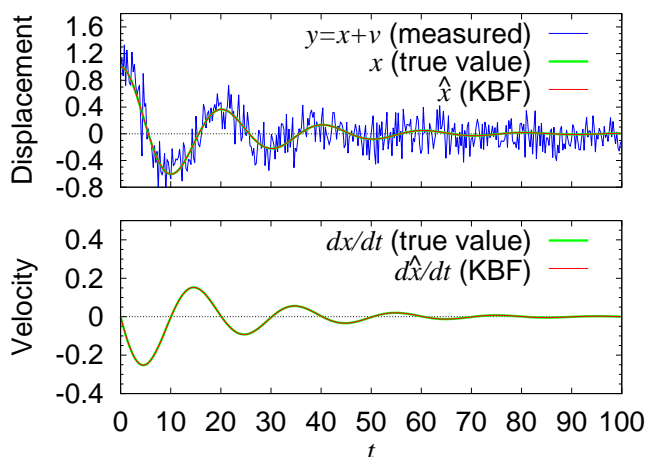


図 1.8 Kalman-Bucy フィルタによる濾波結果

波値 (赤) が, 真値 (緑) にほぼ一致してしまった^{b)}.

^{b)} これは, 制御対象の完全なモデルが既知の数値例だからそうになっている. 実験ではこんなには一致しない.

次に, Kalman-Bucy フィルタによる濾波を用いた制御結果を図 1.9 に示す. ノイ




図 1.9 Kalman-Bucy フィルタによる制御結果: 緑がノイズなし, 黒がノイズあり

ズが無いときの結果 (緑) に較べて, 若干の違い (オーバーシュート) が見られるが, ほぼ同等の制御性能が得られている. ちなみに, このような Kalman-Bucy フィルタを活用した制御法を, LQG 制御という. 具体形は 13 章 p103 で導く.

前節までとの違いは何かというと, 図 1.9 の LQG 制御は, 現代確率論による計算を駆使して導かれている. というわけで, このような高性能な制御手法をきちんと理解して活用するためには, 現代確率論の知識が不可欠である.

しかしながら, 通常の機械系学科のカリキュラムでは, 初等的な確率・統計程度しか確率論を勉強しない. こうした境遇にある学生諸君が, 例えば Kalman-Bucy フィルタを独習するのは至難の技だ. 微積分を知らずに, 力学を学ぶようなものだからだ.

そこで, 本書では, 予備知識なしの状態から, 現代確率論に入門し, 推定理論の基礎を学び, Kalman-Bucy フィルタに到達することを試みる.

恐らく, 機械系の学生諸君にとっては, ほとんど新規の学習内容になると思うが, 始めて微積分に接したときのことを思い出してほしい. 最初はかなり面くらったと思うが, いつの間にか普通に使えてるでしょ? 健闘を祈る.

2

確率空間

試行ごとに実験結果が変化し、結果が予測困難な現象を、ランダム現象という。具体例として、ミニ玩具のカプセル自動販売機（以下、ガチャ）を考える。次に何が出てくるかは予測不可能だから、これはランダム現象である。

現代確率論では、このようなランダム現象を確率空間 (Ω, \mathcal{F}, P) という器に収めて考察する^{a)}。以下、ガチャを例に、 Ω と \mathcal{F} と P を順に導入する。

2.1 見本空間 Ω

2.1.1 試行

試行とは、実験 1 回分の実行をいう。例えば、ガチャからカプセルを 1 つ取り出す操作は試行である。いま、ガチャからカプセルを N 回取り出したところ、次のような結果が得られたとしよう。

犬, 鳥, 犬, 人, 人, 鳥, 犬, \dots , 人 (2.1)

このような複数回の試行の並びを試行列という。試行の回数 N を試行数という。

2.1.2 見本

こうした試行列を紙の上に表記する場合、字画が多いと面倒なので、適当な記号や数字が割り当てられる。例えば、次のようにしよう。

a : 犬, b : 鳥, c : 人

結果を表記する記号 a, b, c を見本という。見本を使うと、試行列は簡潔に、

$a, b, a, c, c, b, a, \dots, c$ (2.2)

と書ける。

^{a)} パボリス [2] p15, 津野 [4] p3 など。

表 2.1 事象の演算 (集合演算)

集合演算	選ばれる見本	名称
集合和 $A_1 \cup A_2$	いずれかに含まれる	和事象
集合積 $A_1 \cap A_2$	両方に含まれる	積事象
集合差 $A_1 \setminus A_2$	$:= A_1 \cap \overline{A_2}$	差事象
補集合 $\overline{A_1}$	A_1 に含まれない ($:= \Omega \setminus A_1$)	余事象

2.1.3 見本空間

次に、確率論では、全ての見本を網羅した見本帳 Ω を作る。例えば、ミニ玩具が a, b, c の 3 種類だけのとき、ガチャの見本帳を次のように表す。

$$\Omega := \{a, b, c\}$$

このような全ての見本を列挙した集合 (見本帳) Ω を見本空間という。

▶▶ 数学ではしばしば「集合」を「空間」と言い表す。ただし「空間」というときには、何かが動く土台というニュアンスが込められることが多い。

2.2 事象の代数 \mathcal{F}

2.2.1 事象

続いて、確率論では、用途に応じて見本の様々なクラス分けが導入される。例えば、哺乳類と 2 足歩行に興味があるなら、

$$\text{哺乳類} : A_1 = \{\text{犬}, \text{人}\} = \{a, c\}, \quad \text{2 足歩行} : A_2 = \{\text{鳥}, \text{人}\} = \{b, c\} \quad (2.3)$$

のようなクラス分けが導入できる。こうした Ω の部分集合 A_1, A_2 を事象という。また、表 2.1 のような事象同士の集合演算の結果もまた事象であると約束する。

事象 A と共通部分を持たない事象を、 A の背反事象という。例えば、余事象 \overline{A} は必ず A の背反事象となる。

演習 2.1 (2.3) の A_1, A_2 を、見本空間 $\Omega = \{a, b, c\}$ 上の事象とする。和事象 $A_1 \cup A_2$ 、積事象 $A_1 \cap A_2$ 、差事象 $A_1 \setminus A_2$ 、余事象 $\overline{A_1}$ を求めよ。

▶▶ 余事象は、見本空間を決めないと定義できない。

2.2.2 事象の代数

一般に、集合の集合を、族という。したがって、事象の集合は、事象の族と呼ばれる。例えば、冒頭で着目した事象 A_1, A_2 を要素とする集合、

$$F = \{\text{哺乳類}, \text{2 足歩行}\} = \{A_1, A_2\} = \{\{a, c\}, \{b, c\}\} \quad (2.4)$$

は事象の族である。

ここで、興味ある事象だけを並べた族 (2.4) には、各種集合演算の結果が含まれていない。例えば、 $A_1 \cap A_2 = \{c\}$ は事象とする約束だが、 F には含まれない。そこで、足りない事象として、

- 和事象 $A_1 \cup A_2 = \{a, b, c\} = \Omega$
- 積事象 $A_1 \cap A_2 = \{c\}$
- 余事象 $\overline{A_1} = \{b\}, \overline{A_2} = \{a\}$

を追加してみる．その結果，事象の族は，

$$F' = \left\{ \{a, c\}, \{b, c\}, \{a\}, \{b\}, \{c\}, \Omega \right\} \quad (2.5)$$

まで膨らむ．

- ▶▶ (1 人だけのクラス) $\{a\}, \{b\}, \dots$ 等は 1 人だけのクラスを表す．すなわち， a と $\{a\}$ は異なる．前者は見本 (個人)，後者は 1 人しかいないクラスである．

しかし，この F' においても，2 段階の集合演算では閉じない．例えば，

$$\overline{A_1 \cup A_2} = \overline{\{a, b, c\}} = \{\} := \emptyset \quad (\text{空事象} \quad \text{くうじしょう}) \quad (2.6)$$

は F' に含まれない．こうした多段階の集合演算をも網羅しようとする，事象の族は，

$$\mathcal{F} = \left\{ \{a, c\}, \{b, c\}, \{a, b\}, \{a\}, \{b\}, \{c\}, \Omega, \emptyset \right\} \quad (2.7)$$

まで膨らむ．この \mathcal{F} は， A_1, A_2 に対する任意回の集合演算に対して閉じている． \mathcal{F} は， A_1, A_2 から理論上想定しうる全ての事象のリストを与える．

2.2.3 σ 代数

(2.7) の \mathcal{F} は，任意回の集合演算で閉じるように F を膨らませたものである．これを， F から生成した σ 代数と呼ぶ．このような \mathcal{F} は，大きくも小さくもとれるが，そのなかで最小なものを $\sigma(F)$ と書く．

- ▶▶ 最小の集合とは，要素数が最小の集合ということ．

ある集合族 \mathcal{F} が σ 代数となるためのチェックリストが整備されている．

定義 2.1 集合 Ω の部分集合を集めた族 \mathcal{F} を考える．次の条件を満足する \mathcal{F} を， Ω 上の σ 代数という．

$$(\sigma 1) \quad \Omega \in \mathcal{F}.$$

$$(\sigma 2) \quad A \in \mathcal{F} \implies \overline{A} \in \mathcal{F}.$$

$$(\sigma 3) \quad A_1, A_2, \dots, A_n \in \mathcal{F} \implies A_1 \cup A_2 \cup \dots \cup A_n \in \mathcal{F}. \quad (n \text{ は任意の自然数})$$

例題 2.1 $\Omega := \{a, b, c\}$ 上の族 $G := \{\{b, c\}, \{c\}\}$ から生成した最小の σ 代数 $\sigma(G)$ を求めよ． $\{\{b, c\}, \{c\}\} = \{2 \text{ 足歩行}, \text{霊長類}\}$

演習 2.2 $\Omega := \{a, b, c\}$ 上の族 $H := \{\{a, b\}, \{c\}\}$ から生成した最小の σ 代数 $\sigma(H)$ を求めよ．

2.3 確率 P

事象 A が生起する確率を $P(A)$ と書く．その値の定め方には，大きく 2 種類ある．見本に基づく方法と，標本に基づく方法である．

2.3.1 見本に基づく方法 (論理的解釈)

大雑把にいうと、実際の試行によらずに確率を定める方法である．以下、集合 A の要素数を $\#A$ と表記する．

古典的には、ラプラス (1749 ~ 1827) の方法がある．ガチャの例では、

$$P(\{a\}) := \frac{\#\{a\}}{\#\Omega} = \frac{1}{3}, \quad P(\{b\}) := \frac{\#\{b\}}{\#\Omega} = \frac{1}{3}, \quad P(\{c\}) := \frac{\#\{c\}}{\#\Omega} = \frac{1}{3} \quad (2.8)$$

となる． $\#\Omega = 3$ は見本の総数であり、 $\#\{a\} = 1$ は事象 $\{a\}$ に含まれる見本の数である．この定め方は、

- 結果の発現傾向について知識がない場合、等確率を仮定するのが最も合理的である．

という仮説に基いている．しかし、ラプラスの方法は、歴史的に様々な批判にさらされてきた (実験と合わないなど) ．

そこで、力学を始めとする確率論以外の知見を動員して、例えば、

$$P(\{a\}) := \frac{1}{4}, \quad P(\{b\}) := \frac{2}{4}, \quad P(\{c\}) := \frac{1}{4} \quad (2.9)$$

などと確率を仮置きし、これを作業仮説とみなす立場もある．

以上の方法論は、実測に基いていないため、妥当性に疑問が残る．しかし、ランダム現象を数値シミュレーションするような場合は、ランダム性の源をこの立場で設けるしかない．その意味で、淘汰された古い方法論というわけではない．

2.3.2 その他の事象の確率

(2.8) では、ガチャの事象 $\{a\}, \{b\}, \{c\}$ について確率を定めたが、(2.7) の \mathcal{F} にエントリートされた事象はまだ 5 つある．これらの確率を矛盾なく割り出すためのルールが整備されている．

算法 2.1 (確率の性質) 確率 $P(\cdot)$ は一般に次の性質を持つ．

(P1) 任意の事象 A に対して、 $0 \leq P(A) \leq 1$.

(P2) 特に、 $P(\Omega) = 1$.

(P3) 背反事象 A_1, A_2, \dots に対して、

$$P(A_1 \cup A_2 \cup \dots) = P(A_1) + P(A_2) + \dots .$$

以上の帰結として、次の性質も示される．

(P4) A の余事象 \bar{A} に対して、 $P(\bar{A}) = 1 - P(A)$

(P5) $P(\emptyset) = 0$. ($\emptyset := \{\}$ は空集合)

例題 2.2 (P2)(P3) を前提として (P4) を示せ． (ヒント : $\Omega = A \cup \bar{A}$)

演習 2.3 (P4) を前提として (P5) を示せ .

(2.7) のガチャの事象 \mathcal{F} に話を戻す . (P2)(P5) より $P(\Omega) = P(\{a, b, c\}) = 1$ と $P(\emptyset) = 0$ が定まる . さらに , 事象 $\{a\}$ と $\{b\}$ は背反だから ,

$$P(\{a, b\}) = P(\{a\} \cup \{b\}) = P(\{a\}) + P(\{b\}) = \frac{2}{3} \quad (2.10)$$

を得る .

演習 2.4 (2.8) を前提に , (2.7) の \mathcal{F} の残りの事象 $\{a, c\}$ と $\{b, c\}$ の確率を求めよ .

2.3.3 試行に基づく方法 (頻度解釈 , 統計的解釈)

あるランダム現象の無限試行列 $a_1, a_2, a_3, \dots \in \Omega$ を要素とする集合 :

$$\Pi := \{a_1, a_2, \dots, a_n, \dots\} \quad (2.11)$$

を統計学では , 母集団という . 一般に $\Pi \neq \Omega$ である . 例えば , ガチャでは ,

$$\Omega = \{a, b, c\} \quad (\text{見本})$$

$$\Pi = \{a, b, a, c, c, b, a, \dots\} \quad (\text{母集団})$$

のような違いとなる . また , 母集団の一部を抽出した部分集合 ,

$$\Pi_n = \{a_1, a_2, \dots, a_n\} \subset \Pi \quad (2.12)$$

を , 標本という . このなかで , 試行結果 a_i が事象 $A \subset \Omega$ に含まれる試行の個数を $N(A)$ と書くとき ,

$$P_n(A) := \frac{N(A)}{\#\Pi_n} = \frac{N(A)}{n} \quad (2.13)$$

を , 事象 A の標本 Π_n における相対度数という .

例題 2.3 ガチャの標本 $\Pi_7 := \{a, b, a, c, c, b, a\}$ について , 事象 $A_1 = \{a, c\}$, $A_2 = \{b, c\}$ の相対度数をそれぞれ求めよ .

演習 2.5 (2.7) の \mathcal{F} の残りの事象について , 相対度数を求めよ .

以上の統計学をベースに , 確率を , 相対度数の極限 ,

$$P(A) := \lim_{n \rightarrow \infty} P_n(A) \quad (2.14)$$

として定める . このような確率の解釈を , 頻度解釈または統計的解釈という .

▶▶ (混同しやすい用語) 見本空間 Ω を , 標本空間と呼ぶ流儀がある . 語感としては , 標本が降り積る土台が標本空間 Ω である .

2.4 確率変数 $X(\omega)$

以上，ガチャのようなランダム現象は確率空間 (Ω, \mathcal{F}, P) で表せる． Ω は試行結果の見本帳であり，そのクラス分けを事象と呼んだ． \mathcal{F} は集合演算で閉じた事象の族， $P(A)$ は事象 $A \in \mathcal{F}$ の確率であった．しかしながら，この確率空間 (Ω, \mathcal{F}, P) には，工学的な実験には付き物の，測定値を収める器がまだ存在しない．

例えば，ガチャの各見本について，全長 x [cm] と重量 y [g] を測定したところ，下表の結果が得られたとしよう．

見本 ω	全長 x [cm]	重量 y [g]
a : 犬	3.5	22
b : 鳥	2.8	22
c : 人	3.5	25

このとき，例えば $x = 3.5$ となる確率はどのように考えればよいのだろうか？

▶▶ 値に重複が見られる例としたが，こうしても確率論は破綻しない．ただし，「可測性」と呼ばれる実用上の問題が起こる (2.4.4 節で述べる) ．

2.4.1 確率変数

そこで，まず，上記の「測定」を次のような関数でモデル化する．

$$\begin{cases} x = & X(a) = 3.5, & X(b) = 2.8, & X(c) = 3.5 \\ y = & Y(a) = 22, & Y(b) = 22, & Y(c) = 25 \end{cases} \quad (2.15)$$

このような，各見本 ω の測定値 x, y を記憶させた関数 X, Y を確率変数と呼ぶ．

▶▶ $x = \sin(t)$ という関数関係において， \sin は関数， x は t における関数値である．同様に， $x = X(\omega)$ において， X は関数， x は ω における関数値である．

▶▶ 見本の関数を確率変数と呼ぶのは，確率論の歴史的慣習である．

参考まで，上記の確率変数 $x = X(\omega)$ は次のようにプログラミングできる．

```
function x = X(om)           Matlab/Octave の場合
    if ( om == 'a' )
        x = 3.5;
    elseif ( om == 'b' )
        x = 2.8;
    elseif ( om == 'c' )
        x = 3.5;
    end
endfunction
```

以上の測定を通して，(2.2) の試行列 $a, b, a, c, b, a, \dots, c$ からは，

$$\begin{cases} x = & X(a), X(b), X(a), X(c), X(c), X(b), X(a), \dots, X(c) \\ & = 3.5, 2.8, 3.5, 3.5, 3.5, 2.8, 3.5, \dots, 3.5 \\ y = & Y(a), Y(b), Y(a), Y(c), Y(c), Y(b), Y(a), \dots, Y(c) \\ & = 22, 22, 22, 25, 25, 22, 22, \dots, 25 \end{cases} \quad (2.16)$$

のようなデータ列が得られる．

2.4.2 測定値の生起確率

早速, $P(x = 3.5)$ のような確率を導入したいわけだが, 確率 $P(A)$ は事象に対する量である. そこで, 測定値 $x = X(\omega)$ に対応する事象を次式で逆算する.

$$X^{-1}(x) := \{\omega \in \Omega \mid X(\omega) = x\} \quad (2.17)$$

例えば, (2.15) の X について $x = 3.5$ とすると,

$$X^{-1}(3.5) := \{\omega \in \Omega \mid X(\omega) = 3.5\} = \{a, c\} \quad (2.18)$$

となる. もう 1 つの測定値 $x = 2.8$ については,

$$X^{-1}(2.8) := \{\omega \in \Omega \mid X(\omega) = 2.8\} = \{b\} \quad (2.19)$$

となる.

演習 2.6 同様に, $Y^{-1}(22)$ と $Y^{-1}(25)$ を求めよ.

以上より, $x = 3.5$ となる確率は, ラプラスの確率 (2.8) では,

$$P(X^{-1}(3.5)) = P(\{a, c\}) = \frac{2}{3} \quad (2.20)$$

となる. 表記短縮のため, よく用いられる略記

$$P(X = x) := P(X^{-1}(x)) \quad (2.21)$$

を使うと, 先の例は,

$$P(X = 3.5) = P(\{a, c\}) = \frac{2}{3} \quad (2.22)$$

と書ける.

演習 2.7 確率 $P(X = 2.8)$, $P(Y = 22)$, $P(Y = 25)$ を求めよ.

2.4.3 確率変数から生成される σ 代数

$X(\omega)$ が取り得る値 $x = 3.5, 2.8$ が表す事象は $\{a, c\}, \{b\}$ であった. これらから生成される σ 代数を, $\sigma(X)$ と書き, 確率変数 X から生成される σ 代数という.

実際に計算してみよう. 定義は,

$$\sigma(X) := \sigma(\{\{a, c\}, \{b\}\}) \quad (2.23)$$

であった. ひとまず, 括弧内の集合族に, $\Omega = \{a, b, c\}$, $\emptyset = \{\}$ を追加してみると,

$$F = \{\{a, c\}, \{b\}, \{a, b, c\}, \{\}\} \quad (2.24)$$

となる. これは, 各事象の余事象を含む. また, 全てのペアの和集合を含む. というわけで, これでよい. すなわち, $\sigma(X) = F = \{\{a, c\}, \{b\}, \Omega, \emptyset\}$ である.

演習 2.8 同様に $\sigma(Y)$ を求めよ.

表 2.2 確率変数から生成される事象と測定値の関係

事象	$\sigma(X)$	測定値 x の条件	$\sigma(Y)$	測定値 y の条件
$\{\}$	○	$x \neq 2.8, 3.5$	○	$y \neq 22, 25$
$\{a\}$				
$\{b\}$	○	$x = 2.8$		
$\{c\}$			○	$y = 25$
$\{a, b\}$			○	$y = 22$
$\{b, c\}$				
$\{a, c\}$	○	$x = 3.5$		
$\{a, b, c\}$	○	$x = 3.5 \text{ or } 2.8$	○	$y = 22 \text{ or } 25$

2.4.4 確率変数の可測性

X から生成した $\sigma(X)$ の事象は全て、測定値 $x = X(\omega)$ に関する条件で表せる．これを表 2.2 に示す． $\sigma(X)$ が含む事象を○で示し、対応する測定値 x の条件を示した．同じく $\sigma(Y)$ についても示した．

一般に、ある事象を、測定値側の条件で識別できることを、可測であるという．例えば、表 2.2 の X は、その値 x に関する条件で、

$$\mathcal{F}_1 = \{\{a, c\}, \{b\}, \Omega, \emptyset\} \quad (= \sigma(X)) \quad (2.25)$$

の全ての事象を識別できる．この事実を、 X は \mathcal{F}_1 -可測である、と言い表す．(これは、 \mathcal{F}_1 を X から生成したのだから当然)

可測でない状況は次のようにして起る．例えば、2 足歩行 $A_2 = \{b, c\}$ に興味があったとしよう．まず、対応する σ 代数を生成し、見るべき事象をリストアップする．

$$\mathcal{F}_2 = \sigma(A_2) = \{\{b, c\}, \{a\}, \Omega, \emptyset\} \quad (2.26)$$

次に、測定値として見本の全長 x を採用したところ、 x のデータ列を分析しても 2 足歩行 A_2 か否かは判別できないことが分かった．なぜなら、表 2.2 の $\sigma(X)$ の $A_2 = \{b, c\}$ が空欄なので、 A_2 を識別する X の値は存在しない．そこで、測定値を重量 y に変更しても、表 2.2 の $\sigma(Y)$ の $A_2 = \{b, c\}$ は空欄のままなので、やはり A_2 は識別できない．ようするに、全長や重量を測定しても「2 足歩行」は識別できない．

一般に、確率変数 X の値によって、 \mathcal{F} の事象が全て識別できることを、 X は \mathcal{F} -可測である、と言い表す．

上述の例では、 X も Y も \mathcal{F}_2 -可測でない．これを解消するには、 A_2 が判別可能となるような新たな確率変数 (測定方法) を導入せねばならない．

演習 2.9 \mathcal{F}_2 -可測となるような新しい確率変数 $Z(\omega)$ の例を作れ．

♣ 2 章の補足

A2 解答例

A2.1 例題 2.1 p10 の解答例

初期状態を $\mathcal{F}_0 = F = \{\{b, c\}, \{c\}\}$ とする．これに，定義 2.1 p10 のチェックリストが求める事象を追加していく．まず， $(\sigma 1)$ より， Ω が必要なので追加する．

$$\mathcal{F}_1 = \mathcal{F}_0 \cup \{\Omega\} = \{\{b, c\}, \{c\}, \{a, b, c\}\}$$

次に， $(\sigma 2)$ を充足するため， \mathcal{F}_1 の余事象を求めると，

$$\overline{\{b, c\}} = \{a\}, \quad \overline{\{c\}} = \{a, b\}, \quad \overline{\{a, b, c\}} = \{\} = \emptyset$$

となるが，これらは \mathcal{F}_1 にないので追加する．

$$\mathcal{F}_2 = \mathcal{F}_1 \cup \{\{a\}, \{a, b\}, \emptyset\} = \{\{a\}, \{c\}, \{a, b\}, \{b, c\}, \Omega, \emptyset\}$$

次に， $(\sigma 3)$ より， \mathcal{F}_2 の和事象を全てチェックすると， $\{a, c\}$ が足りない．その余事象 $\overline{\{a, c\}} = \{b\}$ もない．これらを追加すると，

$$\mathcal{F}_3 = \mathcal{F}_2 \cup \{\{a, c\}, \{b\}\} = \{\{a\}, \{b\}, \{c\}, \{a, b\}, \{b, c\}, \{a, c\}, \Omega, \emptyset\}$$

を得る．改めて定義 2.1 p10 でチェックすると， \mathcal{F}_3 は， Ω を含むから $(\sigma 1)$ を満す．全ての余事象を含むから $(\sigma 2)$ を満す．全ての組み合わせの和事象を含むから $(\sigma 3)$ を満す． \mathcal{F}_3 の要素がどれか 1 つでも欠けると，チェックを通らなくなるから，最小である．したがって， $\sigma(F) = \mathcal{F}_3$ である．

A2.2 例題 2.2 p11 の解答例

(P2) より $P(\Omega) = 1$ が成立する．また，余事象の定義より $\Omega = A \cup \bar{A}$ が成立し， A と \bar{A} は背反だから，(P3) より，

$$1 = P(\Omega) = P(A \cup \bar{A}) \stackrel{(P3)}{=} P(A) + P(\bar{A})$$

したがって， $P(\bar{A}) = 1 - P(A)$ ．

A2.3 例題 2.3 p12 の解答例

事象 $A_1 = \{a, c\}$ に該当する試行の個数は，試行結果が a または c となった回数だから $N(A_1) = 5$ である．同じく $A_2 = \{b, c\}$ については， b または c となった回数だから $N(A_2) = 4$ である．ゆえに，

$$P_n(A_1) = \frac{N(A_1)}{7} = \frac{5}{7}, \quad P_n(A_2) = \frac{N(A_2)}{7} = \frac{4}{7}$$

となる．

3

ランダム現象の例

前章のガチャの確率空間 (Ω, \mathcal{F}, P) は見本数が 3 だったので、実際に見本を見ながら事象や確率を議論できた。いわば、測定値（確率変数）は補助的な存在であった。しかし、工学的には、測定値（確率変数の値）のほうが主役で、見本空間 Ω はブラックボックスという状況も少なくない。本章では、測定値を出発点とする定式化を概観する。

3.1 射撃実験

図 3.1 は、原点から発射された弾丸の軌跡をシミュレートしたものである。弾丸は $x = 100$ で標的（壁）に弾き、図の右端の小円は着弾点を表す。この軌跡は、次の運動方程式を数値的に解いて求めた。

$$m\ddot{x} = -c|\dot{x}|\dot{x}, \quad m\ddot{y} = -c|\dot{y}|\dot{y} - mg \quad (3.1)$$

x は発射点からの距離で、 y は高さである。各右辺の第 1 項は、速度の 2 乗に比例する抗力を表す。 m は質量で、 g は重力加速度である。初期条件は、原点を初期位置として、初速度 800m/s を仰角 10^{-3}rad で与えた。




図 3.1 弾丸の軌跡

この理想的なシミュレーションの世界では、パラメータ m, c, g と初期条件を変えない限り、何度発射しても、この弾道が再現される。このような再現性のある挙動は、

決定論的であるという^{a)}。

ところが、同様の試行を物理的に行うと、例えば、図 3.2 のような結果になるはずだ。試行ごとに結果が変化している。これは、すなわち、ランダム現象である。




図 3.2 弾丸の軌跡 (試行 21 回)

3.2 確率変数

図 3.2 のランダムな着弾高さ y の標本は、

$$\begin{aligned} \Pi_n &= \{y_0, y_1, \dots, y_n\} \\ &= \left\{ \begin{array}{lll} -0.0005546, & -0.0009029, & -0.0120882, \\ 0.0030689, & 0.0022497, & -0.0008347, \\ -0.0053880, & -0.0027085, & -0.0139268, \\ 0.0070402, & -0.0060878, & 0.0056178, \\ 0.0033460, & 0.0010289, & 0.0064170, \\ -0.0062657, & 0.0054214, & 0.0059001, \\ -0.0035151, & -0.0007244, & -0.0011962 \end{array} \right\} \end{aligned} \quad (3.2)$$

となった ($n = 21$)。全て値が異なるので、見本帳 Ω には少なくとも 21 個の見本が必要である。そこで、 y_i の添字をそのまま見本空間




$$\Omega := \{0, 1, 2, \dots, 20\} \quad (3.3)$$

とし、確率変数を、

$$y = Y(\omega) = y_\omega \quad (\omega = 0, 1, \dots, 20) \quad (3.4)$$

としてみる。これを図 3.3 に示す。横軸は見本番号 $\omega \in \Omega$ ，縦軸は対応する着弾点の観測値 $y = Y(\omega)$ である。

図 3.3 と同じ試行について、 $x = 60$ での通過高さを測定値とした確率変数 $Z(\omega)$ を図 3.4 に示す。 $Y(\omega)$ と $Z(\omega)$ は同一の見本空間 (= 実験) 上で定めた確率変数だが、

図 3.3 確率変数 ($x = 100$)図 3.4 確率変数 ($x = 60$)図 3.5 確率変数 ($x = 100, \# \Omega = 501$)

測定方法が違うので関数形は異なる。

同様に、標本数を 501 としたときの結果を図 3.5 に示す。この場合も標本 $\Pi_{501} = \{y_0, \dots, y_{501}\}$ に重複は生じなかったので、 y_i の添字を $\omega := i$ としている。

見本空間 Ω とそれ上の確率変数 $Y(\omega)$, $Z(\omega)$ の具体的な役割については、次のようなイメージを持っておくとよい。

- Ω は試行結果の全種類を収録した見本帳。
- $\omega \in \Omega$ は見本番号。(番号ではなく文字列でもよい)
- 同じ実験 Ω の同じ見本 $\omega \in \Omega$ から、性質の異なる測定値 $X(\omega), Y(\omega), Z(\omega), \dots$ が収集される。これらの違いは測定箇所や使用センサの違いなどによる。

このように、確率変数の関数形はギザギザしていて捉え所がないが、測定値が実際そうなのだからしかたがない。

^{a)} 確定的ともいう。

3.3 事象と確率

射撃実験と前章のガチャの違いは標本空間 Ω の大きさにある．ガチャでは $\#\Omega = 3 < \infty$ だったが，以下に述べるように，射撃実験では理論上 $\#\Omega = \infty$ となる．

3.3.1 初等的確率の限界

2.4.2 節 p14 の方法をそのまま適用してみる．例えば，着弾点が $y = Y(0) = -0.0005546$ となる確率 $P(Y = -0.0005546)$ は，

$$P(Y = -0.0005546) := P(Y^{-1}(-0.0005546)) = P(\{0\}) \quad (3.5)$$

となる．その値は，ラプラスの方法 (2.8) により， $\#\Omega = 21$ の場合，

$$P(\{0\}) := \frac{\#\{0\}}{\#\Omega} = \frac{1}{21} \quad (3.6)$$

となる．と結論づけてしまってよいのだろうか？

残念ながらそうはできない．ガチャでそうできたのは，分母の 3 が確定したからである．これに対して，着弾点の可能性は高々 21 点では網羅できない．実際，501 点まで増やした標本 Π_{501} にも重複点は存在しない．さらに試行を増やしても，着弾点がそれまでの着弾点に一致する状況は，ほとんど起らないだろう．結局のところ，将来起りうる着弾点を全て網羅するには， $\#\Omega \rightarrow \infty$ の極限を考えるしかない．

というわけで，2.3.3 節の頻度解釈に乗り換えて，相対度数を求めると，

$$P_n(\{0\}) := \frac{N(\{0\})}{\#\Pi_n} = \frac{N(\{0\})}{n} \quad (3.7)$$

となる．ここで若干，楽観的に，

- 同じ着弾点は有限回しか繰り返さない (限りなくは繰り返さない)

と仮定しても，分子 $N(\{0\})$ が有限であるから，

$$P(\{0\}) := \lim_{n \rightarrow \infty} \frac{N(\{0\})}{n} = \frac{\text{有限}}{\infty} = 0 \quad (3.8)$$



となる．すなわち，発生頻度が有限な事象については，頻度の大小によらず，常に確率が 0 になってしまう．

以上，「将来起りうる」測定値が無限個ある場合，測定値が定数に一致する確率は 0 になる．すなわち，定点 a に着目した確率 $P(Y = a)$ は，測定値が連続値であるようなランダム現象に対しては，常に同じ値をとるので意味をなさない．

3.3.2 事象

そこで，起りうる測定値 y の範囲をピンポイントではなく，実数直線 \mathbb{R} 上の区間で指定することにする．次のように表記する．

$$y \in [a, b] \quad \text{または} \quad a \leq y \leq b \quad (3.9)$$

図 3.6 事象 $\{|Y| \leq 10^{-3}\}$ の抽出 ($\#\Omega = 21$)図 3.7 事象 $\{|Y| \leq 10^{-3}\}$ の抽出 ($\#\Omega = 501$)

►► $[a, b]$ を閉区間といい, $y \in [a, b]$ は $a \leq y \leq b$ を意味する. 同じく (a, b) を开区間
 といい, $y \in (a, b)$ は $a < y < b$ を意味する. 同様に, $[a, b)$ や $(a, b]$ を半开区間という.

ここで改めて, 測定値が区間に入る見本だけを集めた Ω の部分集合,

$$\{Y \in [a, b]\} \quad \text{または} \quad \{a \leq Y \leq b\}$$

$$:= Y^{-1}([a, b]) = \{\omega \in \Omega \mid a \leq Y(\omega) \leq b\} \subset \Omega \quad (3.10)$$

を事象と定める. 2.2.1 節で既に述べたことが, 異なる事象 $A_i := \{a_i \leq Y \leq b_i\}$ ($i = 1, 2, \dots$) を, 表 2.1 のように集合演算した結果もまた事象であると約束する.

さて, 図 3.3 の確率変数 $Y(\omega)$ の見本空間は $\Omega = \{0, 1, 2, \dots, 20\}$ であったが, そのなかで, 例えば $|Y(\omega)| \leq 10^{-3}$ に該当する事象は,

$$\{|Y| < 10^{-3}\} = \{0, 1, 5, 19\} \quad (3.11)$$

となる. これらを図 3.6 に赤○で示す. 同じく, $\#\Omega = 501$ での結果を図 3.7 に示す.

3.3.3 確率

事象が実現する確率は, 厳密には $P(\text{事象})$ と書くべきだが, 表記短縮のためこれを略して $P(\text{条件})$ とも書くことにする.

事象 $\{a \leq Y \leq b\}$ が実現する確率は, ラプラスの確率を使うと,

$$P(a \leq Y \leq b) = \frac{\#\{a \leq Y \leq b\}}{\#\Omega} \quad (3.12)$$

となる. $\#A$ は集合 A の要素数を表す.


図 3.8 確率 $P(|Y| \leq 10^{-3})$ の数値例

図 3.8 は、図 3.6 や図 3.7 と同様の試行結果から求めた確率 $P(|Y| \leq 10^{-3})$ の数値例である。横軸は分母となる全見本数 $\#\Omega$ であり、縦軸は得られた確率である。全見本数 $\#\Omega$ が 8000 を超えたあたりから、確率の計算値がある値に漸近していくように見える。区間で分子をカウントする (3.12) の定義では、分母と同時に分子も増えるから、このようなことが起きる。

実用的には、十分に漸近したと思われる計算値を、確率の近似値とすることが多い。右端の $\#\Omega = 15000$ においてもなお、可能な測定値が出尽したとは言い難いので、こうした数値計算値はあくまで近似値である。射撃の想定に戻ると、この (架空の) 実験においては、およそ 13% の弾丸が $y = 0 \pm 1\text{mm}$ の範囲に命中することが分かる。

また、区間の確率を考えるうえでは、次の性質が重要である。

算法 3.1 $\#\Omega = \infty$ の状況では、(1 点や 2 点の確率は 0 なので)

$$P(a \leq Y \leq b) = P(a \leq Y < b) = P(a < Y \leq b) = P(a < Y < b) \quad (3.13)$$

3.4 見本空間のタイプ

本章の射撃実験のような問題では、見本空間 Ω の要素は列挙できない。すなわち Ω はブラックボックスとなるが、理論上どのような見本空間を想定しうるか、いくつか例を挙げておく。

3.4.1 有限集合

測定値が有限個の値しか取らない場合の見本空間は有限集合となる。

$$\Omega := \{\omega_1, \omega_2, \dots, \omega_n\} \quad (n < \infty) \quad (3.14)$$

上述の数値例は厳密にいうと全てこれに該当する。なぜなら、コンピュータの数値は有限桁の小数なので、とりうる値は有限個である。また、統計学においても、無限回の試行を実施するのは不可能だから、有限な標本 Π_n から見本を抽出することになり、この場合に該当する。

3.4.2 可算無限集合

測定値が整数値や有理数値をとるとき、理論上起りうる全ての見本は、次のような形式で表せる。

$$\Omega := \{\omega_1, \omega_2, \dots\} \quad (3.15)$$

この見本空間の要素数は無限になるが、まだ番号付けは可能である（シリアル番号を振れる）。 N を自然数の全体とすると、同じことは、

$$\Omega := \{\omega_i \mid i \in N\} \quad (3.16)$$

と書ける。

なお、このような番号付け可能な無限を可算無限という。

3.4.3 非可算無限集合

これに対して、測定値が実数のときは、(3.16) の見本空間では全てを網羅できない。そこで、 R を実数の全体として、

$$\Omega := \{\omega_s \mid s \in R\} \quad (3.17)$$

というタイプの見本空間が導入される。

この見本空間は非常に大きくて、シリアル番号で全ての見本を網羅することはできない。このタイプの無限を非可算無限という。なにやらかめしいが、力学的なランダム現象の見本空間はほとんどこのタイプであろう。

例えば、(3.1) のような運動方程式の解は実数である。それがランダムに揺らいだ解もまた実数である。ということは、図 3.2 の弾道を理論解析する際には、見本空間を非可算無限として想定しておかないと、可能性が漏れることになる。

4

確率分布

ランダム現象における試行のばらつきを関数で表す．

4.1 分布関数と密度関数

図 3.5 の確率変数のグラフは無作為で理解しがたいが，見本 ω を測定値 $Y(\omega)$ の小さい順に並べると，だいたい傾向が見やすくなる．図 3.5 に対して，実際にそうしたものを図 4.1 に示す． ω' は測定値が小さい順に振り直した見本番号である．

4.1.1 分布関数

図 4.1 の傾向を定量化するために， y を閾値とする次の事象を導入する．

$$\{Y \leq y\} \quad (4.1)$$

これは，測定値が y 以下となる見本を集めた事象である．



次に y を等間隔にとって，事象の見本数 $\#\{Y \leq y\}$ をカウントする．例えば，図 4.1 の結果を， y の刻みを，

$$y = -0.02, -0.015, -0.01, -0.005, 0, 0.005, 0.015, 0.02 \quad (4.2)$$

としてカウントすると，表 4.1 のような結果が得られる．

表 4.1 累積度数と分布関数

y	$\#\{Y \leq y\}$	$F(y) := P(Y \leq y)$
-0.02	0	0
-0.015	1	0.001996
-0.01	19	0.037924
-0.005	97	0.193613
0	254	0.506986
0.005	393	0.784431
0.015	499	0.996008
0.02	501	1

図 4.1 見本を昇順にソートした確率変数 ($x = 100$, $\#\Omega = 501$)図 4.2 確率分布関数 ($x = 100$, $\#\Omega = 501$)

表の 2 列目は測定値が y 以下となる見本数で，累積度数と呼ぶ．また，表の 3 列目は事象 $\{Y \leq y\}$ の確率であり，これを改めて，

$$F(y) := P(Y \leq y) \quad (4.3)$$

と書き，確率分布関数または単に分布関数と呼ぶ．

y の刻み幅をさらに細かく ($\Delta y = 4 \times 10^{-5}$) して求めた分布関数を図 4.2 に示す．

算法 4.1 (分布関数の性質) 分布関数 $F(x)$ は一般に次の性質を持つ^{a)}．

- (F1) $F(x)$ は単調増加．
- (F2) $F(-\infty) = 0$, $F(\infty) = 1$.
- (F3) $P(a \leq x \leq b) = F(b) - F(a)$.

演習 4.1 (F1) ~ (F3) を満足する $F(x)$ の概形を図示せよ．

4.1.2 ヒストグラム

図 4.2 の分布関数 $F(y)$ では，測定値の頻度が見えにくい．そこで， y 軸上に均等な n 個の区間：

$$y_i := y_0 + i\Delta y \quad (i = 0, 1, 2, \dots, n) \quad (4.4)$$

をとり，隣り合う分点から連続的な背反事象：

^{a)} パボリス [2] p73 など．

$$A_i := \{y_{i-1} \leq y < y_i\} \quad (i = 1, 2, \dots, n) \quad (4.5)$$

をとる．

事象 A_i に入る見本数 $\#A_i$ をカウントする．これらの列 $\#A_1, \#A_2, \dots$ を度数分布といい，そのグラフをヒストグラムという．表 4.1 と同じデータから求めた度数分布を表 4.2 の $\#A_i$ 列に示す．

表 4.2 ヒストグラムと近似的な密度関数

i	y_{i-1}	y_i	$\#A_i$	$P(A_i)$	$p^*(A_i)$
1	-0.02	-0.015	1	1.996e-03	3.992e-01
2	-0.015	-0.01	18	3.593e-02	7.186e+00
3	-0.01	-0.005	78	1.557e-01	3.114e+01
4	-0.005	0	157	3.134e-01	6.267e+01
5	0	0.005	139	2.774e-01	5.549e+01
6	0.005	0.01	95	1.896e-01	3.792e+01
7	0.01	0.015	11	2.196e-02	4.391e+00
8	0.015	0.02	2	3.992e-03	7.984e-01

$$(X)e(Y) := (X) \times 10^{(Y)}$$

次に，表の $P(A_i)$ 列は， $\#A_i$ を $\#\Omega$ で割って確率として表示したものであり，これを相対度数分布という．図 4.3 はそのグラフだが，これを相対度数ヒストグラムという．各矩形の底辺の範囲をビンと呼び，事象の区間を表す．矩形の高さが，測定値が各区間に入る確率 $P(A_i)$ である．

4.1.3 密度関数

図 4.3 の矩形の面積が確率 $P(A_i)$ になるよう高さ調整したものを，図 4.4 に示す．高さ調整は，

$$p^*(A_i) = \frac{P(A_i)}{\Delta y} \quad (i = 1, 2, \dots, n) \quad (4.6)$$

とすればよい．具体値を表の $p^*(A_i)$ 列に示す．

大雑把にいうと，図 4.4 のグラフ（矩形の面積が確率を表すヒストグラム）形状を，確率密度関数または単に密度関数という．

正確には，試行数 $\rightarrow \infty$ ，ビンの幅 $\Delta y \rightarrow 0$ としたときに浮び上がる関数形：

$$p^*(A_i) \rightarrow p(\bar{y}_i) \quad (i = 1, 2, \dots, n) \quad (4.7)$$

を，確率密度関数という．ここに， \bar{y}_i は区間の代表値である．なお，比較的小さな n に対して近似的な密度関数を求めるときは，中央値：

$$\bar{y}_i := \frac{y_i + y_{i-1}}{2} \quad (i = 1, 2, \dots, n) \quad (4.8)$$

で表示するとグラフの左右の偏りが防げる．




図 4.3 相対度数ヒストグラム ($x = 100$, $\#\Omega = 501$) . 高さが確率を表す .




図 4.4 近似的な確率密度関数 ($x = 100$, $\#\Omega = 501$) . 面積が確率を表す .

▶▶ 「試行数 $\rightarrow \infty$ 」は、同じ測定値が (有限回しか) 繰り返さない試行については「見本数 $\#\Omega \rightarrow \infty$ 」と同義になる .

算法 4.2 (密度関数の性質) 密度関数 $p(x)$ は一般に次の性質を持つ ^{b)} .

(p1) $p(x) \geq 0$.

(p2) $\int_{-\infty}^{\infty} p(x) dx = 1$.

(p3) $P(a \leq X \leq b) = \int_a^b p(x) dx$.

(p4) 分布関数 $F(x)$ が連続関数のとき, $p(x) = \frac{dF(x)}{dx}$.

演習 4.2 性質 (p1) ~ (p4) を図示せよ .

4.2 代表的な確率分布

以上の議論では、ランダム現象のデータから、その分布関数や密度関数を算定した . 得られる分布形は対象に応じて千差万別だが、歴史的にいくつかの典型例が認知されている . 以下、代表的なものを紹介する ^{b)} .

^{b)} パボリス [2] p76 , p77 など .

4.2.1 一様分布

次の密度関数を持つ分布を，一様分布という．

$$p(x) := \begin{cases} \frac{1}{b-a} & (a \leq x \leq b) \\ 0 & (\text{otherwise}) \end{cases} \quad (4.9)$$

これに従うランダム現象の測定値は，区間 $[a, b]$ 上を均等に分布する．

演習 4.3 $p(x)$ のグラフを描け．

4.2.2 ガウス分布 (正規分布)

次の密度関数を持つ分布を，ガウス分布または正規分布という．


$$p(x) = \mathcal{N}(x; m, v) := \frac{1}{\sqrt{2\pi v}} \exp\left(-\frac{(x-m)^2}{2v}\right) \quad (4.10)$$

分布形の中心を定める m を平均値，広がり $v > 0$ を分散という．実現象にはこの分布にフィットするものが多いとされる．ガウス分布を有する確率変数 X は，ガウス型^{c)}であるという．文脈に応じて，ガウスの，ガウス性という言い方もする．ガウス型の確率変数を略して，ガウス確率変数という．

演習 4.4 平均 m と分散 v を変えると，ガウス分布の密度関数 $p(x)$ の重心と幅がどのように変化するか，グラフを描いて考察せよ．

参考まで，Gnuplot による作図例を示す．

```
gnuplot> p(x,m,v)=1/sqrt(2*pi*v)*exp(-(x-m)**2/(2*v))
gnuplot> set sample 200
gnuplot> plot p(x,-1,1), p(x,1,0.2)
```



4.2.3 ガンマ分布

部品寿命の分布や，トラフィックの待ち時間などによくフィットする分布である．

$$p(x) := x^{k-1} \frac{\exp\left(-\frac{x}{\theta}\right)}{\Gamma(k)\theta^k} \quad (x > 0) \quad (4.11)$$

^{c)} 「がうすがた」

4.2.4 裾厚 (fat-tail) 分布

分布形の裾野がガウス分布より桁違いに厚いものをいう．近年，災害の発生頻度，経済データ，人間のバランス運動などがこのタイプの分布を持つことが発見された．未だ研究途上の分布で，これを表す数理モデルが探求されている．

中～高頻度の事象についてはガウス分布と大差ないが，ごく稀に起る事象の確率が桁違いに大きい．例えば，ガウス分布においては 1000 年に 1 度の事象が，裾厚分布では数年に 1 度発現するかも知れない．前者を理論，後者を現実とみると恐しい．

4.3 数値例

4.3.1 一様乱数の分布

一様分布 $[-1, 2]$ の確率変数 X_0

4.3.2 正規乱数の分布


ガウス分布の確率変数 X_0

Code 1 “pdf1.sce” (Scilab)

```

1  clf; clear;
2  N=1e6;
3  x=linspace(-1,2,21);
4  M=12;
5  Xuni = 3*rand(1,N)-1; //
6  Xnor = rand(1,N,'normal');
7  Xuni2 = Xuni .* Xuni;
8  function y = pnor(x)
9      m=0; v=1;
10     y = 1/sqrt(2*pi*v)*exp(-(x-m)^2/(2*v));
11 endfunction
12 function y = puni(x)
13     a=-1; b=2;
14     if (a<=x & x<=b) then
15         y = 1/(b-a);
16     else
17         y = 0;
18     end
19 endfunction
20 function y = puni2(x)
21     y = 1/(2*sqrt(x))*(puni(sqrt(x)) + puni(-sqrt(x)));
22 endfunction
23 subplot(2,1,1); histplot(21,Xuni);
24 fplot2d([-1:0.01:2],puni,2);
25 subplot(2,1,2); histplot(21,Xnor);
26 fplot2d([-5:0.01:5],pnor,2);
27 xs2eps(gcf(),'pdf1.eps')
```

実行例



5

多変数の確率分布

分布関数と密度関数を多変数の場合に拡張すると、独立性という概念が浮上してくる。

5.1 確率ベクトル

確率空間 (Ω, \mathcal{F}, P) において、 d 個の確率変数 (測定値) をとる。

$$X_1(\omega), X_2(\omega), \dots, X_d(\omega) \quad (5.1)$$

これらを成分とするベクトル

$$\mathbf{X}(\omega) := (X_1(\omega), X_2(\omega), \dots, X_d(\omega))^T \quad (5.2)$$

を、 d 次元確率ベクトルという。すなわち、確率ベクトルとは、特定の見本 ω を代入すると、対応する d 次元測定値を返すベクトル値関数である。

▶▶ 確率ベクトルは、確率変数を並べたベクトルであり、確率 P を並べたものではない。

以下、適宜 ω を略して \mathbf{X} と書く。

5.2 2次元の分布

簡単のため、2次元 $\mathbf{X} := (X_1, X_2)^T$ の場合を例にとる。

5.2.1 事象

確率変数 X では、実数軸上の区間から事象 $\{a \leq X \leq b\}$ を定義した。これの自然な拡張として、各 X_i について同様な区間 $D_i := [a_i, b_i]$ をとり、対応する事象をとる。

$$A_i = X_i^{-1}(D_i) = \{X_i \in D_i\} := \{\omega \in \Omega \mid a_i \leq X_i(\omega) \leq b_i\} \quad (i = 1, 2) \quad (5.3)$$

ここで、

$$A_1 \cap A_2 = \{\omega \in \Omega \mid a_1 \leq X_1(\omega) \leq b_1, a_2 \leq X_2(\omega) \leq b_2\} \quad (5.4)$$

であるから、積事象 $A_1 \cap A_2$ は、測定値 $\mathbf{x} = \mathbf{X}(\omega)$ が、実平面 \mathbb{R}^2 上の矩形領域 $[a_1, b_1] \times [a_2, b_2]$ に入る事象を表す。これらを含めた全事象の族を \mathcal{F} とする。

5.2.2 結合確率

任意の 2 つの事象 $A, B \in \mathcal{F}$ に対して, 結合確率 $P(A, B)$ を

$$P(A, B) := P(A \cap B) \quad (5.5)$$

のように定義する. $P(A, B)$ は事象 A, B が同時に起きる確率を表すので, 同時確率とも呼ばれる. この定義より,

$$P(A, B) = P(A \cap B) = P(B \cap A) = P(B, A) \quad (5.6)$$

となることに注意する.

表記短縮のため, 本来なら $P(\text{事象}, \text{事象})$ と書くべきところを, 略して $P(\text{条件}, \text{条件})$ とも書く.

5.2.3 分布関数

X_i の値が x_i 以下となる確率

$$F_i(x_i) := P(X_i \leq x_i) \quad (5.7)$$

を X_i の周辺分布関数という ($i = 1, 2$).

また, X_1 の値が x_1 以下となり, なおかつ X_2 の値が x_2 以下となる確率

$$F(x_1, x_2) := P(X_1 \leq x_1, X_2 \leq x_2) \quad (5.8)$$

を, X_1 と X_2 の結合分布関数という. 特別な場合を除いて,

$$F(x_1, x_2) \neq F(x_2, x_1) \quad (5.9)$$

であることに注意する.

演習 5.1 次の事象が指定する範囲を, (X_1, X_2) 平面上に図示せよ.

$$\{X_1 \leq x_1\}, \quad \{X_2 \leq x_2\}, \quad \{X_1 \leq x_1\} \cap \{X_2 \leq x_2\}$$

算法 5.1 (結合分布関数の性質) $F(x_1, x_2)$ は一般に次の性質を示す^{a)}.

- | | |
|-------------------------------|---------------------------------|
| (1) $F(-\infty, -\infty) = 0$ | (4) $F(\infty, \infty) = 1$ |
| (2) $F(x_1, -\infty) = 0$ | (5) $F(x_1, \infty) = F_1(x_1)$ |
| (3) $F(-\infty, x_2) = 0$ | (6) $F(\infty, x_2) = F_2(x_2)$ |

例題 5.1 (2) と (5) を示せ.

演習 5.2 同様に (1)(3)(4)(6) を示せ.

^{a)} パボリス [2] p132 など.

5.2.4 密度関数

(x_1, x_2) 平面上に分布する測定値の面密度 $p(x_1, x_2)$ を, 結合密度関数という. 特に $F(x_1, x_2)$ が連続関数の場合は,

$$p(x_1, x_2) := \frac{\partial^2 F(x_1, x_2)}{\partial x_1 \partial x_2} \quad (5.10)$$

のように計算できる. 結合確率 $P(A, B)$ とは異なり, 特別な場合を除いて,

$$p(x_1, x_2) \neq p(x_2, x_1) \quad (5.11)$$

であることに注意する.

この密度関数 $p(x_1, x_2)$ を, x_1 や x_2 で積分した

$$\begin{cases} p_1(x_1) := \int_{-\infty}^{\infty} p(x_1, x_2) dx_2 \\ p_2(x_2) := \int_{-\infty}^{\infty} p(x_1, x_2) dx_1 \end{cases} \quad (5.12)$$

を, 周辺密度関数という. 実際に積分を実行すると,

$$\begin{aligned} p_1(x_1) &= \int_{-\infty}^{\infty} \frac{\partial^2 F(x_1, x_2)}{\partial x_1 \partial x_2} dx_2 = \frac{\partial F(x_1, \infty)}{\partial x_1} - \frac{\partial F(x_1, -\infty)}{\partial x_1} \\ &= \frac{\partial F_1(x_1)}{\partial x_1} - \frac{\partial 0}{\partial x_1} = \frac{\partial F_1(x_1)}{\partial x_1} \quad \because \text{算法 5.1 (2) (5)} \end{aligned} \quad (5.13)$$

となって, 周辺分布関数 $F_1(x_1)$ の微分に帰着する (算法 4.2 参照).

算法 5.2 (結合密度関数の性質) $p(x_1, x_2)$ は一般に次の性質を示す.

- (1) $p(x_1, x_2) \geq 0$
- (2) $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} p(x_1, x_2) dx_1 dx_2 = 1$
- (3) $P(a_1 \leq X_1 \leq b_1, a_2 \leq X_2 \leq b_2) = \int_{a_1}^{b_1} \int_{a_2}^{b_2} p(x_1, x_2) dx_1 dx_2$

5.2.5 2 次元のガウス分布

次の結合密度関数で表される X_1, X_2 の分布を, 2 変数ガウス分布という^{b)}.

$$\begin{aligned} p(x_1, x_2) &:= \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left[-\frac{1}{2(1-\rho^2)} \right. \\ &\quad \left. \times \left(\frac{(x_1 - m_1)^2}{\sigma_1^2} - 2\rho \frac{(x_1 - m_1)(x_2 - m_2)}{\sigma_1\sigma_2} + \frac{(x_2 - m_2)^2}{\sigma_2^2} \right) \right] \end{aligned} \quad (5.14)$$

^{b)} パボリス [2] p135 など.

この密度関数の形状は $m_1, m_2, \sigma_1, \sigma_2, \rho$ という 5 つのパラメータで定まるが, m_i を X_i の平均, $\sigma_i > 0$ を X_i の標準偏差, ρ を X_1, X_2 の相関係数という. σ_i^2 を X_i の分散という.

算法 5.3 X_i の周辺密度関数 $p_i(x_i)$ は, 平均 m_i , 分散 σ_i^2 のガウス分布となる.

$$p_i(x_i) = \mathcal{N}(x_i; m_i, \sigma_i^2) = \frac{1}{\sigma_i \sqrt{2\pi}} \exp\left(-\frac{(x_i - m_i)^2}{2\sigma_i^2}\right) \quad (i = 1, 2) \quad (5.15)$$

例題 5.2 示せ. ($u_i := (x_i - m_i)/\sigma_i$ において, (5.14) の指数部分を計算する)

5.3 独立性

2 つの事象が何らかの意味で「無関係」なことを定式化したい.

5.3.1 事象の独立性

そのために確率論では, 独立性の概念を導入する.

定義 5.1 2 つの事象 $A, B \in \mathcal{F}$ の結合確率が,

$$P(A, B) = P(A)P(B) \quad (5.16)$$

となるとき, A と B は独立であるという.

▶▶ (背反事象 \neq 独立) 背反事象 $A \cap B = \emptyset$ は, 互いに無関係とはいえない. なぜなら, A が起きれば B は起らず, B が起きれば A は起らないという意味で, 互いに依存関係にある. 実際に計算してみると, $P(A), P(B) \neq 0$ のとき,

$$P(A, B) := P(A \cap B) = P(\emptyset) = 0 \neq P(A)P(B) \quad (5.17)$$

となる. すなわち, 確率が 0 でない背反事象 A, B は互いに独立ではない.

5.3.2 条件付き確率

2 つの事象 $A, B \in \mathcal{F}$ について, 次の確率を導入する.

$$P(A|B) := \frac{P(A, B)}{P(B)} \quad (P(B) \neq 0) \quad A|B \text{ の読み方「A パイプ B」} \quad (5.18)$$

これを, 条件 B における A の条件付き確率と呼び, 条件 B のなかで A が発生する確率を表す[○]. 右辺は, ラプラスの確率を使うと,

$$P(A|B) := \frac{P(A, B)}{P(B)} = \frac{\frac{\#(A \cap B)}{\#\Omega}}{\frac{\#B}{\#\Omega}} = \frac{\#(A \cap B)}{\#B} \quad (5.19)$$

のように解釈できる.

演習 5.3 $P(A) = \#A/\#\Omega$ と $P(A|B)$ の違いをベン図で説明せよ.

[○]例えば, 男子の留年率 $P(\text{留年} | \text{男子})$ の分母は, 男子の総数. (< 学生総数)




図 5.1 事象の独立性の例

算法 5.4 (条件付き確率の性質) 条件付き確率は一般に次の性質を示す．

(1) 乗法定理： $P(A, B) = P(A|B)P(B)$, $P(B, A) = P(B|A)P(A)$

(2) ベイズの定理： $P(B|A) = \frac{P(A|B)P(B)}{P(A)}$

演習 5.4 示せ．(1) は (5.18) の分母を払えばよい．(2) は, (5.6) より $P(A, B) = P(B, A)$ であることを利用して, 乗法定理の 2 式を等値すると得られる．

条件付き確率を使うと, 独立性の意味がより明確になる．

算法 5.5 事象 A, B が互いに独立ならば, 条件付き確率は次の性質を示す．

$$P(A|B) = P(A) \quad (P(B) \neq 0) \quad (5.20)$$

$$P(B|A) = P(B) \quad (P(A) \neq 0) \quad (5.21)$$

すなわち, A の確率に B は影響せず, B の確率に A は影響しない．

演習 5.5 (5.16) を (5.18) に代入し, 算法 5.5 を示せ．

(5.20) の意味を考えてみる．両辺をラプラスの確率で解釈すると,

$$\frac{\#(A \cap B)}{\#B} = \frac{\#A}{\#\Omega} \quad (5.22)$$

となる．この等式の成否を図 5.1 に模式的に示す．黒枠で見本空間 Ω を表す．そこに無数の見本を均等にばら撒いたとしよう．このとき, 確率 = 面積の割合 となる．

図 5.1 (a) は A, B が独立な場合で, このような配置に対しては (5.22) が成立する．すなわち, 青 B に占める赤 A の割合 $P(A|B)$ と, 全体 Ω に占める赤 A の割合 $P(A)$ は一致する．これに対して, 図 5.1 (b) の A, B は独立でない．なぜなら, 青に占める赤の割合と, 全体に占める赤の割合が一致せず, (5.22) は成立しない．

5.3.3 確率変数の独立性

事象の独立性を、確率変数から逆算した事象に適用すると、確率変数の独立性が定式化できる。

定義 5.2 確率変数 X_1, X_2 の値域の任意の区間 D_1, D_2 に対して、

$$P(X_1 \in D_1, X_2 \in D_2) := P(X_1 \in D_1)P(X_2 \in D_2) \quad (5.23)$$

が成立するとき、 X_1 と X_2 は独立であるという。

この定義の意味するところは、図 5.1 の黒枠の底辺を X_1 軸、左の側辺を X_2 軸とすることで同様に理解できる。

独立な確率変数 X_1, X_2 の分布関数は、

$$\begin{aligned} F(x_1, x_2) &:= P(X_1 \leq x_1, X_2 \leq x_2) \\ &= P(X_1 \leq x_1)P(X_2 \leq x_2) = F_1(x_1)F_2(x_2) \end{aligned} \quad (5.24)$$

のように、周辺分布の積になる。この両辺を x_1 と x_2 で偏微分すると、

$$p(x_1, x_2) = \frac{\partial^2 F_1(x_1)F_2(x_2)}{\partial x_1 \partial x_2} = \frac{\partial F_1(x_1)}{\partial x_1} \frac{\partial F_2(x_2)}{\partial x_2} = p_1(x_1)p_2(x_2) \quad (5.25)$$

となり、結合密度関数は周辺密度関数の積になる。以上をまとめて次の公式を得る。

算法 5.6 互いに独立な確率変数 X_1, X_2 の結合分布は、周辺分布の積で書ける。

$$(1) F(x_1, x_2) = F_1(x_1)F_2(x_2)$$

$$(2) p(x_1, x_2) = p_1(x_1)p_2(x_2)$$

5.3.4 条件付き密度関数

確率変数 X_1, X_2 の結合密度関数 $p(x_1, x_2)$ を、 X_2 の周辺密度関数 $p_2(x_2)$ で割った、

$$p(x_1|x_2) := \frac{p(x_1, x_2)}{p_2(x_2)} \quad (5.26)$$

を、条件 $X_2 = x_2$ における X_1 の条件付き密度関数という。

例えば、2 変数ガウス分布 (5.14) について、条件付密度関数 $p(x_1|x_2)$ を求めると、周辺密度関数 (5.15) より、

$$\begin{aligned} p(x_1|x_2) &:= \frac{p(x_1, x_2)}{p_2(x_2)} = \frac{1}{\sigma_1 \sqrt{1 - \rho^2} \sqrt{2\pi}} \exp \left[-\frac{1}{2(1 - \rho^2)} \right. \\ &\quad \times \left(\frac{(x_1 - m_1)^2}{\sigma_1^2} - 2\rho \frac{(x_1 - m_1)(x_2 - m_2)}{\sigma_1 \sigma_2} + \frac{(x_2 - m_2)^2}{\sigma_2^2} \right) + \frac{(x_2 - m_2)^2}{2\sigma_2^2} \left. \right] \\ &= \cdots \left[-\frac{1}{2(1 - \rho^2)} \left(\frac{(x_1 - m_1)^2}{\sigma_1^2} - 2\rho \frac{(x_1 - m_1)(x_2 - m_2)}{\sigma_1 \sigma_2} + \rho^2 \frac{(x_2 - m_2)^2}{\sigma_2^2} \right) \right] \end{aligned}$$

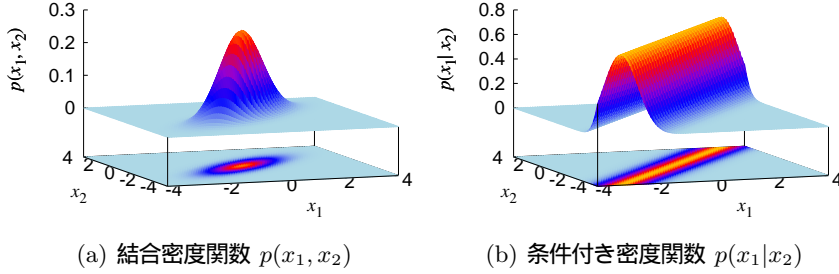


図 5.2 2 変数ガウス分布の結合密度関数と条件付き密度関数 ($m_1 = m_2 = 0$, $\sigma_1 = \sigma_2 = 1$, $\rho = 0.8$)

$$\begin{aligned}
 &= \frac{1}{\sigma_1 \sqrt{1-\rho^2} \sqrt{2\pi}} \exp \left[-\frac{1}{2(1-\rho^2)} \left(\frac{x_1 - m_1}{\sigma_1} - \rho \frac{x_2 - m_2}{\sigma_2} \right)^2 \right] \\
 &= \frac{1}{\sigma_1 \sqrt{1-\rho^2} \sqrt{2\pi}} \exp \left[-\frac{1}{2(1-\rho^2)\sigma_1^2} \left(x_1 - m_1 - \rho \frac{\sigma_1}{\sigma_2} (x_2 - m_2) \right)^2 \right] \\
 &= \mathcal{N} \left(x_1; m_1 + \rho \frac{\sigma_1}{\sigma_2} (x_2 - m_2), \sigma_1^2 (1 - \rho^2) \right) \quad (5.27)
 \end{aligned}$$

すなわち，平均 $m_1 + \rho\sigma_1/\sigma_2(x_2 - m_2)$ ，分散 $\sigma_1^2(1 - \rho^2)$ の正規分布となる．

演習 5.6 同様に $p(x_2|x_1)$ を求めよ．

図 5.2 (a) は 2 変数ガウス分布 (5.14) の結合密度関数 $p(x_1, x_2)$ であり，(b) は対応する (5.27) の条件付き密度関数 $p(x_1|x_2)$ である．例えば， $(x_1, x_2) = (-3, -4)$ の付近 (手前) に着目すると， $p(-3, -4) \approx 8.42 \times 10^{-5}$ であり， $(x_1, x_2) = (-3, -4)$ という測定値は極めて稀にしか実現しないことが分かる．

これに対して， $p(-3|-4) := p(-3, -4)/p_2(-4)$ は，ごく稀に $x_2 = -4$ が測定されたときに $p_2(-4) = 1.34 \times 10^{-4}$ ，もう 1 つの測定値が $x_1 = -3$ になる確率密度である．その値は $p(-3|-4) \approx 0.629$ であり，そうなる頻度は (この例では) 比較的高いことが分かる．

算法 5.7 (条件付き密度関数の性質) 一般に次の性質を示す．

- (1) 条件 x_2 によらず， $\int_{-\infty}^{\infty} p(x_1|x_2) dx_1 = 1$
- (2) 乗法定理： $p(x_1, x_2) = p(x_1|x_2)p_2(x_2)$

5.4 多次元の分布

d 次元確率ベクトル $\mathbf{X} = (X_1, \dots, X_d)^T$ を考える．

5.4.1 密度関数

d 個の確率変数 X_1, \dots, X_d が共存するので, 密度関数は d 変数となる.

$$p(x_1, \dots, x_d) \quad (5.28)$$

5.4.2 周辺密度関数

$d = 4$ で例示すると,

$$p_2(x_2) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} p(x_1, x_2, x_3, x_4) dx_1 dx_3 dx_4 \quad (5.29)$$

$$p_{13}(x_1, x_3) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} p(x_1, x_2, x_3, x_4) dx_2 dx_4 \quad (5.30)$$

$$p_{134}(x_1, x_3, x_4) = \int_{-\infty}^{\infty} p(x_1, x_2, x_3, x_4) dx_2 \quad (5.31)$$

のようなものを考える.

5.4.3 独立性

同じく, $d = 4$ で例示すると,

- X_1 と X_2, X_3, X_4 が独立 $p(x_1, x_2, x_3, x_4) = p_1(x_1)p_{234}(x_2, x_3, x_4)$
- X_1, X_3 と X_2, X_4 が独立 $p(x_1, x_2, x_3, x_4) = p_{13}(x_1, x_3)p_{24}(x_2, x_4)$

5.4.4 条件付き密度関数

同じく,

$$p(x_1, x_2, x_3 | x_4) := \frac{p(x_1, x_2, x_3, x_4)}{p_4(x_4)} \quad (5.32)$$

$$p(x_1, x_3 | x_2, x_4) := \frac{p(x_1, x_2, x_3, x_4)}{p_{24}(x_2, x_4)} \quad (5.33)$$

$$p(x_3 | x_1, x_2, x_4) := \frac{p(x_1, x_2, x_3, x_4)}{p_{124}(x_1, x_2, x_4)} \quad (5.34)$$

などとなる.

♣ 5 章の補足

A5 解答例

A5.1 例題 5.1 p32 の解答例

$$\begin{aligned} (2) \text{ について, } F(x_1, -\infty) &:= P(\{X_1 \leq x_1\} \cap \{X_2 \leq -\infty\}) \\ &= P(\{X_1 \leq x_1\} \cap \emptyset) = P(\emptyset) = 0 \end{aligned}$$

$$\begin{aligned} (5) \text{ について, } F(x_1, \infty) &:= P(\{X_1 \leq x_1\} \cap \{X_2 \leq \infty\}) \\ &= P(\{X_1 \leq x_1\} \cap \Omega) = P(\{X_1 \leq x_1\}) =: F_1(x_1) \end{aligned}$$

A5.2 例題 5.2 p34 の解答例

(5.14) の指数部分 E は, $u_i := (x_i - m_i)/\sigma_i$ と置くと,

$$\begin{aligned} E &= -\frac{1}{2(1-\rho^2)}(u_1^2 - 2\rho u_1 u_2 + u_2^2) \\ &= -\frac{1}{2(1-\rho^2)}((u_1 - \rho u_2)^2 + u_2^2 - \rho^2 u_2^2) = -\frac{(u_1 - \rho u_2)^2}{2(1-\rho^2)} - \frac{u_2^2}{2} \end{aligned}$$

周辺密度関数を置換積分で整理していくと, $dx_i = \sigma_i du_i$ より,

$$\begin{aligned} p_2(x_2) &:= \int_{-\infty}^{\infty} p(x_1, x_2) dx_1 = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \int_{-\infty}^{\infty} \exp(E) dx_1 \\ &= \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \int_{-\infty}^{\infty} \exp\left(-\frac{(u_1 - \rho u_2)^2}{2(1-\rho^2)}\right) \sigma_1 du_1 \cdot \exp\left(-\frac{u_2^2}{2}\right) \\ &= \int_{-\infty}^{\infty} \frac{1}{\sqrt{1-\rho^2}\sqrt{2\pi}} \exp\left(-\frac{(u_1 - \rho u_2)^2}{2(1-\rho^2)}\right) du_1 \cdot \frac{1}{\sigma_2\sqrt{2\pi}} \exp\left(-\frac{u_2^2}{2}\right) \\ &= \underbrace{\int_{-\infty}^{\infty} \mathcal{N}(u_1; \rho u_2, (1-\rho^2)) du_1}_{=1} \cdot \frac{1}{\sigma_2\sqrt{2\pi}} \exp\left(-\frac{u_2^2}{2}\right) \end{aligned}$$

6

期待値

確率変数の値 (測定値) のばらつき具合を、いくつかの指標で表す。

6.1 確率変数の期待値

以下、確率変数 $X(\omega)$ を略して X と表記する。

6.1.1 密度関数 $p(x)$ が既知の場合

確率変数 X の確率密度関数を $p(x)$ とする。 $p(x)$ を x 軸上に分布する物質の線密度とみなしたときの重心：

$$m_X = \langle X \rangle := \int_{-\infty}^{\infty} x p(x) dx \quad \left(= \frac{\int_{-\infty}^{\infty} x p(x) dx}{\int_{-\infty}^{\infty} p(x) dx = 1} \right) \quad (6.1)$$

を、 X の期待値または平均値という。以下、 $\langle \cdots \rangle$ を平均操作と呼ぶことにする。 m_X は X の値のばらつきの重心であるから、ばらつきの中心を表す指標になる。

演習 6.1 $p(x)$ が一様分布 (4.9) であるときの期待値を求めよ。

同様に、スカラー値関数 $f(\cdot)$ を介した、

$$\langle f(X) \rangle := \int_{-\infty}^{\infty} f(x) p(x) dx \quad (6.2)$$

を、 $f(X)$ の期待値または平均値という。特に、 $f(x) = x^n$ としたもの

$$m_X^{(n)} := \langle X^n \rangle = \int_{-\infty}^{\infty} x^n p(x) dx \quad (n = 1, 2, 3, \cdots) \quad (6.3)$$

を n 次モーメントと呼ぶ。これを期待値との差で計算したもの、

$$s_X^{(n)} := \langle (X - m_X)^n \rangle = \int_{-\infty}^{\infty} (x - m_X)^n p(x) dx \quad (n = 1, 2, 3, \cdots) \quad (6.4)$$

を n 次中心モーメントと呼ぶ。特に、 $n = 2$ のときの中心モーメント、

$$\sigma_X^2 := s_X^{(2)} = \langle (X - m_X)^2 \rangle \quad (n = 1, 2, 3, \dots) \quad (6.5)$$

を分散という．分散は平均値からの「ばらつき」を表す指標としてよく用いられる．

同じく「ばらつき」を表す量として，分散の正の平方根 $\sigma_X := \sqrt{\sigma_X^2}$ もよく用いられる．これを標準偏差という．標準偏差は「ばらつき」を確率変数と同じ単位で表す．例えば， X [m] の分散の単位は σ_X^2 [m²] だが，標準偏差の単位は σ_X [m] となる．

演習 6.2 $p(x)$ が一様分布 (4.9) であるときの分散を求めよ．

算法 6.1 (ガウス分布の期待値と分散) (4.10) のガウス分布 $p(x) = \mathcal{N}(x; m, v)$ の期待値と分散は，

$$\langle X \rangle = \int_{-\infty}^{\infty} x p(x) = m, \quad \langle (X - m)^2 \rangle = \int_{-\infty}^{\infty} (x - m)^2 p(x) = v \quad (6.6)$$

6.1.2 密度関数 $p(x)$ が未知の場合

確率変数 $x = X(\omega)$ の試行列 x_1, x_2, \dots から標本

$$\Pi_n := \{x_1, x_2, \dots, x_n\} \quad (6.7)$$

をとる． n は試行回数である．このとき，

$$\langle X \rangle_n := \frac{1}{n} \sum_{i=1}^n x_i \quad (6.8)$$

を， X の標本平均という．同様に，適当なスカラー値関数 $f(\cdot)$ を介した，

$$\langle f(X) \rangle_n := \frac{1}{n} \sum_{i=1}^n f(x_i) \quad (6.9)$$

を， $f(X)$ の標本平均という．

単に平均と言わずに「標本」をつけるのは，標本を変えると $\langle X \rangle_n$ の値が変化するためである．例えば，標本 Π_n を別の標本 $\Pi'_n := \{x_{n+1}, x_{n+2}, \dots, x_{2n}\}$ に置き換えると， $\langle X \rangle_n$ は変化する．また標本数 n を変えても $\langle X \rangle_n$ は変化する．

ところで，分散 σ_X^2 に対応する標本平均は，

$$\langle (X - m)^2 \rangle_n := \frac{1}{n} \sum_{i=1}^n (x_i - m)^2, \quad m = \langle X \rangle_n \quad (6.10)$$

であり，これを標本分散というが， n が小さいときは理論値 σ_X^2 より若干小さな値をとる．そこで，分母を補正した，

$$\langle (X - m)^2 \rangle_n^* := \frac{1}{1 - n} \sum_{i=1}^n (x_i - m)^2 \quad (6.11)$$

を用いることがあり，これを不偏分散という．標本数 n が十分大きければ両者はほぼ等しい．

6.1.3 標本平均の性質

標本平均 $\langle X \rangle_n$ は、理論的な平均 $\langle X \rangle$ の近似値を与える．次の定理が成立する．

算法 6.2 (大数の法則) 期待値 $\langle X \rangle$ が存在する確率変数 X について ^{a)} ,

$$\langle X \rangle_n \rightarrow \langle X \rangle \quad (n \rightarrow \infty) \quad (6.12)$$

が成立する．

また、平均値 $\langle X \rangle$ まわりの $\langle X \rangle_n$ のばらつきについては、次の定理が成立する．

算法 6.3 (中心極限定理) X を平均 m , 分散 σ の確率変数とする． X の試行列から複数の異なる標本 Π_n^1, Π_n^2, \dots をとり、それらの標本平均

$$m^1 = \langle X \rangle_n, m^2 = \langle X \rangle_n, \dots \quad (6.13)$$

を考える． m^1, m^2, \dots はランダムな試行列となり、その分布は、 $n \rightarrow \infty$ の極限で平均 m , 分散 σ^2/n のガウス分布に近づく．

▶▶ 算法 6.3 では、 X をガウス型としていない．ようするに、どんな分布の確率変数でも、いっぱい足すと、ガウス分布に近づくということ．

以上をまとめると、標本平均 $\langle X \rangle_n$ の n を十分に大きくとると、

- 算法 6.2 により、 X の相異なる試行列から計算した標本平均の重心は、どれも理論値 $\langle X \rangle$ に近づく．
- さらに算法 6.3 で、 $\sigma^2/n \rightarrow 0$ ($n \rightarrow \infty$) だから、標本平均の分散は 0 に近づく．

ということが分かる．すなわち、期待値が存在する確率変数の標本平均は、標本数 n を増やしていくと、理論値の近くに集積していく．

6.2 確率ベクトルの期待値

簡単のため、2 次元 $X := (X_1, X_2)^T$ の場合を例にとる．

6.2.1 多変数の期待値

単独の確率変数との違いとして、密度関数を結合密度関数 $p(x_1, x_2)$ とし、積分を 2 重積分とする．すなわち、 $f(X_1, X_2)$ に対する平均操作を、

$$\langle f(X_1, X_2) \rangle := \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x_1, x_2) p(x_1, x_2) dx_1 dx_2 \quad (6.14)$$

で定める．代表的な期待値 (広義) とその記号や名称を表 6.1 に示す．

^{a)} 期待値が定まらない分布もあるので仮定が必要．例えば、コーシー分布は極限の取り方で期待値が変化する．

表 6.1 代表的な期待値 (広義)

名称	記号 1	記号 2	定義
X_i の期待値 (狭義)	$E[X_i]$	m_i	$\langle X_i \rangle$
X_i の n 次モーメント	—	$m_i^{(n)}$	$\langle X_i^n \rangle$
X_i の n 次中心モーメント	—	$s_i^{(n)}$	$\langle (X_i - m_i)^n \rangle$
X_i の分散 ($= s_i^{(2)}$)	$V[X_i]$	σ_i^2	$\langle (X_i - m_i)^2 \rangle$
X_i の標準偏差	$SD[X_i]$	σ_i	$\sqrt{\sigma_i^2}$
X_i, X_j の結合モーメント	—	m_{ij}	$\langle X_i X_j \rangle$
X_i, X_j の共分散	$\text{Cov}[X_i, X_j]$	C_{ij}	$\langle (X_i - m_i)(X_j - m_j) \rangle$
X_i, X_j の相関係数	—	ρ_{ij}	$C_{ij}/(\sigma_i \sigma_j)$

相関係数 ρ_{ij} は, 標準偏差 σ_i, σ_j で規格化した確率変数 $X'_i := X_i/\sigma_i, X'_j := X_j/\sigma_j$ の共分散を表す.

$$\rho_{ij} = \text{Cov}[X'_i, X'_j] \quad (6.15)$$

なお, ベクトル $X = (X_1, X_2)^T$ に対する平均操作は, 各成分に対する平均操作

$$\left\langle \begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \right\rangle := \begin{pmatrix} \langle X_1 \rangle \\ \langle X_2 \rangle \end{pmatrix} \quad (6.16)$$

を意味すると約束する. 2 次元の期待値 $m := (\langle X_1 \rangle, \langle X_2 \rangle)^T$ は, $p(x_1, x_2)$ を (x_1, x_2) 平面上に分布する物質の面密度とみなしたときの重心ベクトルを与える.

6.2.2 期待値に関する公式

(a) 加法とスカラ倍 積分の性質 $\iint f + g \, dx_1 dx_2 = \iint f \, dx_1 dx_2 + \iint g \, dx_1 dx_2$, $\iint \alpha f \, dx_1 dx_2 = \alpha \iint f \, dx_1 dx_2$ より,

$$\langle f(X_1, X_2) + g(X_1, X_2) \rangle = \langle f(X_1, X_2) \rangle + \langle g(X_1, X_2) \rangle \quad (6.17)$$

$$\langle \alpha f(X_1, X_2) \rangle = \alpha \langle f(X_1, X_2) \rangle \quad (6.18)$$

が成立する. これを応用すると, 以下の公式が示せる.

算法 6.4 (分散の公式)

- (1) $V[X_i] = \langle X_i^2 \rangle - m_i^2$
- (2) $\text{Cov}[X_1, X_2] = \langle X_1 X_2 \rangle - m_1 m_2$

例題 6.1 (1) を示せ.

演習 6.3 同様に (2) を示せ.

演習 6.4 同様に (6.15) を示せ. (ヒント: $\langle (X'_i - m'_i)(X'_j - m'_j) \rangle$ に $m'_i = \langle X'_i \rangle = \langle X_i/\sigma_i \rangle = m_i/\sigma_i$ を代入して展開する)

算法 6.5 (相関係数の性質)

$$-1 \leq \rho_{ij} \leq 1 \quad (6.19)$$

例題 6.2 示せ .

(b) 低次元化 1 変数の平均操作は周辺密度で簡単にできる .

算法 6.6 X_i の周辺密度関数 $p_i(x_i)$ が既知のとき , $f(X_i)$ の期待値は ,

$$\langle f(X_i) \rangle = \int_{-\infty}^{\infty} f(x_i) p_i(x_i) dx_i \quad (i = 1, 2) \quad (6.20)$$

例題 6.3 示せ .

6.3 条件付き期待値

6.3.1 関数としての定義

$Y = y$ を条件とする X の条件付き密度関数 $p(x|y)$ による期待値 ,

$$E[X|y] = \langle X|y \rangle := \int_{-\infty}^{\infty} x p(x|y) dx \quad (6.21)$$

を考える . 変数 y が残されているので , $E[X|y]$ は y の関数である . これを , 条件 $Y = y$ における X の条件付き期待値という .

$E[X|y]$ は , 確率ベクトル (X, Y) の試行列

$$(x_1, y_1), (x_2, y_2), (x_3, y_3), \dots \quad (6.22)$$

において , 与えられた定数 $y_i = y$ を検出したときの相方 x_i の期待値を表す ^{b)} .

6.3.2 確率変数としての定義

(6.21) の定義には , 実は , 論理上の問題がある . なぜなら , 確率変数 Y の値が定数 y に一致する確率は 0 なので , 実際に $Y = y$ を検出する可能性は無きに等しい .

そこで , 次の計算をヒントにする .

$$\begin{aligned} \langle X \rangle &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x p(x, y) dx dy \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x p(x|y) p(y) dx dy \quad \because \text{算法 5.7 p37(2)} \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x p(x|y) dx p(y) dy = \int_{-\infty}^{\infty} E[X|y] p(y) dy \end{aligned} \quad (6.23)$$

^{b)} 例えば , 身長・体重の一覧において , 身長 170cm の人の平均体重 $E[\text{体重} | 170\text{cm}]$ など .

最後の式は, $\phi(y) = E[X|y]$ と置くと, 確率変数 Y の関数 $\phi(Y)$ の期待値

$$\int_{-\infty}^{\infty} \phi(y)p(y)dy = \langle \phi(Y) \rangle = \langle E[X|Y] \rangle \quad (6.24)$$

になっている.

以上を踏まえて, 確率変数 $Y(\omega)$ の関数であるところの確率変数

$$E[X|Y](\omega) := \phi(Y(\omega)) \quad (6.25)$$

を改めて, 条件 Y における X の条件付き期待値と定める. その土台となる関数形 $\phi(y) = E[X|y]$ は, (6.21) から求める.

算法 6.7 確率変数 X_1, X_2 の結合密度関数 $p(x_1, x_2)$ が 2 変数ガウス分布 (5.14) であるとき, 条件付き期待値 $E[X_1|X_2]$ の関数形 $\phi(x_2) = E[X_1|x_2]$ は,

$$E[X_1|x_2] = m_1 + \rho_{12} \frac{\sigma_1}{\sigma_2} (x_2 - m_2) = m_1 + \frac{C_{12}}{\sigma_2^2} (x_2 - m_2) \quad (6.26)$$

演習 6.5 示せ. (5.27) p37 の条件付き密度 $p(x_1|x_2)$ の期待値 (6.6) を求めればよい.

算法 6.8 (条件付き期待値の性質 1) 定数 a, b, c と実数値関数 $f(x), g(x)$ に対して,

$$(1) E[a f(Y) + b g(Y) + c|x] = a E[f(Y)|x] + b E[g(Y)|x] + c.$$

$$(2) E[f(X)g(Y)|x] = f(x) E[g(Y)|x].$$

条件付き期待値 $E[X|Y]$ について,

$$(3) E[E[X|Y]] := \int_{-\infty}^{\infty} E[X|y] dy = E[X]. \quad \therefore (6.23)$$

例題 6.4 (2) を示せ.

演習 6.6 同様に (1) を示せ.

6.4 共分散と相関

定義 6.1 (無相関) 確率変数 X_1, X_2 が無相関であるとは, 共分散が 0 になること

$$\text{Cov}[X_i, X_j] = 0 \quad (6.27)$$

をいう. 特に $\sigma_i, \sigma_j \neq 0$ のときは, 相関係数が 0 になること

$$\rho_{ij} = 0 \quad (6.28)$$

と同じである.

$\text{Cov}[X_i, X_j] > 0$ のとき, X_i と X_j には正の相関があるといい, $\text{Cov}[X_i, X_j] < 0$ のときは負の相関があるという. このとき, X_i と X_j の間には正または負の比例関係が見い出される. 逆に, X_i, X_j が無相関ならば比例関係は見出せない.

6.4.1 独立 \implies 無相関

X_1, X_2 を独立な確率変数とする．このとき結合密度関数は、算法 5.6 より、 $p(x_1, x_2) = p_1(x_1)p_2(x_2)$ となるので、

$$\begin{aligned}\text{Cov}[X_1, X_2] &:= \langle (X_1 - m_1)(X_2 - m_2) \rangle \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x_1 - m_1)(x_2 - m_2)p_1(x_1)p_2(x_2)dx_1dx_2 \\ &= \int_{-\infty}^{\infty} (x_1 - m_1)p_1(x_1)dx_1 \int_{-\infty}^{\infty} (x_2 - m_2)p_2(x_2)dx_2 \\ &= m_1 - m_1 + m_2 - m_2 = 0 \quad (6.29)\end{aligned}$$

となる．すなわち、次がいえる．

算法 6.9 X_1, X_2 が独立 $\implies X_1, X_2$ は無相関．

しかしながら、その逆は一般には成立しない．

6.4.2 無相関だが独立でない例

例えば、 $\Omega := \{1, 2, 3, 4\}$ をとり、その確率を、

$$P(\{\omega\}) = \frac{1}{4} \quad (\omega = 1, 2, 3, 4) \quad (6.30)$$

で定めたとする．ここで、次のような確率変数 X_1, X_2 をとると、

$$\begin{cases} X_1(1) = 1, & X_1(2) = 0, & X_1(3) = -1, & X_1(4) = 0 \\ X_2(1) = 0, & X_2(2) = 1, & X_2(3) = 0, & X_2(4) = -1 \end{cases} \quad (6.31)$$

これらは無相関になる．すなわち、

$$\begin{aligned}m_X &= E[X] = 0, & m_Y &= E[Y] = 0 \\ \text{Cov}[X_1, X_2] &= \frac{1}{4} \sum_{\omega=1}^4 (X_1(\omega) - m_1)(X_2(\omega) - m_2) = 0\end{aligned}$$

しかし、例えば、

$$P(X_1 = 1, X_2 = 0) = \frac{1}{4} \neq P(X_1 = 1)P(X_2 = 0) = \frac{1}{4} \cdot \frac{1}{2} = \frac{1}{8} \quad (6.32)$$

より独立ではない．

6.4.3 ガウス分布なら、独立 \iff 無相関

ただし、ガウス分布に話を限ると逆も成立する． X_1, X_2 が 2 変数ガウス分布 (5.14) に従うとする．無相関 $\rho_{12} = 0$ を仮定して、 $\rho = \rho_{12} = 0$ を (5.14) に代入すると、

$$\begin{aligned}
p(x_1, x_2) &:= \frac{1}{2\pi\sigma_1\sigma_2} \exp \left[-\frac{1}{2} \times \left(\frac{(x_1 - m_1)^2}{\sigma_1^2} + \frac{(x_2 - m_2)^2}{\sigma_2^2} \right) \right] \\
&= \frac{1}{\sigma_1\sqrt{2\pi}} \exp \left[-\frac{(x_1 - m_1)^2}{2\sigma_1^2} \right] \frac{1}{\sigma_2\sqrt{2\pi}} \exp \left[-\frac{(x_2 - m_2)^2}{2\sigma_2^2} \right] \\
&= p_1(x_1)p_2(x_2)
\end{aligned} \tag{6.33}$$

となって、独立性 (算法 5.6) が帰結される。 $p_i(x_i)$ は算法 5.3 の周辺分布である。
 これと一般論「独立 \implies 無相関」を組み合わせると、

算法 6.10 X_1, X_2 がガウス型確率変数ならば、

$$X_1, X_2 \text{ が独立} \xLeftrightarrow[\text{十分}]{\text{必要}} X_1, X_2 \text{ は無相関.}$$

6.5 ベクトルと行列の期待値

d 次元確率ベクトル $\mathbf{X} = (X_1, \dots, X_d)^T$ を考える。 d 個の確率変数が共存するので、平均操作は d 重積分となる。

$$\langle f(X_1, \dots, X_d) \rangle := \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f(x_1, \dots, x_d) p(x_1, \dots, x_d) dx_1 \cdots dx_d \tag{6.34}$$

確率ベクトルの期待値 $\langle \mathbf{X} \rangle$ は、各成分の平均操作 (6.34) を意味すると約束する。

$$\langle \mathbf{X} \rangle = \left\langle \begin{pmatrix} X_1 \\ \vdots \\ X_d \end{pmatrix} \right\rangle := \begin{pmatrix} \langle X_1 \rangle \\ \vdots \\ \langle X_d \rangle \end{pmatrix} = \begin{pmatrix} m_1 \\ \vdots \\ m_d \end{pmatrix} \tag{6.35}$$

同様に、行列の期待値 $\langle A \rangle$ も各成分の平均操作であるとする。

$$\langle A \rangle = \left\langle \begin{pmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{pmatrix} \right\rangle := \begin{pmatrix} \langle a_{11} \rangle & \cdots & \langle a_{1n} \rangle \\ \vdots & \ddots & \vdots \\ \langle a_{m1} \rangle & \cdots & \langle a_{mn} \rangle \end{pmatrix} \tag{6.36}$$

条件付き期待値は、多次元の条件付き密度関数を用いて、次のようにとる。

$$E[X_1|x_2, x_3] = \int_{-\infty}^{\infty} x_1 p(x_1|x_2, x_3) dx_1, \quad p(x_1|x_2, x_3) := \frac{p(x_1, x_2, x_3)}{p(x_2, x_3)} \tag{6.37}$$

算法 6.11 (条件付き期待値の性質 2) ガウス確率変数 X_1, X_2, X_3 について、 X_2, X_3 が独立ならば、

$$E[X_1|X_2, X_3] = E[X_1|X_2] + E[X_1|X_3] - E[X_1] \tag{6.38}$$

例題 6.5 示せ。算法 6.7 p45 と、その多次元版である算法 9.2 p67 による。

♣ 6 章の補足

A6 解答例

A6.1 例題 6.1 p43 の解答例

$$\begin{aligned} (1) \text{ について, } V[X_i] &= \langle (X_i - m_i)^2 \rangle = \langle X_i^2 - 2m_i X_i + m_i^2 \rangle \\ &= \langle X_i^2 \rangle - 2m_i \langle X_i \rangle + m_i^2 \langle 1 \rangle = \langle X_i^2 \rangle - m_i^2 \end{aligned}$$

A6.2 例題 6.2 p44 の解答例

任意の t に対して, $S = \{(X_i - m_i)t + (X_j - m_j)\}^2 \geq 0$ は明らか. その平均も当然 $\langle S \rangle = \langle (X_i - m_i)^2 \rangle t^2 + 2 \langle (X_i - m_i)(X_j - m_j) \rangle t + \langle (X_j - m_j)^2 \rangle \geq 0$ となる. すなわち, $\sigma_i^2 t^2 + 2C_{ij}t + \sigma_j^2 \geq 0$ がいえる. これが任意の t で成立するのだから, 判別式は $C_{ij}^2 - \sigma_i^2 \sigma_j^2 \geq 0$ となる. ゆえに $(\rho_{ij})^2 \leq 1$.

A6.3 例題 6.3 p44 の解答例

$$\begin{aligned} & \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x_1) p(x_1, x_2) dx_1 dx_2 \\ &= \int_{-\infty}^{\infty} f(x_1) \int_{-\infty}^{\infty} p(x_1, x_2) dx_2 dx_1 = \int_{-\infty}^{\infty} f(x_1) p_1(x_1) dx_1 \end{aligned}$$

A6.4 例題 6.4 p45 の解答例

(2) について,

$$E[f(X)g(Y)|x] = \int_{-\infty}^{\infty} f(x)g(y)p(y|x)dy = f(x) \int_{-\infty}^{\infty} g(y)p(y|x)dy$$

A6.5 例題 6.5 p47 の解答例

まず右辺は, 算法 6.7 p45 の $E[X_1|X_2] = m_1 + \frac{C_{12}}{\sigma_2^2}(x_2 - m_2)$, $E[X_1|X_3] = m_1 + \frac{C_{13}}{\sigma_3^2}(x_3 - m_3)$ より, (右辺) $= m_1 + \frac{C_{12}}{\sigma_2^2}(x_2 - m_2) + \frac{C_{13}}{\sigma_3^2}(x_3 - m_3)$ となる.

次に左辺は, 算法 9.2 p67 で $\mathbf{Y} := X_1$, $\mathbf{X} := (X_2, X_3)^T$ とおく. X_2, X_3 はガウス性で独立と仮定したから $C_{23} = 0$ より,

$$A_0 = \Sigma_{yx} \Sigma_{xx}^{-1} = (C_{12}, C_{13}) \begin{pmatrix} \sigma_2^2 & C_{23} \\ C_{23} & \sigma_3^2 \end{pmatrix}^{-1} = \left(\frac{C_{12}}{\sigma_2^2}, \frac{C_{13}}{\sigma_3^2} \right)$$

となるが, これを $E[X_1|X_2, X_3] = E[\mathbf{Y}|\mathbf{X}] = \bar{\mathbf{y}} + A_0(\mathbf{X} - \bar{\mathbf{X}})$ に代入すると, 右辺と同じ式を得る.

7

確率ベクトルの変換

例えば, X, Y がガウス分布のとき, $X + Y$ がどういう分布になるのか計算する. 前章までの算法の応用であり, よい計算練習になる. もちろん計算結果も大事で, 後続の章で使われる.

7.1 確率変数の加法とスカラ倍

X, Y を確率変数とする.

7.1.1 加法 $Z = X + Y$ の分布

X, Y の結合密度関数 $p_{XY}(x, y)$ を既知とする. Z の分布関数は,

$$F_Z(z) := P(\{Z \leq z\}) \quad (7.1)$$

であるが, 事象 $\{Z \leq z\} = \{X + Y \leq z\}$ の範囲より,

$$F_Z(z) := \int_{-\infty}^{\infty} \left\{ \int_{-\infty}^{z-y} p_{XY}(x, y) dx \right\} dy = \int_{-\infty}^{\infty} \left\{ \int_{-\infty}^z p_{XY}(s - y, y) ds \right\} dy \quad (7.2)$$

となる (中括弧内を $x = s - y$ で置換した). これを z で微分すると,

$$p_Z(z) = \frac{dF_Z(z)}{dz} = \int_{-\infty}^{\infty} p_{XY}(z - y, y) dy \quad (7.3)$$

という公式を得る.

特に, X, Y が独立ならば, $p_{XY}(z - y, y) = p_X(z - y)p_Y(y)$ より,

$$p_Z(z) = \int_{-\infty}^{\infty} p_X(z - y)p_Y(y) dy \quad (7.4)$$

となる. この形式の積分を, 畳み込み積分と呼んだ.

7.1.2 スカラ倍 $Z = aX$ の分布

X の密度関数 $p_X(x)$ を既知とする．まず， X と Z の分布関数の定義は，

$$F_X(x) = P(\{X \leq x\}), \quad F_Z(z) = P(\{Z \leq z\}) \quad (7.5)$$

であった． P は確率である．ここで，事象 $\{Z \leq z\} = \{aX \leq z\}$ は，事象 $\{X \leq a^{-1}z\}$ と同じなので，

$$F_Z(z) = P(\{Z \leq z\}) = P(\{X \leq a^{-1}z\}) = F_X(a^{-1}z) \quad (7.6)$$

が成立する．これを z で微分することで， Z の密度関数が判明する．

$$p_Z(z) := \frac{dF_Z(z)}{dz} = \frac{dF_X(a^{-1}z)}{dz} = \frac{da^{-1}z}{dz} \frac{dF_X(x)}{dx} \Big|_{x=a^{-1}z} = a^{-1}p_X(a^{-1}z) \quad (7.7)$$

7.2 ガウス確率変数の加法とスカラ倍

X, Y をガウス確率変数とする．

7.2.1 加法 $Z = X + Y$ の分布

X, Y の 2 変数ガウス分布が既知とする．

$$p_{XY}(x, y) := \frac{1}{2\pi\sigma_X\sigma_Y\sqrt{1-\rho^2}} \exp \left[-\frac{1}{2(1-\rho^2)} \right. \\ \left. \times \left(\frac{(x-m_X)^2}{\sigma_X^2} - 2\rho \frac{(x-m_X)(y-m_Y)}{\sigma_X\sigma_Y} + \frac{(y-m_Y)^2}{\sigma_Y^2} \right) \right] \quad (7.8)$$

(7.3) に代入すると，

$$p_Z(z) = \int_{-\infty}^{\infty} p_{XY}(z-y, y) dy = \int_{-\infty}^{\infty} \frac{1}{2\pi\sigma_X\sigma_Y\sqrt{1-\rho^2}} \exp \left[-\frac{1}{2(1-\rho^2)} \right. \\ \left. \times \left(\frac{(z-y-m_X)^2}{\sigma_X^2} - 2\rho \frac{(z-y-m_X)(y-m_Y)}{\sigma_X\sigma_Y} + \frac{(y-m_Y)^2}{\sigma_Y^2} \right) \right] dy \quad (7.9)$$

積分を実行すると，

$$p_Z(z) = \frac{1}{\sqrt{\sigma_X^2 + 2\rho\sigma_X\sigma_Y + \sigma_Y^2}\sqrt{2\pi}} \exp \left[-\frac{(z-m_X-m_Y)^2}{2(\sigma_X^2 + 2\rho\sigma_X\sigma_Y + \sigma_Y^2)} \right] \\ = \mathcal{N}(z; m_X + m_Y, \sigma_X^2 + 2C_{XY} + \sigma_Y^2) \quad (7.10)$$

を得る．すなわち， $Z = X + Y$ は，平均 $m_Z = m_X + m_Y = E[X + Y]$ ，分散 $\sigma_Z^2 = \sigma_X^2 + 2C_{XY} + \sigma_Y^2 = \langle (X - m_Z + Y - m_Y)^2 \rangle = V[X + Y]$ のガウス分布に従う．

7.2.2 スカラ倍 $Z = aX$ の分布

X のガウス分布 $\mathcal{N}(x; m_x, \sigma_x^2)$ を既知とする．(7.7) より，

$$\begin{aligned} p_Z(z) &= a^{-1} p_X(a^{-1}z) = \frac{1}{a\sigma_x\sqrt{2\pi}} \exp\left\{-\frac{(a^{-1}z - m_x)^2}{2\sigma_x^2}\right\} \\ &= \frac{1}{a\sigma_x\sqrt{2\pi}} \exp\left\{-\frac{(z - am_x)^2}{2a^2\sigma_x^2}\right\} = \mathcal{N}(z; am_x, a^2\sigma_x^2) \quad (7.11) \end{aligned}$$

という公式を得る．すなわち， $Z = aX$ は，平均 $m_z = am_x = E[aX]$ ，分散 $\sigma_z^2 = a^2\sigma_x^2 = V[aX]$ のガウス確率変数となる．

7.2.3 線形結合 $Z = a_1X_1 + a_2X_2$

$m_i = E[X_i]$ ， $\sigma_i^2 := V[X_i]$ ， $C_{12} := \text{Cov}[X_1, X_2]$ とする．まず，(7.11) より， $Z_i = a_iX_i$ は平均 $m'_i = E[a_iX_i] = a_im_i$ ，分散 $\sigma'^2_i = V[a_iX_i] = a_i^2\sigma_i^2$ のガウス確率変数となる．さらに，(7.10) より， $Z = Z_1 + Z_2$ は，平均が

$$m_Z = E[Z_1 + Z_2] = E[a_1X_1 + a_2X_2] = a_1m_1 + a_2m_2 \quad (7.12)$$

で，分散が

$$\begin{aligned} \sigma_Z^2 &= V[Z_1 + Z_2] = V[a_1X_1 + a_2X_2] \\ &= a_1^2\sigma_1^2 + 2a_1a_2C_{12} + a_2^2\sigma_2^2 = \begin{pmatrix} a_1 & a_2 \end{pmatrix} \begin{pmatrix} \sigma_1^2 & C_{12} \\ C_{12} & \sigma_2^2 \end{pmatrix} \begin{pmatrix} a_1 \\ a_2 \end{pmatrix} \quad (7.13) \end{aligned}$$

のガウス確率変数となる．

以上を帰納的に用いると，次の結果が得られる．

算法 7.1 (ガウス確率変数の線形結合) X_1, X_2, \dots, X_n を既知のガウス確率変数とする．これらの線形結合

$$Z = a_1X_1 + a_2X_2 + \dots + a_nX_n \quad (7.14)$$

は，平均が

$$m_Z = E[Z] = a_1m_1 + a_2m_2 + \dots + a_nm_n \quad (7.15)$$

分散が

$$\sigma_Z^2 = V[Z] = \begin{pmatrix} a_1 & a_2 & \dots & a_n \end{pmatrix} \begin{pmatrix} \sigma_1^2 & C_{12} & \dots & C_{1n} \\ C_{12} & \sigma_2^2 & \dots & C_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ C_{1n} & C_{2n} & \dots & \sigma_n^2 \end{pmatrix} \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_n \end{pmatrix} \quad (7.16)$$

のガウス確率変数となる．

7.3 共分散行列と多変数ガウス分布

ガウス確率変数 X_1, \dots, X_n を成分とする確率ベクトル $\mathbf{X} = (X_1, \dots, X_n)^T$ を, ガウス確率ベクトルという.

7.3.1 共分散行列

算法 7.1 に現れた行列を, 分散共分散行列または略して共分散行列と呼び, 次のように表記する.

$$\text{Cov}[\mathbf{X}] \quad \text{または} \quad \Sigma_{xx} := \begin{pmatrix} \sigma_1^2 & C_{12} & \cdots & C_{1n} \\ C_{12} & \sigma_2^2 & \cdots & C_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ C_{1n} & C_{2n} & \cdots & \sigma_n^2 \end{pmatrix} \quad (7.17)$$

共分散行列は, 確率ベクトルの全成分の全ての組み合わせの相関を表している. 対角成分には分散 $\sigma_i^2 = V[X_i]$ が並び, それ以外には共分散 $C_{ij} := \text{Cov}[X_i, X_j]$ が並び.

ここで, ベクトルから行列を作るテンソル積と呼ばれる算法

$$\mathbf{X}\mathbf{X}^T = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{pmatrix} (X_1, X_2, \dots, X_n) := \begin{pmatrix} X_1X_1 & X_1X_2 & \cdots & X_1X_n \\ X_2X_1 & X_2X_2 & \cdots & X_2X_n \\ \vdots & \vdots & \ddots & \vdots \\ X_nX_1 & X_nX_2 & \cdots & X_nX_n \end{pmatrix} \quad (7.18)$$

を導入すると, 共分散行列は,

$$\text{Cov}[\mathbf{X}] = \langle (\mathbf{X} - \bar{\mathbf{x}})(\mathbf{X} - \bar{\mathbf{x}})^T \rangle, \quad \bar{\mathbf{x}} := \langle \mathbf{X} \rangle \quad (7.19)$$

と表記できる. 共分散の対称性 $C_{ij} = C_{ji}$ より, $\text{Cov}[\mathbf{X}]$ は対称行列となる. すなわち, $\text{Cov}[\mathbf{X}] = \text{Cov}[\mathbf{X}]^T$.

その他, 2 つの確率ベクトル \mathbf{X}, \mathbf{Y} の相関を定量化するときには,

$$\text{Cov}[\mathbf{X}, \mathbf{Y}] \quad \text{または} \quad \Sigma_{xy} := \langle (\mathbf{X} - \mathbf{m}_X)(\mathbf{Y} - \mathbf{m}_Y)^T \rangle \quad (7.20)$$

という行列も用いる. これを, 相互共分散行列という. $\text{Cov}[\mathbf{X}, \mathbf{Y}]$ は, 一般には, 対称行列とはならない. なお, 以上の表記法においては, $\text{Cov}[\mathbf{X}, \mathbf{X}] = \text{Cov}[\mathbf{X}]$ となることに注意せよ.

演習 7.1 $n = 3$ のときの $\text{Cov}[\mathbf{X}]$ と $\text{Cov}[\mathbf{X}, \mathbf{Y}]$ の成分を書き下せ.

7.3.2 多変数ガウス分布

ガウス確率ベクトル X の共分散行列を Σ_{xx} とする．このとき， X の分布は，

$$p(\mathbf{x}) = \mathcal{N}(\mathbf{x}; \bar{\mathbf{x}}, \Sigma_{xx}) := \frac{1}{(\sqrt{2\pi})^n \sqrt{|\Sigma_{xx}|}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \bar{\mathbf{x}})^T \Sigma_{xx}^{-1} (\mathbf{x} - \bar{\mathbf{x}}) \right\} \quad (7.21)$$

に従う．これを n 変数ガウス分布という．

算法 7.2 (ガウス確率ベクトルの構成要件)

- (1) ガウス確率ベクトル X の共分散行列 Σ_{xx} は，半正定値行列になる．
- (2) 逆に，(7.21) を勝手な行列 $\Sigma_{xx} = A$ で与えたとき， A が半正定値行列ならば，対応する X は必ずガウス確率ベクトルとなる（全成分がガウス分布となる）．

▶▶ (半正定値行列) 任意のベクトル \mathbf{x} に対して， $\mathbf{x}^T A \mathbf{x} \geq 0$ となる行列 A を，半正定値行列という．この条件を破ると対角成分が負になる状況が起り，分散が非負となる確率論の計算を逸脱する．半正定値行列 A には， $A = C^T C$ となる行列 C が存在する．

7.4 ガウス確率ベクトルの線形変換

7.4.1 ガウス型確率ベクトルの線形変換

X をガウス確率ベクトルとする．定数行列 A による X の線形変換 $Y = AX$ を考える． $\langle X \rangle = \bar{\mathbf{x}}$ と Σ_{xx} を既知とする．このとき，両辺の期待値をとると，

$$\bar{\mathbf{y}} = A\bar{\mathbf{x}} \quad (7.22)$$

が得られる．また， Y の分散共分散行列は，

$$\begin{aligned} \Sigma_{yy} &:= \langle (Y - \bar{\mathbf{y}})(Y - \bar{\mathbf{y}})^T \rangle = \langle (AX - A\bar{\mathbf{x}})(AX - A\bar{\mathbf{x}})^T \rangle \\ &= A \langle (X - \bar{\mathbf{x}})(X - \bar{\mathbf{x}})^T \rangle A^T = A \Sigma_{xx} A^T \end{aligned}$$

となる． Σ_{xx} の半正定値性から， Σ_{yy} も半正定値となる．

▶▶ ガウス確率ベクトルの共分散行列 Σ_{xx} は半正定値だから， $\Sigma_{xx} = B^T B$ となる行列 B が存在する．このとき， $\Sigma_{yy} = AB^T B A^T = (B A^T)^T (B A^T)$ となる行列 $C = B A^T$ が存在するので， Σ_{yy} も半正定値である．

ゆえに， Y は Σ_{yy} を共分散行列とするガウス確率ベクトルであり，その分布は，

$$p_Y(\mathbf{y}) = \mathcal{N}(\mathbf{y}; \bar{\mathbf{y}}, \Sigma_{yy}) = \frac{1}{(\sqrt{2\pi})^n \sqrt{|\Sigma_{yy}|}} \exp \left\{ -\frac{1}{2} (\mathbf{y} - \bar{\mathbf{y}})^T \Sigma_{yy}^{-1} (\mathbf{y} - \bar{\mathbf{y}}) \right\} \quad (7.23)$$

となる．

【算法 7.3 (ガウス確率ベクトルの線形変換)】 ガウス確率ベクトル X の線形変換 $Y = AX$ は、ガウス確率ベクトルとなる．その平均は $\bar{y} = A\bar{x}$ ，共分散行列は $\Sigma_{yy} = A\Sigma_{xx}A^T$ となる．

7.4.2 共分散行列の対角化による「無相関」化

さて、線形代数によれば、 Σ_{xx} の固有ベクトルを列ベクトルとする対角化行列 $S = (u_1, u_2, u_3)$ を使うと、

$$\Sigma'_{xx} := S^{-1}\Sigma_{xx}S = \begin{pmatrix} \lambda_1 & 0 & 0 \\ 0 & \lambda_2 & 0 \\ 0 & 0 & \lambda_3 \end{pmatrix} \quad (7.24)$$

となって、 Σ_{xx} は対角化された． λ_i は固有値である．

また、共分散行列 Σ_{xx} は対角行列であるから、その固有ベクトル u_1, u_2, u_3 は互いに直交する．ゆえに、対角化行列 $S = (u_1, u_2, u_3)$ は、直交変換の性質を示す．

$$S^T = S^{-1} \quad (7.25)$$

ただし、そうなるために u_i の長さを $\|u_i\| = 1$ ($i = 1, 2, 3$) に調整しておく．

以上の対角化行列 S を使って、確率ベクトル X を Y に変換すると、

$$Y := S^{-1}X = S^T X \quad (7.26)$$

算法 7.3 で $A = S^{-1}$ とおくと、 Y の共分散行列は、 $S^{-1} = S^T$ より、

$$\Sigma_{yy} = A\Sigma_{xx}A^T = S^T\Sigma_{xx}(S^T)^T = S^{-1}\Sigma_{xx}S = \Sigma'_{xx} \quad (7.27)$$

となって対角化される．すなわち、 Σ_{yy} の非対角成分は全て 0 となる．

その効果として、変換後の Y の成分 Y_1, Y_2, Y_3 は互いに無相関

$$\text{Cov}[Y_1, Y_2] = \text{Cov}[Y_2, Y_3] = \text{Cov}[Y_1, Y_3] = 0 \quad (7.28)$$

となる．

このように、無相関という性質は、確率変数 X_1, X_2, X_3 の取り方に依存している．すなわち、元の $X = (X_1, X_2, X_3)^T$ に相関があっても、対角化行列 S による変換 $Y = S^{-1}X$ によって、無相関な組 Y_1, Y_2, Y_3 を作るができる．

▶▶ (作為的な相関?) 逆にいうと、等高線が楕円になるような密度関数の分布であれば、確率変数の座標変換 (回転) により、相関無しに見せたり、相関有りに見せたりできる？

7.4.3 2 変数ガウス分布の例

図 5.2 の 2 変数ガウス分布 $p(x_1, x_2)$ の共分散行列は、

$$\Sigma_{xx} = \begin{pmatrix} 1 & 0.8 \\ 0.8 & 1 \end{pmatrix} \quad (7.29)$$

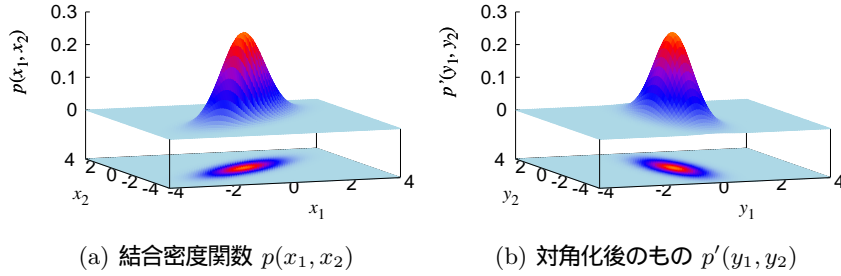


図 7.1 2 変数ガウス分布と対角化後のガウス分布 ($m_1 = m_2 = 0$, $\sigma_1 = \sigma_2 = 1$, $\rho = 0.8$)

である．固有値は 0.2, 1.8 となり，規格化した固有ベクトルより，

$$S = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 & 1 \\ 1 & 1 \end{pmatrix} \quad (7.30)$$

が得られる．このとき，新しい確率ベクトル

$$\begin{pmatrix} Y_1 \\ Y_2 \end{pmatrix} = S^T \begin{pmatrix} X_1 \\ X_2 \end{pmatrix} = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \quad (7.31)$$

の Y_1 と Y_2 は無相関となる．なぜなら，

$$\Sigma_{yy} = S^T \Sigma_{xx} S = \begin{pmatrix} 0.2 & 0 \\ 0 & 1.8 \end{pmatrix} \quad (7.32)$$

より $\text{Cov}[Y_1, Y_2] = 0$ である．

元の $p(x_1, x_2) = \mathcal{N}(\mathbf{x}; \bar{\mathbf{x}}, \Sigma_{xx})$ と，対角化後の $p'(y_1, y_2) = \mathcal{N}(\mathbf{y}; \bar{\mathbf{y}}, \Sigma_{yy})$ の比較を 図 7.1 に示す．元の (a) には x_1, x_2 の比例関係が見てとれる．これに対して，対角化後の (b) では， y_1, y_2 の比例関係が消失するよう密度関数が変換されている．

以上の対角化を応用したものに，統計学の因子分析や主成分分析などがある．

8

推定問題と直交射影

8.1 最小二乗法

確率ベクトルの $X = (X, Y)^T$ の標本 Π_n が, 図 8.1 のように得られたとする.

$$\Pi_n = \left\{ \begin{pmatrix} x_1 \\ y_1 \end{pmatrix}, \begin{pmatrix} x_2 \\ y_2 \end{pmatrix}, \dots, \begin{pmatrix} x_n \\ y_n \end{pmatrix} \right\} \quad (8.1)$$




図 8.1 2次元の試行列




図 8.2 回帰直線

8.1.1 推定問題

この試行列の傾向を学習することで, 新たに x_i が観測されたときの y_i を推定する問題を考える.

そのために, X と Y の実測値 x_i, y_i の関係について, 次のようなモデルを導入する.

$$\hat{y}_i := f(x_i) \quad (8.2)$$

$f(x)$ をモデル関数, \hat{y}_i を推定値という. また, Y の測定値を

$$y_i := f(x_i) + e_i \quad (8.3)$$

でモデル化する. e_i は誤差である.

図 8.1 の試行列には，明らかな比例関係が見てとれるので，

$$f(x) = a_0 + a_1 x \quad (8.4)$$

を採用する．これを線形回帰モデルという．そのグラフを回帰直線という．

8.1.2 最小二乗法

誤差 e_i の 2 乗の和をとる．

$$J = \sum_{i=1}^n (e_i)^2 = \sum_{i=1}^n (y_i - f(x_i))^2 \quad (8.5)$$

これを残差二乗和という．二乗和を平方和ともいう．

J を最小にするパラメータ a_0, a_1 を見付けることを，最小二乗法という． J の停留値を求めるため， a_0, a_1 による J の偏微分を 0 におくと，

$$\begin{cases} \frac{\partial J}{\partial a_0} = -2 \sum_{i=1}^n \frac{\partial f}{\partial a_0} (y_i - f(x_i)) = -2 \sum_{i=1}^n (y_i - a_0 - a_1 x_i) = 0 \\ \frac{\partial J}{\partial a_1} = -2 \sum_{i=1}^n \frac{\partial f}{\partial a_1} (y_i - f(x_i)) = -2 \sum_{i=1}^n x_i (y_i - a_0 - a_1 x_i) = 0 \end{cases} \quad (8.6)$$

両辺を $-2n$ で割ると， a_0, a_1 に関する連立方程式が得られる．

$$\begin{cases} 0 = \frac{1}{n} \sum_{i=1}^n (y_i - a_0 - a_1 x_i) = \langle Y \rangle - a_0 - a_1 \langle X \rangle \\ 0 = \frac{1}{n} \sum_{i=1}^n x_i (y_i - a_0 - a_1 x_i) = \langle XY \rangle - a_0 \langle X \rangle - a_1 \langle X^2 \rangle \end{cases} \quad (8.7)$$

$\langle \cdot \rangle$ はここでは標本平均を表す．これらを解くと，

$$\begin{aligned} \begin{pmatrix} a_0 \\ a_1 \end{pmatrix} &= \begin{pmatrix} 1 & m_X \\ m_X & \langle X^2 \rangle \end{pmatrix}^{-1} \begin{pmatrix} m_Y \\ \langle XY \rangle \end{pmatrix} \\ &= \frac{1}{\langle X^2 \rangle - m_X^2} \begin{pmatrix} \langle X^2 \rangle & -m_X \\ -m_X & 1 \end{pmatrix} \begin{pmatrix} m_Y \\ \langle XY \rangle \end{pmatrix} \\ &= \frac{1}{\sigma_X^2} \begin{pmatrix} \sigma_X^2 m_Y - C_{XY} m_X \\ C_{XY} \end{pmatrix} = \begin{pmatrix} m_Y - \rho_{XY} \frac{\sigma_Y}{\sigma_X} m_X \\ \rho_{XY} \frac{\sigma_Y}{\sigma_X} \end{pmatrix} \quad (8.8) \end{aligned}$$

となる．表 6.1 の記号を用いた．ゆえに，推定値は，

$$\hat{y}_i = f(x_i) = \rho_{XY} \frac{\sigma_Y}{\sigma_X} (x_i - m_X) + m_Y \quad (8.9)$$

となる^{a)}．この \hat{y}_i を y_i の最小二乗推定値という．図 8.2 は， Π_n 上の標本平均 $m_X, m_Y, \sigma_X, \sigma_Y, \rho_{XY}$ から求めた回帰直線である．

^{a)}久米 [1] p87 など．

8.2 確率変数の線形代数

8.2.1 結合モーメントと内積

数ベクトル $\mathbf{x} = (x_1, \dots, x_n)^T$, $\mathbf{y} = (y_1, \dots, y_n)^T$ の内積は,

$$\langle \mathbf{x}, \mathbf{y} \rangle = x_1 y_1 + \dots + x_n y_n = \mathbf{x}^T \mathbf{y} \quad (8.10)$$

のように計算した. 一方で, 内積は,

$$\langle \mathbf{x}, \mathbf{y} \rangle = \|\mathbf{x}\| \|\mathbf{y}\| \cos \theta \quad (8.11)$$

でも計算できた. $\|\cdot\|$ はノルムでベクトルの長さを表す. θ は \mathbf{x}, \mathbf{y} のなす角である. それでは, どちらが正真正銘の内積なのだろうか?

現代数学の発想は少し違う. 計算の理論であるから, 紙と鉛筆でどう計算できるかしか気にしない. それが現実の何を表そうとも, 紙の上の計算が同じなら現代数学にとっては同じものである. この観点で, 内積に特有の計算ルールが抽出された.

定義 8.1 (内積の公理) 次の法則で式変形できる積 $\langle \mathbf{x}, \mathbf{y} \rangle$ を内積という.

- (0) 実数値: $\langle \mathbf{x}, \mathbf{y} \rangle$ は常に実数値^{b)}.
- (1) 対称性: $\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle$
- (2) 分配則: $\langle a\mathbf{x}, \mathbf{y} \rangle = a \langle \mathbf{x}, \mathbf{y} \rangle$, $\langle \mathbf{x}, a\mathbf{y} \rangle = a \langle \mathbf{x}, \mathbf{y} \rangle$, $\langle \mathbf{x} + \mathbf{y}, \mathbf{z} \rangle = \langle \mathbf{x}, \mathbf{z} \rangle + \langle \mathbf{y}, \mathbf{z} \rangle$,
 $\langle \mathbf{x}, \mathbf{y} + \mathbf{z} \rangle = \langle \mathbf{x}, \mathbf{y} \rangle + \langle \mathbf{x}, \mathbf{z} \rangle$.
- (3) 正定値性: 自分自身との内積は常に $\langle \mathbf{x}, \mathbf{x} \rangle \geq 0$. 特に $\langle \mathbf{x}, \mathbf{x} \rangle = 0$ となるのは $\mathbf{x} = \mathbf{0}$ のときだけ.

このルール (公理) に従う限り, どのように式変形しても内積 $\langle \mathbf{x}, \mathbf{y} \rangle$ は内積であり続ける. 例えば, 力学的仕事は内積 $\langle \mathbf{x}, \mathbf{F} \rangle$ で表せるが, このルールを逸脱しない限り, どのように式変形しても $\langle \mathbf{x}, \mathbf{F} \rangle$ は力学的仕事であり続ける. 逆に, ルールにない式変形を行ってしまうと, 計算結果にある表式 $\langle \mathbf{x}, \mathbf{F} \rangle$ が力学的仕事を表す保証はない.

ここで, 確率変数 X, Y の 2 次結合モーメント

$$\langle XY \rangle := \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xy p(x, y) dx dy \quad (8.12)$$

の式変形は, 実は, 定義 8.1 の内積の公理に該当してしまう. 実際,

- (0) 実数値: $\langle XY \rangle$ は常に実数値.
- (1) 対称性: $\langle XY \rangle = \langle YX \rangle$
- (2) 分配則: $\langle (aX)Y \rangle = a \langle XY \rangle$, $\langle X(aY) \rangle = a \langle XY \rangle$, $\langle (X + Y)Z \rangle = \langle XZ \rangle + \langle YZ \rangle$, $\langle X(Y + Z) \rangle = \langle XY \rangle + \langle XZ \rangle$.
- (3) 正定値性: 自分自身との結合モーメント (2 次モーメント) は常に $\langle X^2 \rangle \geq 0$.

というところまで普通に該当してしまう. ただし, 最後の

^{b)} ここでは実数値バージョンの内積を示している. 複素数値バージョンでは若干ルールが変わる.

表 8.1 確率変数 $X(\cdot)$ のベクトル化 (測定器で比喻)

操作項目	文字表記	対応する測定器 $x = X(\omega), y = Y(\omega)$
(a) 等号	$X = Y$	どんな見本 ω を代入しても測定値が一致 $X(\omega) = x = y = Y(\omega)$ すること
(b) 加法	$X + Y$	$x + y$ を返す新たな測定器 “ $X + Y$ ” (\cdot)
(c) スカラ倍	λX	λx を返す新たな測定器 “ λX ” (\cdot)
(d) 零ベクトル	O	常に 0 を返す測定器 “ O ” (\cdot)
(e) 逆ベクトル	$-X$	$-x$ を返す新たな測定器 “ $-X$ ” (\cdot)

- 特に $\langle X^2 \rangle = 0$ となるのは $X = O$ のときだけ .

のところは検討を要する . ゼロ O が何だか分らない . これは次節で述べるように ,

- 任意の見本 ω について常に $O(\omega) = 0$ となる確率変数をゼロ O とする .

と定義すると辻褄が合う . 以上 , $\langle XY \rangle$ の計算は内積 $\langle X, Y \rangle$ と同じである .

8.2.2 確率変数のベクトル化

内積と同様に , 現代数学では「ベクトル」を計算ルールとして捉える .

定義 8.2 (ベクトルの公理) 次のように式変形できる x, y, \dots をベクトルという .

- (L1) $x + y = y + x$.
- (L2) $(x + y) + z = x + (y + z)$.
- (L3) どんな x に足しても , $x + \textcircled{0} = x$ となる $\textcircled{0}$ が使える . (ゼロベクトル)
- (L4) どんな x にも , 相方 $(-x)$: $x + (-x) = \textcircled{0}$ がいる . (逆ベクトル)
- (L5) $\lambda(\mu x) = (\lambda\mu)x$.
- (L6) スカラ 1 の作用は , $1x = x$.
- (L7) $(\lambda + \mu)x = \lambda x + \mu x$.
- (L8) $\lambda(x + y) = \lambda x + \lambda y$.

ベクトルの全体集合 $V := \{x, y, \dots\}$ をベクトル空間という .

この計算ルールを満足するものは , 物理的実体が何であろうとも , 紙の上の計算では区別できない (記号の違いは無視するとして) . それをベクトルと呼ぶわけだ .

具体的対象をベクトル化するには , 5 つの操作項目を定めればよい . 表 8.1 は確率変数 X をベクトル化するための操作項目である . 測定器の比喻で述べている . 確率変数 X とは , 見本 ω を入力すると測定値 $x = X(\omega)$ を返す関数


$$\text{見本 } \omega \longrightarrow \boxed{X} \longrightarrow x \text{ 測定値}$$

だった . これに該当する物理的存在とは測定器であろう .

詳細は省くが , 表 8.1 の操作は , 定義 8.2 の 8 つのルールを全て満足する . 一例としてルール (L2) の成立を図 8.3 に示す . 測定器 “ $(X + Y) + Z$ ” と測定器 “ $X + (Y + Z)$ ” は , どんな見本 ω についても測定値が一致する .

演習 8.1 定義 8.2 の他のルールについても図式化せよ .

以上 , 表 8.1 の操作を付与された確率変数 X, Y, \dots はベクトルと化す .

図 8.3 確率変数における (L2) $(X + Y) + Z = X + (Y + Z)$

8.2.3 確率変数の線形代数

というわけで、通常のベクトル x, y, \dots とその内積 $\langle x, y \rangle$ において成立することは、確率変数 X, Y, \dots とその 2 次結合モーメント $\langle XY \rangle$ の世界でもそのまま成立する（逆は一般には成立しない）。その結果、次の手順が可能になる。

- まず、ベクトル x, y, \dots とその内積 $\langle x, y \rangle$ の世界で、矢印の作図などを通してアイデアを練る。
- 得られた結果の x, y, \dots を X, Y, \dots に置き換え、 $\langle x, y \rangle$ を $\langle XY \rangle$ に置き換えると、それは確率変数の結果になっている。

言い方を変えると、確率変数 X, Y, \dots は、矢印ベクトルだと思って作図して考えてよい。そうしても、得られた結果に間違いは起らない。

ただし、 $\langle X, Y \rangle$ や $\langle X^2 \rangle$ が発散するような確率変数 X, Y をとると議論が破綻する。これを防ぐには、制約条件 $\langle X^2 \rangle < \infty$ を課せばよいことが知られている^{c)}。このような制約を課されたベクトルの集合をヒルベルト空間という。

以上の内容をまとめると、次のような設定が得られる。

定義 8.3 (確率変数の内積) $X, Y \in \mathcal{H}$ の 2 次結合モーメントを、必要に応じて、

$$\langle X, Y \rangle := \langle XY \rangle = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xy p(x, y) dx dy \quad (8.13)$$

と書く。 $\langle X, Y \rangle$ は内積となり、定義 8.1 で計算できる。

定義 8.4 (ヒルベルト空間) 2 次モーメントが有限な確率変数の集合

$$\left\{ X(\cdot) \mid \langle X^2 \rangle < \infty \right\} \quad (8.14)$$

に表 8.1 の 5 項目と、定義 8.3 の内積を付与したものを \mathcal{H} と書き、確率変数のヒルベルト空間と呼ぶ。その要素 $X, Y, \dots \in \mathcal{H}$ は、定義 8.2 のベクトル演算と、定義 8.1 に従う内積 $\langle X, Y \rangle$ で計算できる。

^{c)}この条件を、2 乗可積分という。

定義 8.5 (確率変数の直交性) 無相関 $\langle X, Y \rangle = \langle XY \rangle = 0$ であることを, $X \perp Y$ と書き, X と Y は直交するという.

定義 8.6 (確率変数のノルムと距離) 2 次モーメントの正の平方根

$$\|X\| := \sqrt{\langle X, X \rangle} = \sqrt{\langle X^2 \rangle} \quad (8.15)$$

を X のノルムという. 特に $\langle X \rangle = 0$ ときは $\|X\| = \sigma_X$ (標準偏差) となる. また,

$$d(X, Y) := \|X - Y\| \quad (8.16)$$

は確率変数 X, Y の距離, すなわち近さを表す.

矢印ベクトル x のノルム $\|x\|$ は矢印の長さを表すが, 確率変数のノルム $\|X\|$ は X のばらつきの大きさを表している. したがって, X, Y の距離 $\|X - Y\|$ は, X と Y の違いを, $X - Y$ のばらつきの大きさを測ったものである.

8.3 ベクトルの近似

近似とは, 大雑把にいうと, 不完全なモデル (模型) で本物を真似することである. 簡単のため $V = \mathbb{R}^3$ の場合を考える. まず, 近似対象のベクトル $x = (1, 2, 1)^T \in V$ を 1 つ取って固定する (本物). そのモデルを m としよう. V のなかで最良のモデルを探すと本物 x が該当してしまうので, m が動く空間 M は, 一般に $M \subset V$ とされる. さらに, M 内のベクトル演算は M からはみ出さないとする.

- $m_1, m_2 \in M \implies m_1 + m_2 \in M$
- $m \in M \implies ax \in M$

こうした M を, V の部分空間という. 以下, V の部分空間 M をモデル空間と呼ぶことにする. ここでは,

$$M := \left\{ a_0 \mathbf{u}_1 + a_1 \mathbf{u}_2 \mid a_0, a_1 \in \mathbb{R}, \mathbf{u}_1 = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \mathbf{u}_2 = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} \in \mathbb{R}^3 \right\} \quad (8.17)$$

としよう. ここで, 誤差ベクトル

$$e := x - m \quad (8.18)$$

を導入すると, 誤差の大きさは $\|e\| = \|x - m\|$ で評価できる.

以上の設定において, 誤差 $\|x - m\|$ を最小化するモデル $m = m_0$ を求めたい. m_0 を最小化ベクトルという.

x や m は 3 次元ベクトルなので, 図 8.4 のような作図で考えることができる. 制約のない x に対して, m は xy 平面 (モデル空間 M) 内に制限されている. m から x に向うベクトルの長さ $\|e\|$ が誤差の大きさを表す.




図 8.4 ベクトルの近似

図より，誤差 $\|e\|$ を最小化するベクトル $m = m_0$ は， M の法線方向 (z 軸) から照射された平行光が， M に落す x の影に一致することが分かる．これを

$$m_0 = \mathcal{P}(x|M) \quad (8.19)$$

と書き，右辺を， x の M 上への直交射影と呼ぶ．その作り方から， $(x - m_0) \perp M$ が成立する．ただし，

$$(x - m_0) \perp M \stackrel{\text{定義}}{\iff} \langle (x - m_0), m \rangle = 0 \quad \text{for } \forall m \in M \quad (8.20)$$

である．すなわち， $x - m_0$ は M 上の任意方向のベクトルと直交する．条件 (8.20) の成否を確かめるには，無限個の $\forall m \in M$ についてチェックする必要がある．それは無理なので，次の算法が編み出された．有限回のチェックで (8.20) の成否が確認できる．

算法 8.1 u_1, \dots, u_n によって張られる部分空間 M に対して，

$$(x - m_0) \perp M \stackrel{\text{必要}}{\iff} \langle (x - m_0), u_i \rangle = 0 \quad (i = 1, \dots, n) \quad (8.21)$$

▶ 証明 まず， \implies を示すため (8.20) を仮定すると， $u_i \in M$ より $\langle (x - m_0), u_i \rangle = 0$ が成立する．次に， \impliedby を示すため $\langle (x - m_0), u_i \rangle = 0$ を仮定する．任意の m は適当な係数 c_i で， $m = c_1 u_1 + \dots + c_n u_n$ と書ける．このとき，

$$\langle (x - m_0), m \rangle = c_1 \langle (x - m_0), u_1 \rangle + \dots + c_n \langle (x - m_0), u_n \rangle = 0$$

が c_i によらず成立するが，これは (8.20) の成立を意味する．

モデル空間 (8.17) を張るベクトル u_1, u_2 の線形結合で，最小化ベクトルの候補を，

$$m_0 = a_0 u_1 + a_1 u_2 \quad (8.22)$$

と表す．算法 8.1 を適用すると，

$$0 = \langle x - m_0, u_1 \rangle = \left\langle \begin{pmatrix} 1 \\ 2 \\ 1 \end{pmatrix} - \begin{pmatrix} a_0 \\ a_1 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} \right\rangle = 1 - a_0 \quad (8.23)$$

$$0 = \langle x - m_0, u_2 \rangle = \left\langle \begin{pmatrix} 1 \\ 2 \\ 1 \end{pmatrix} - \begin{pmatrix} a_0 \\ a_1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} \right\rangle = 2 - a_1 \quad (8.24)$$

より $a_0 = 1, a_1 = 2$ が判明し、次の最小化ベクトルが得られる。

$$m_0 = a_0 \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} + a_1 \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \\ 0 \end{pmatrix}$$

8.4 確率変数の推定

前節の算法を、そっくりそのまま確率変数に適用すると、確率変数の推定問題が定式化できる。8.1 節の最小二乗法では標本 Π_n 上で議論を展開したが、ここでは同じことを確率空間 (Ω, \mathcal{F}, P) 上で行う。

8.4.1 推定問題

あるランダム現象の測定量を確率変数 X, Y で表す。これらをヒルベルト空間上のベクトル $X, Y \in \mathcal{H}$ とみなす。

\mathcal{H} は一般に無限次元なので（独立なベクトルを無限個とれる）、その要素は有限個のパラメータでは表せない。そこで、有限次元の部分空間 $\mathcal{M} \subset \mathcal{H}$ をとり、 $Y \in \mathcal{H}$ を $\hat{Y} \in \mathcal{M}$ で近似することを考える。この $\hat{Y} \in \mathcal{M}$ を Y の推定値という。 \mathcal{M} は有限次元だから、その要素である \hat{Y} は有限個のパラメータで表せる。

推定誤差を評価するため、誤差ベクトル $e := Y - \hat{Y}$ のノルム $\|e\|$ を誤差の大きさとする。これを最小化する \hat{Y} について、8.3 節と全く同じ算法が使える。記号を取り替え、若干集約して再掲すると、

算法 8.2 (確率変数の推定) \mathcal{M} を確率変数 U_1, \dots, U_n で張られた部分空間とする。誤差 $\|Y - \hat{Y}\|$ を最小化する推定値 $\hat{Y} \in \mathcal{M}$ は、 $Y \in \mathcal{H}$ の \mathcal{M} 上への直交射影

$$\hat{Y} = \mathcal{P}(Y|\mathcal{M}) \quad (8.25)$$

となる。そのための必要十分条件は、 $(Y - \hat{Y}) \perp \mathcal{M}$ 、すなわち

$$\langle (Y - \hat{Y}), U_i \rangle = 0 \quad (i = 1, \dots, n) \quad (8.26)$$

で与えられる。

8.4.2 線形回帰の例題

線形回帰型のモデル空間

$$\mathcal{M} := \left\{ a_0 + a_1 X \mid a_0, a_1 \in \mathbb{R}; X \in \mathcal{H} \right\} \quad (8.27)$$

をとる．定数項を，定値関数

$$a_0(\omega) := a_0 \quad \forall \omega \in \Omega \quad (8.28)$$

とみなすと， \mathcal{M} は確率変数 $a_0, X \in \mathcal{H}$ で張られた部分空間になっている．

算法 8.2 より，本物 $Y \in \mathcal{H}$ との誤差 $\|Y - \hat{Y}\|$ を最小にする推定値 $\hat{Y} \in \mathcal{M}$ は，

$$\hat{Y} = \mathcal{P}(Y|\mathcal{M}) \subset \mathcal{M} \quad (8.29)$$

であり，そのための条件は，

$$\begin{cases} 0 = \langle (Y - \hat{Y}), a_0 \rangle = \langle (Y - \hat{Y})a_0 \rangle = a_0 \langle Y - \hat{Y} \rangle & \therefore \langle Y - \hat{Y} \rangle = 0 \\ 0 = \langle (Y - \hat{Y}), X \rangle = \langle (Y - \hat{Y})X \rangle \end{cases} \quad (8.30)$$

である． $\hat{Y} \in \mathcal{M}$ の候補を， $\hat{Y} = a_0 + a_1 X$ とおいて代入すると，

$$\begin{cases} 0 = \langle Y - \hat{Y} \rangle = \langle Y - a_0 - a_1 X \rangle = \langle Y \rangle - a_0 - a_1 \langle X \rangle \\ 0 = \langle (Y - \hat{Y})X \rangle = \langle (Y - a_0 - a_1 X)X \rangle = \langle XY \rangle - a_0 \langle X \rangle - a_1 \langle X^2 \rangle \end{cases} \quad (8.31)$$

となり，(8.7) と同じ式が得られる．ゆえに，(8.8) と同じパラメータ

$$\begin{pmatrix} a_0 \\ a_1 \end{pmatrix} = \begin{pmatrix} m_Y - \rho_{XY} \frac{\sigma_Y}{\sigma_X} m_X \\ \rho_{XY} \frac{\sigma_Y}{\sigma_X} \end{pmatrix} \quad (8.32)$$

を得る．ゆえに推定値は，

$$\hat{Y} = \hat{Y}(X) := a_0 + a_1 X = \rho_{XY} \frac{\sigma_Y}{\sigma_X} (X - m_X) + m_Y \quad (8.33)$$

のような X の関数となる．

8.4.3 条件付き期待値との関係

(8.33) の関数形は，算法 6.7 p45 で示した正規型確率変数の条件付き期待値

$$E[X_1|x_2] = \rho \frac{\sigma_1}{\sigma_2} (x_2 - m_2) + m_1 \quad (8.34)$$

と一致している．すなわち，(8.27) の線形回帰モデル \mathcal{M} 上の推定値は次の性質を示す．

算法 8.3 $X, Y \in \mathcal{H}$ がガウス型の場合，

$$\mathcal{M} := \left\{ a_0 + a_1 X \mid a_0, a_1 \in \mathbb{R}; X \in \mathcal{H} \right\}$$

をモデルとする推定値 $\hat{Y} = \mathcal{P}(Y|\mathcal{M})$ は，次の条件付き期待値に一致する．

$$\hat{Y} = \mathcal{P}(Y|\mathcal{M}) = E[Y|X] \quad (8.35)$$

演習 8.2 なんかも適当なの考えて！

もちろん，ガウス型でない場合は $E[Y|X]$ の関数形が変わるので，一般には $\mathcal{P}(Y|\mathcal{M}) \neq E[Y|X]$ である．ただし，未知の確率変数の分布は，ガウス分布と仮定することも多い．その場合は，算法 8.3 の解釈が使える．

9

確率ベクトルの推定

推定問題を確率ベクトルに拡張する .

9.1 条件付き期待値

2 つのガウス型確率ベクトル $\mathbf{Y} := (Y_1, \dots, Y_m)^T$, $\mathbf{X} := (X_1, \dots, X_n)^T$ を考える .

9.1.1 確率ベクトルの条件付き期待値

$m + n$ 個の確率変数が共存するので , その法則は $m + n$ 変数結合密度関数

$$p(\mathbf{y}, \mathbf{x}) := p(y_1, \dots, y_m, x_1, \dots, x_n) \quad (9.1)$$

で記述される . \mathbf{X} を条件とする \mathbf{Y} の条件付き密度関数

$$p(\mathbf{y}|\mathbf{x}) = \frac{p(\mathbf{y}, \mathbf{x})}{p(\mathbf{x})} := \frac{p(y_1, \dots, y_m, x_1, \dots, x_n)}{p(x_1, \dots, x_n)} \quad (9.2)$$

を導入すると , \mathbf{x} を条件とする \mathbf{Y} の条件付き期待値の関数形は ,

$$\mathbb{E}[\mathbf{Y}|\mathbf{x}] = \int_{-\infty}^{\infty} \mathbf{y} p(\mathbf{y}|\mathbf{x}) d\mathbf{y} \quad (9.3)$$

で得られる . 積分は y_1, \dots, y_m に関する m 重積分を意味するものとする .

9.1.2 多変数ガウス分布

$m + n$ 次元ベクトル $(\mathbf{X}^T, \mathbf{Y}^T)^T$ の共分散行列を次のように導入する .

$$\Sigma := \begin{pmatrix} \Sigma_{yy} & \Sigma_{yx} \\ \Sigma_{xy} & \Sigma_{xx} \end{pmatrix} := \begin{pmatrix} \langle (\mathbf{Y} - \bar{\mathbf{y}})(\mathbf{Y} - \bar{\mathbf{y}})^T \rangle & \langle (\mathbf{Y} - \bar{\mathbf{y}})(\mathbf{X} - \bar{\mathbf{x}})^T \rangle \\ \langle (\mathbf{X} - \bar{\mathbf{x}})(\mathbf{Y} - \bar{\mathbf{y}})^T \rangle & \langle (\mathbf{X} - \bar{\mathbf{x}})(\mathbf{X} - \bar{\mathbf{x}})^T \rangle \end{pmatrix} \quad (9.4)$$

\mathbf{X} の期待値を $\bar{\mathbf{x}}$ と書いた . このとき , 結合密度関数は , $m + n$ 変数ガウス分布

$$p(\mathbf{y}, \mathbf{x}) = \frac{1}{(\sqrt{2\pi})^{m+n} \sqrt{|\Sigma|}} \exp \left\{ -\frac{1}{2} \begin{pmatrix} \mathbf{y} - \bar{\mathbf{y}} \\ \mathbf{x} - \bar{\mathbf{x}} \end{pmatrix}^T \Sigma^{-1} \begin{pmatrix} \mathbf{y} - \bar{\mathbf{y}} \\ \mathbf{x} - \bar{\mathbf{x}} \end{pmatrix} \right\} \quad (9.5)$$

として与えられる .

9.1.3 ガウス確率ベクトルの条件付き期待値

算法 9.1 $m \times n$ 行列 A_0 を

$$A_0 \Sigma_{xx} = \Sigma_{yx} \quad (9.6)$$

の解とするとき, m 次元確率ベクトル (後に誤差ベクトルという)

$$E := Y - \bar{y} - A_0(X - \bar{x}) \quad (9.7)$$

は, X と独立となる. また, E の期待値と分散共分散行列は,

$$E[E] = 0, \quad \Sigma_{ee} = \Sigma_{yy} - A_0 \Sigma_{yx} = \Sigma_{yy} - A_0 \Sigma_{xx} A_0^T \quad (9.8)$$

例題 9.1 示せ.

算法 9.2 X を条件とする Y の条件付き期待値は,

$$E[Y|X] = \bar{y} + A_0(X - \bar{x}) \quad (9.9)$$

となる. ただし, A_0 は, $A_0 \Sigma_{xx} = \Sigma_{yx}$ を満足する $m \times n$ 行列である.

例題 9.2 示せ.

演習 9.1 例題 6.5 p47 を復習せよ.

9.2 確率ベクトルの推定

9.2.1 ヒルベルト空間

確率ベクトル X は成分が $X_i \in \mathcal{H}$ なので, 次のような空間を動く.

$$\mathcal{H}^n := \{ X = (X_1, X_2, \dots, X_n)^T \mid X_i \in \mathcal{H} \} \quad (9.10)$$

$X, Z \in \mathcal{H}^n$ の内積を,

$$\langle X, Z \rangle := \langle X^T Z \rangle = \langle X_1 Z_1 + \dots + X_n Z_n \rangle = \underline{\text{tr} \langle X Z^T \rangle} \quad (9.11)$$

のように定めると, これは定義 8.1 を満足する. ようするに, 確率ベクトルの内積とは, 成分を普通に内積した後に期待値をとったものである. 下線部はよく用いられる等価表現である.

▶▶ 下線部の tr は, 行列のトレース (対角成分の和) を表す. 例えば,

$$\begin{aligned} \text{tr} \langle x z^T \rangle &= \text{tr} \left\langle \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} (z_1, z_2) \right\rangle = \text{tr} \left\langle \begin{pmatrix} x_1 z_1 & x_1 z_2 \\ x_2 z_1 & x_2 z_2 \end{pmatrix} \right\rangle \quad (6.36) \text{ p47} \\ &= \text{tr} \begin{pmatrix} \langle x_1 z_1 \rangle & \langle x_1 z_2 \rangle \\ \langle x_2 z_1 \rangle & \langle x_2 z_2 \rangle \end{pmatrix} = \langle x_1 z_1 \rangle + \langle x_2 z_2 \rangle = \langle x_1 z_1 + x_2 z_2 \rangle = \langle x^T z \rangle \end{aligned}$$

▶▶ 平均操作は, $2n$ 変数密度関数 $p(x_1, \dots, x_n, z_1, \dots, z_n)$ に対してとる.

$$\begin{aligned} & \langle f(X_1, \dots, X_n, Z_1, \dots, Z_n) \rangle \\ &= \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f(x_1, \dots, z_n) p(x_1, \dots, z_n) dx_1 \dots dz_n \end{aligned} \quad (9.12)$$

ノルムは, これまでと同様に, 自分自身との内積の平方根

$$\|X\| := \sqrt{\langle X, X \rangle} = \sqrt{\langle X^T X \rangle} \quad (9.13)$$

とすればよい. ここで, $X_i \in \mathcal{H}$ より $\langle X_i^2 \rangle < \infty$ なので,

$$\|X\|^2 = \langle X_1^2 + \dots + X_n^2 \rangle = \langle X_1^2 \rangle + \dots + \langle X_n^2 \rangle < \infty \quad (9.14)$$

という制約条件が自動的に課される. ゆえに, \mathcal{H}^n もまたヒルベルト空間である.

9.2.2 推定問題

ヒルベルト空間上のベクトル $X \in \mathcal{H}^n$ は, 計算方法が普通のベクトルと同じである. これは確率変数 $X \in \mathcal{H}$ も同様だった. というわけで, 確率変数に対する算法 8.2 p63 と全く同じ算法が通用する. 若干集約して示すと,

算法 9.3 (確率ベクトルの推定) \mathcal{M} を確率ベクトル U_1, \dots, U_n で張られた部分空間とする. 誤差 $\|Y - \hat{Y}\|$ を最小化する推定値 $\hat{Y} \in \mathcal{M}$ は, $Y \in \mathcal{H}$ の \mathcal{M} 上への直交射影 $\hat{Y} = \mathcal{P}(Y|\mathcal{M})$ となる ($\iff (Y - \hat{Y}) \perp \mathcal{M}$). そのための必要十分条件は,

$$\langle (Y - \hat{Y}), U_i \rangle = 0 \quad (i = 1, \dots, p) \quad (9.15)$$

で与えられる.

9.3 確率ベクトルの線形回帰

9.3.1 確率ベクトル X からの線形回帰

$Y \in \mathcal{H}^m$ のモデルとして, 次のような線形回帰モデルを考える.

$$\mathcal{M} := \{a_0 + AX \mid a_0 \in \mathcal{H}^m, X \in \mathcal{H}^n, A \in \mathbb{R}^{m \times n}\} \quad (9.16)$$

a_0 は定数ベクトル, A は定数行列である. 定数項を, 定ベクトル値関数

$$a_0(\omega) = a_0 \quad \forall \omega \in \Omega \quad (9.17)$$

と見なすと, \mathcal{M} は確率ベクトル $a_0, AX \in \mathcal{H}^m$ で張られた, \mathcal{H}^m の部分空間となる.

算法 9.3 を $U_1 = a_0, U_2 = AX$ として使うと, 推定値 $\hat{Y} = \mathcal{P}(Y|\mathcal{M})$ について,

$$\begin{cases} 0 = \langle (Y - \hat{Y}), a_0 \rangle := \langle (Y - \hat{Y})^T a_0 \rangle = \langle (Y - \hat{Y})^T \rangle a_0 \\ 0 = \langle (Y - \hat{Y}), AX \rangle := \text{tr} \langle (Y - \hat{Y})(AX)^T \rangle = \text{tr} \left(\langle (Y - \hat{Y}) X^T \rangle A^T \right) \end{cases}$$

(9.18)

が成立するが、特殊な場合 $\mathbf{a}_0 = \mathbf{0}$, $A = O$ を除くと、上式は、

$$\begin{cases} 0 = \langle \mathbf{Y} - \hat{\mathbf{Y}} \rangle \\ O = \langle (\mathbf{Y} - \hat{\mathbf{Y}}) \mathbf{X}^T \rangle \quad (\text{ゼロ行列}) \end{cases} \quad (9.19)$$

と等価である。これに、推定値の候補 $\hat{\mathbf{Y}} = \mathbf{a}_0 + A\mathbf{X}$ を代入すると、

$$\begin{cases} 0 = \langle \mathbf{Y} - \mathbf{a}_0 - A\mathbf{X} \rangle = \bar{\mathbf{y}} - \mathbf{a}_0 - A\bar{\mathbf{x}} \\ O = \langle (\mathbf{Y} - \mathbf{a}_0 - A\mathbf{X}) \mathbf{X}^T \rangle = \langle \mathbf{Y} \mathbf{X}^T \rangle - \mathbf{a}_0 \bar{\mathbf{x}}^T - A \langle \mathbf{X} \mathbf{X}^T \rangle \end{cases} \quad (9.20)$$

\mathbf{X} の期待値を $\bar{\mathbf{x}}$ と書いた。第 1 式 $\mathbf{a}_0 = \bar{\mathbf{y}} - A\bar{\mathbf{x}}$ を第 2 式に代入すると、

$$O = \langle \mathbf{Y} \mathbf{X}^T \rangle - \bar{\mathbf{y}} \bar{\mathbf{x}}^T + A\bar{\mathbf{x}} \bar{\mathbf{x}}^T - A \langle \mathbf{X} \mathbf{X}^T \rangle \quad (9.21)$$

となる。この式は、前節の記号 $\langle \mathbf{Y} \mathbf{X}^T \rangle - \bar{\mathbf{y}} \bar{\mathbf{x}}^T = \Sigma_{yx}$, $\langle \mathbf{X} \mathbf{X}^T \rangle - \bar{\mathbf{x}} \bar{\mathbf{x}}^T = \Sigma_{xx}$ を使くと、 $\Sigma_{yx} = A\Sigma_{xx}$ と書ける。これを満足する A を用いて、推定値は、

$$\hat{\mathbf{Y}} = \mathbf{a}_0 + A\mathbf{X} = \bar{\mathbf{y}} + A(\mathbf{X} - \bar{\mathbf{x}}) \quad (9.22)$$

となる。これは、算法 9.2 の条件付き期待値 $E[\mathbf{Y}|\mathbf{X}]$ と、関数形が同じである。

以上の計算をまとめると、線形回帰に関する次のような結果が得られる。

算法 9.4 (確率ベクトルからの線形回帰) 定数ベクトル \mathbf{a}_0 と定数行列 A をパラメータとする線形回帰モデル

$$\mathcal{M} := \{ \mathbf{a}_0 + A\mathbf{X} \mid \mathbf{a}_0 \in \mathcal{H}^m, \mathbf{X} \in \mathcal{H}^n, A \in \mathbb{R}^{m \times n} \} \subset \mathcal{H}^m \quad (9.23)$$

において、誤差 $\|\mathbf{Y} - \hat{\mathbf{Y}}\|$ を最小化する推定値は、直交射影 $\hat{\mathbf{Y}} = \mathcal{P}(\mathbf{Y}|\mathcal{M}) \in \mathcal{M}$ となる。そうなるための必要十分条件は、次式で与えられる。

$$\langle \mathbf{Y} - \hat{\mathbf{Y}} \rangle = 0, \quad \langle (\mathbf{Y} - \hat{\mathbf{Y}}) \mathbf{X}^T \rangle = O \quad (\text{ゼロ行列}) \quad (9.24)$$

これより推定値 $\hat{\mathbf{Y}}$ は、

$$\Sigma_{yx} = A\Sigma_{xx} \quad (9.25)$$

を満足する行列 A を用いて、次のように書ける。

$$\hat{\mathbf{Y}} = \mathbf{a}_0 + A\mathbf{X} = \bar{\mathbf{y}} + A(\mathbf{X} - \bar{\mathbf{x}}) \quad (9.26)$$

特に \mathbf{Y}, \mathbf{X} がガウス型の場合は、推定値 $\hat{\mathbf{Y}}$ は、次の条件付き期待値に一致する。

$$\hat{\mathbf{Y}} = \mathcal{P}(\mathbf{Y}|\mathcal{M}) = E[\mathbf{Y}|\mathbf{X}] \quad (9.27)$$

9.3.2 確率ベクトル列 X_1, \dots, X_n からの線形回帰

算法 9.4 は、独立変数が複数の場合に拡張できる。

算法 9.5 (確率ベクトル列からの線形回帰) 定数ベクトル \mathbf{a}_0 と定数行列 A_1, \dots, A_k をパラメータとする線形回帰モデル

$$\mathcal{M} := \{ \mathbf{a}_0 + A_1 \mathbf{X}_1 + \dots + A_k \mathbf{X}_n \mid \mathbf{a}_0 \in \mathcal{H}^m, \mathbf{X}_i \in \mathcal{H}^n, A_i \in \mathbb{R}^{m \times n} \} \subset \mathcal{H}^m \quad (9.28)$$

において、誤差 $\|Y - \hat{Y}\|$ を最小化する推定値は、直交射影 $\hat{Y} = \mathcal{P}(Y|\mathcal{M}) \in \mathcal{M}$ となる。そうなるための必要十分条件は、次式で与えられる。

$$\langle Y - \hat{Y} \rangle = 0, \quad \langle (Y - \hat{Y}) \mathbf{X}_i^T \rangle = 0 \quad (i = 1, \dots, k) \quad (9.29)$$

これより推定値 \hat{Y} は、

$$\Sigma_{yx_i} = \sum_{j=1}^k A_j \Sigma_{x_j x_i} \quad (i = 1, \dots, k) \quad (9.30)$$

を満足する行列 A_j を用いて、次のように書ける。

$$\hat{Y} = \mathbf{a}_0 + \sum_{j=1}^k A_j \mathbf{X}_j = \bar{\mathbf{y}} + \sum_{j=1}^k A_j (\mathbf{X}_j - \bar{\mathbf{x}}_j) \quad (9.31)$$

特に Y, X がガウス型の場合は、推定値 \hat{Y} は、次の条件付き期待値に一致する。

$$\hat{Y} = \mathcal{P}(Y|\mathcal{M}) = \mathbb{E}[Y|\mathbf{X}_1, \dots, \mathbf{X}_k] \quad (9.32)$$

右辺は、 $\mathbf{X}_1, \dots, \mathbf{X}_k$ を条件とする Y の条件付き期待値である。

例題 9.3 示せ。

♣ 9 章の補足

A9 解答例

A9.1 例題 9.1 の解答例

まず, $\langle E \rangle = \langle Y \rangle - \bar{y} - A_0(\langle X \rangle - \bar{x}) = \mathbf{0}$. また,

$$\begin{aligned} \langle EX^T \rangle &= \langle (Y - \bar{y})X^T \rangle - A_0 \langle (X - \bar{x})X^T \rangle \\ &= \langle (Y - \bar{y})(X - \bar{x})^T \rangle - A_0 \langle (X - \bar{x})(X - \bar{x})^T \rangle \\ &\quad + \langle Y - \bar{y} \rangle \bar{x}^T - A_0 \langle X - \bar{x} \rangle \bar{x}^T \\ &= \Sigma_{yx} - A_0 \Sigma_{xx} = \mathbf{0} \end{aligned}$$

より, E, X は無相関であり, ガウス性より独立でもある. さらに,

$$\begin{aligned} \Sigma_{ee} &:= \left\langle \left(Y - \bar{y} - A_0(X - \bar{x}) \right) \left((Y - \bar{y})^T - (X - \bar{x})^T A_0^T \right) \right\rangle \\ &= \left\langle (Y - \bar{y})(Y - \bar{y})^T \right\rangle + A_0 \left\langle (X - \bar{x})(X - \bar{x})^T \right\rangle A_0^T \\ &\quad - A_0 \left\langle (X - \bar{x})(Y - \bar{y})^T \right\rangle - \left\langle (Y - \bar{y})(X - \bar{x})^T \right\rangle A_0^T \\ &= \Sigma_{yy} + \underline{A_0 \Sigma_{xx} A_0^T - A_0 \Sigma_{xy} - \Sigma_{yx} A_0^T} = \Sigma_{yy} - A_0 \Sigma_{xx} A_0^T \end{aligned}$$

$\therefore \Sigma_{xy} = \Sigma_{yx}^T = \Sigma_{xx} A_0^T$ より, 下線部 $= 0$.

A9.2 例題 9.2 の解答例

E と X は独立だから, $E[E|X] = E[E]$ となるが, 算法 9.1 より $E[E] = \mathbf{0}$ である. これと算法 6.8 p45 より,

$$\begin{aligned} \mathbf{0} &= E[E|x] = E[Y - \bar{y} - A_0(X - \bar{x})|x] = E[Y|x] - \bar{y} - A_0(E[X|x] - \bar{x}) \\ &= E[Y|x] - \bar{y} - A_0(x - \bar{x}) \quad \therefore E[Y|x] = \bar{y} + A_0(x - \bar{x}) \end{aligned}$$

となって, $E[Y|X]$ の関数形を得る.

A9.3 例題 9.3 の解答例

\mathcal{M} は $a_0, A_1 X_1, \dots, A_k X_k$ によって張られるので, 算法 9.3 より,

$$\begin{cases} 0 = \langle (Y - \hat{Y}), a_0 \rangle = \langle (Y - \hat{Y})^T \rangle a_0 \\ 0 = \langle (Y - \hat{Y}), A_i X_i \rangle = \text{tr} \left(\langle (Y - \hat{Y}), X_i^T \rangle A_i^T \right) \quad (i = 1, \dots, k) \end{cases}$$

となるから, 特別な a_0, A_i を除いて, (9.29) が成立する. (9.29) に推定値の候補 $\hat{Y} := a_0 + \sum_{j=1}^k A_j X_j$ を代入すると, 第 1 式より $a_0 = \bar{y} - \sum_{j=1}^k A_j \bar{x}_j$ を得る. これ

を第 2 式に代入すると ,

$$\begin{aligned}
 O &= \left\langle \mathbf{Y} \mathbf{X}_i^T \right\rangle - \mathbf{a}_0 \bar{\mathbf{x}}_i - \sum_{j=1}^k A_j \left\langle \mathbf{X}_j \mathbf{X}_i^T \right\rangle \\
 &= \left\langle \mathbf{Y} \mathbf{X}_i^T \right\rangle - \bar{\mathbf{y}} \bar{\mathbf{x}}_i - \sum_{j=1}^k A_j \left(\left\langle \mathbf{X}_j \mathbf{X}_i^T \right\rangle - \bar{\mathbf{x}}_j \bar{\mathbf{x}}_i \right) = \Sigma_{y x_i} - \sum_{j=1}^k A_j \Sigma_{x_j x_i}
 \end{aligned}$$

となって (9.30) を得る . (9.31) は \mathbf{a}_0 を代入すれば明らか . 最後の証明は略す .

10

確率過程

10.1 確率過程

確率変数 X とは、見本 $\omega \in \Omega$ の関数 $x = X(\omega)$ の関数であった。その関数形が時間 t とともに変化するものを $X(t, \omega)$ または $X_t(\omega)$ と書き、確率過程という。

特に、時間 t が実数のものを連続時間確率過程と呼び、整数のものを離散時間確率過程と呼ぶ。以下で扱う確率過程は、離散時間確率過程とする。

10.1.1 確率過程の記述

離散時間確率過程 (以下、確率過程) を考える。

$$X_0, X_1, \dots, X_n, \dots \quad (10.1)$$

時刻 $t = 0$ では、1 個の確率変数 X_0 しかないのです、その性質は密度関数

$$p(x_0) \quad (10.2)$$

で表せる。時刻 $t = 1$ では、2 個の確率変数 X_0, X_1 が共存するので、その確率的な性質は 2 変数結合密度関数

$$p(x_1, x_0) \quad (10.3)$$

で表される。今後の議論の都合上、未来を左に書いた。

さらに時刻を進めると、順次 $p(x_2, x_1, x_0), p(x_3, x_2, x_1, x_0), \dots$ が必要になり、時刻 $t = n$ までの性質を表すには、 $n + 1$ 変数結合密度関数

$$p(x_n, x_{n-1}, \dots, x_1, x_0) \quad (10.4)$$

が必要になる。

応用の場面において、 n は 10 や 20 では済まない。そこで理論上の枠組みとして、 $n \rightarrow \infty$ を想定すると、 ∞ 変数結合密度関数が必要になってしまう。これを具体的に扱うことは難しい。

10.1.2 白色雑音

そこで、最も単純な確率過程として、 X_t ($t = 0, 1, \dots, n$) は互いに独立だと仮定する。このとき、結合密度関数は、

$$p(x_n, x_{n-1}, \dots, x_1, x_0) = p(x_n)p(x_{n-1}) \cdots p(x_1)p(x_0) \quad (10.5)$$

のように、 $p(x_t)$ ($t = 0, 1, \dots, n$) の積になる。こうなる確率過程を白色（はくしょく）雑音とよび、これを本書では W_t と書く。

白色雑音の性質は、各時刻の密度関数 $p(x_t)$ で完全に記述される。また、独立なら無相関であるから、異なる時刻の W_t, W_s は無相関である。

算法 10.1 (白色雑音の性質) 白色雑音 W_t は次の性質をもつ。

$$\text{Cov}[W_t, W_s] = \langle (W_t - \bar{w}_t)(W_s - \bar{w}_s) \rangle = V[W_t] \delta_{ts} \quad (10.6)$$

$V[W_t]$ は W_t の分散であり、 δ_{ts} はクロネッカーのデルタである。

$$\delta_{ts} := \begin{cases} 1 & (t = s) \\ 0 & (t \neq s) \end{cases} \quad (10.7)$$

この性質を、白色雑音のデルタ相関という。

10.1.3 マルコフ過程

2 番目に単純な確率過程として、 X_t は X_{t-1} にだけ依存すると仮定する。この性質は、5.4.4 節の条件付密度関数を用いると、次のように表わせる。

$$p(x_n | x_{n-1}, \dots, x_0) = p(x_n | x_{n-1}) \quad (10.8)$$

順次、適用すると、

$$\begin{aligned} p(x_n, x_{n-1}, \dots, x_0) &= p(x_n | x_{n-1}, \dots, x_0) p(x_{n-1}, x_{n-2}, \dots, x_0) \\ &= p(x_n | x_{n-1}) p(x_{n-1}, x_{n-2}, \dots, x_0) \\ &= p(x_n | x_{n-1}) p(x_{n-1} | x_{n-2}) p(x_{n-2}, x_{n-3}, \dots, x_0) \\ &= p(x_n | x_{n-1}) p(x_{n-1} | x_{n-2}) \cdots p(x_1 | x_0) p(x_0) \end{aligned} \quad (10.9)$$

となる。こうなる確率過程をマルコフ過程という。各項の条件付き密度関数

$$p(x_t | x_{t-1}) \quad (t = 1, \dots, n) \quad (10.10)$$

は、状態を単位時間だけ進める役割を演じることから、推移密度関数と呼ばれる。

マルコフ過程の性質は、初期密度関数 $p(x_0)$ と、推移密度関数 $p(x_t | x_{t-1})$ によって完全に記述される。

【算法 10.2 (マルコフ過程の性質)】 マルコフ過程 X_t の推移密度関数について、次の公式が成立する。

$$p(x_t|x_s) = \int_{-\infty}^{\infty} p(x_t|x_m) p(x_m|x_s) dx_m \quad (10.11)$$

これをチャップマン–コルモゴロフ方程式という。

10.1.4 ガウス過程

各項 X_0, X_1, \dots が全てガウス型であるような確率過程 X_t を、ガウス過程という。特に、ガウス型の白色雑音をガウス白色雑音と呼び、ガウス型のマルコフ過程をガウス–マルコフ過程という。

10.1.5 ベクトル値の確率過程

時間とともに変化する確率ベクトル X_t を、ベクトル値過程という。成分の性質に応じて、白色型、マルコフ型、ガウス型などの接頭語がつく。

【算法 10.3 (ガウス型ベクトル値過程の性質)】 X_t をガウス型ベクトル値過程とする。各項の線形変換の和

$$Z = A_0 X_0 + A_1 X_1 + \dots + A_t X_t \quad (10.12)$$

は、ガウス確率ベクトルとなる。

▶ 証明 算法 7.3 p54 より、各項 $Y_i = A_i X_i$ はガウス確率ベクトルである。ゆえに、その総和 Z の各成分はガウス確率変数の和となるので、(7.10) p50 より、 Z の成分は全てガウス確率変数となる。そのようなベクトル Z をガウス確率ベクトルと呼んだ。

10.2 確率的な状態方程式

10.2.1 決定論的な状態方程式

システムの状態をベクトル $x(t)$ で表し、その時間発展を差分方程式

$$x(t+1) = F_t x(t), \quad x(0) = x_0, \quad (t = 0, 1, 2, \dots) \quad (10.13)$$

でモデル化することがよく行われる。 F_t はモデルの構造を表す行列で、ここでは時変(時間 t に依存する)とした。 x_0 は初期値で、時刻 $t = 0$ の状態を表す。問題に即した F_t の成分をとることで、現実の様々な状態量の時間発展を模倣できる。

(10.13) の解は、逐次代入 $x(1) = F(0)x_0$, $x(2) = F(1)x(1)$ によって求まる。

$$x(t) = \Phi(t, 0)x_0, \quad \Phi(t, 0) := F(t-1)F(t-2)\dots F(1)F(0) \quad (10.14)$$

このように、決定論的なモデルにおいては、モデル (10.13) から状態 $x(t)$ が直ちに定まる。なお、行列 $\Phi(t, 0) := F(t-1)F(t-2)\dots F(1)F(0)$ を推移行列という。

10.2.2 ランダムな外乱を受ける場合

次に, (10.13) がランダムな外乱 $w(t)$ を受ける場合を考える.

$$x(t+1) = F_t x(t) + G_t w(t), \quad x(0) = x_0, \quad (t = 0, 1, 2, \dots) \quad (10.15)$$

G_t は外乱の入り方を表す行列である. さて, この場合, 外乱 $w(t)$ はランダムなので試行ごとに变化する. したがって, 状態量 $x(t)$ も試行ごとに变化してしまう.

10.2.3 確率的な状態方程式

そこで, 状態と外乱を確率過程 x_t, w_t とするモデルを導入する. なお, 今後は行列とベクトルを区別するため, 確率ベクトルを小文字で表す.

$$x_{t+1} = F_t x_t + G_t w_t, \quad (t = 0, 1, 2, \dots) \quad (10.16)$$

初期値 x_0 は, 所与の確率ベクトルとする. 以下, これを単に状態方程式と呼ぶことにする. 各ベクトルと行列の次元と名称を下表に示す.

x_t	状態量	n 次元確率ベクトル
w_t	システム雑音	r 次元確率ベクトル
F_t	状態推移行列	$n \times n$ 定数行列
G_t	駆動行列	$n \times r$ 定数行列

このシステムについて次の仮定をおく.

- (a) 初期値に対する仮定 初期状態 x_0 はガウス確率ベクトルで,

$$\langle x_0 \rangle := \bar{x}_0, \quad \text{Cov}[x_0] = \langle (x_0 - \bar{x}_0)(x_0 - \bar{x}_0)^T \rangle := \Sigma_0 \quad (10.17)$$

とする.

- (b) 雑音に対する仮定 w_t は r 次元ガウス白色雑音で, 全ての時刻 t で, 平均

$$\langle w_t \rangle = 0 \quad (10.18)$$

とする. 白色雑音なので, 異なる時刻の w_t, w_s は無相関となる.

$$\langle w_t w_s^T \rangle = Q_t \delta_{ts} \quad (10.19)$$

Q_t は時刻 t の w_t の共分散行列とする (同時刻の成分間の相関は否定しない). δ_{ts} はクロネッカーのデルタである.

また, どの時刻 t の雑音 w_t も, 初期状態 x_0 と独立とする. このとき, $\langle w_t \rangle = 0$ より

$$\langle x_0 w_t^T \rangle \stackrel{\text{独立}}{=} \langle x_0 \rangle \langle w_t^T \rangle = \bar{x}_0 0^T = 0 \quad \forall t \quad (10.20)$$

すなわち, $x_0 \perp w_t$ が成立する.

10.3 期待値と共分散行列の推移則

10.3.1 確率ベクトルの推移

状態方程式 (10.16) の時刻 $s < t$ からの推移を追うと,

$$\begin{aligned}
 \mathbf{x}_{s+1} &= F_s \mathbf{x}_s + G_s \mathbf{w}_s \\
 \mathbf{x}_{s+2} &= F_{s+1} \mathbf{x}_{s+1} + G_{s+1} \mathbf{w}_{s+1} \\
 &= F_{s+1} F_s \mathbf{x}_s + F_{s+1} G_s \mathbf{w}_s + G_{s+1} \mathbf{w}_{s+1} \\
 \mathbf{x}_{s+3} &= F_{s+2} \mathbf{x}_{s+2} + G_{s+2} \mathbf{w}_{s+2} \\
 &= F_{s+2} F_{s+1} F_s \mathbf{x}_s + F_{s+2} F_{s+1} G_s \mathbf{w}_s + F_{s+2} G_{s+1} \mathbf{w}_{s+1} + G_{s+2} \mathbf{w}_{s+2}
 \end{aligned}$$

となる．ここで， F_t の作用の累積を表す推移行列

$$\Phi(t, s) := \begin{cases} F_{t-1} F_{t-2} \cdots F_s & (s < t) \\ I & (s = t) \end{cases} \quad \text{単位行列} \quad (10.21)$$

を導入すると，解は次のように表示できる．

$$\mathbf{x}_t = \Phi(t, s) \mathbf{x}_s + \sum_{k=s}^{t-1} \Phi(t, k+1) G_k \mathbf{w}_k \quad (10.22)$$

10.3.2 状態と雑音の独立性

ベクトル $\mathbf{v}_1, \dots, \mathbf{v}_n$ の線形結合の全体を $\text{Span}\{\mathbf{v}_1, \dots, \mathbf{v}_n\}$ と書く ($\mathbf{v}_1, \dots, \mathbf{v}_n$ で張られる空間のこと)．まず，(10.22) に $s = 0$ を代入すると，

$$\mathbf{x}_t = \Phi(t, 0) \mathbf{x}_0 + \sum_{k=0}^{t-1} \Phi(t, k+1) G_k \mathbf{w}_k \quad (10.23)$$

となるので，解は，

$$\mathbf{x}_t \in \text{Span}\{\mathbf{x}_0, G_0 \mathbf{w}_0, \dots, G_{t-1} \mathbf{w}_{t-1}\} \quad (10.24)$$

となることが分かる． $\mathbf{x}_0, \mathbf{w}_0, \dots, \mathbf{w}_{t-1}$ は \mathbf{w}_t と独立だと仮定したから，それらの線形変換 $\mathbf{x}_0, G_0 \mathbf{w}_0, \dots, G_{t-1} \mathbf{w}_{t-1}$ も \mathbf{w}_t と独立である．ゆえに，それらの線形結合である \mathbf{x}_t は， \mathbf{w}_t と独立となる．すなわち， \mathbf{x}_t は同時刻以降の \mathbf{w}_s ($t \leq s$) と独立である．このとき，

$$\left\langle \mathbf{x}_t \mathbf{w}_s^T \right\rangle \stackrel{\text{独立}}{=} \langle \mathbf{x}_t \rangle \left\langle \mathbf{w}_s^T \right\rangle = \langle \mathbf{x}_t \rangle \mathbf{0}^T = \mathbf{0} \quad (t \leq s) \quad (10.25)$$

すなわち， $\mathbf{x}_t \perp \mathbf{w}_s$ ($t \leq s$) が成立する．

同様に， $\mathbf{x}_0, \mathbf{w}_0, \dots, \mathbf{w}_{t-1}$ はガウス確率ベクトルと仮定したから，その線形変換の

和 x_t はガウス確率ベクトルである．すなわち， x_t はガウス過程である．

最後に，状態方程式，

$$x_t = F_{t-1}x_{t-1} + G_{t-1}w_{t-1} \in \text{Span}\{x_{t-1}, w_{t-1}\}$$

より， x_t は 1 時刻前の x_{t-1} ， w_{t-1} のみに従属するので， x_t はマルコフ過程である．

以上をまとめると，次の結果が得られる．

■ 算法 10.4 x_t は， w_s ($t \leq s$) と独立なガウス-マルコフ過程である．

10.3.3 期待値と共分散行列の推移

x_t はガウス過程であることが分かったので，各時刻の x_t の性質は，期待値と共分散行列によって完全に記述される．

$$\langle x_t \rangle = \bar{x}_t, \quad \Sigma_t = \langle (x_t - \bar{x}_t)(x_t - \bar{x}_t)^T \rangle \quad (10.26)$$

さらに， x_t はマルコフ過程なので， \bar{x}_t や Σ_t は 1 時刻前の情報だけに依存するはずである．

まず期待値の推移だが，状態方程式 (10.16) の両辺の期待値をとると，

$$\langle x_{t+1} \rangle = F_t \langle x_t \rangle + G_t \langle w_t \rangle = F_t \langle x_t \rangle + G_t \mathbf{0} \quad (10.27)$$

となるので，次の結果が得られる．

$$\bar{x}_{t+1} = F_t \bar{x}_t \quad (10.28)$$

続いて， Σ_{t+1} を Σ_t で書き下す方向で変形を進める．まず，

$$\Sigma_{t+1} := \langle (x_{t+1} - \bar{x}_{t+1})(x_{t+1} - \bar{x}_{t+1})^T \rangle = \langle x_{t+1} x_{t+1}^T \rangle - \bar{x}_{t+1} \bar{x}_{t+1}^T \quad (10.29)$$

となるが，右辺第 2 項は，

$$\bar{x}_{t+1} \bar{x}_{t+1}^T = F_t \bar{x}_t \bar{x}_t^T F_t^T \quad (10.30)$$

となる．右辺第 1 項は，状態方程式 (10.16) を代入すると，

$$\begin{aligned} \langle x_{t+1} x_{t+1}^T \rangle &= \langle (F_t x_t + G_t w_t)(F_t x_t + G_t w_t)^T \rangle = F_t \langle x_t x_t^T \rangle F_t^T \\ &\quad + F_t \langle x_t w_t^T \rangle G_t^T + G_t \langle w_t x_t^T \rangle F_t^T + G_t \langle w_t w_t^T \rangle G_t^T \end{aligned} \quad (10.31)$$

となる． x_t と w_t の共分散行列は，状態方程式の解 (10.22) を使って， x_t を x_0 まです遡及すると消去できる．実際，(10.20) と， w_t のデルタ相関 (10.19) より，

$$\langle x_t w_t^T \rangle = \left\langle \left(\Phi(t, 0) x_0 + \sum_{k=0}^{t-1} \Phi(t, k+1) G_k w_k \right) w_t^T \right\rangle$$

$$= \underbrace{\Phi(t, 0) \langle \mathbf{x}_0 \mathbf{w}_t^T \rangle}_{=O} + \sum_{k=0}^{t-1} \underbrace{\Phi(t, k+1) G_k \langle \mathbf{w}_k \mathbf{w}_t^T \rangle}_{=O} = O \quad (10.32)$$

を得る．これを転置すると $\langle \mathbf{w}_t \mathbf{x}_t^T \rangle = O$ も示される．以上を (10.29) に代入すると，

$$\begin{aligned} \Sigma_{t+1} &= F_t \langle \mathbf{x}_t \mathbf{x}_t^T \rangle F_t^T - F_t \bar{\mathbf{x}}_t \bar{\mathbf{x}}_t^T F_t^T + G_t \langle \mathbf{w}_t \mathbf{w}_t^T \rangle G_t^T \\ &= F_t \langle \mathbf{x}_t \mathbf{x}_t^T - \bar{\mathbf{x}}_t \bar{\mathbf{x}}_t^T \rangle F_t^T + G_t \langle \mathbf{w}_t \mathbf{w}_t^T \rangle G_t^T \\ &= F_t \Sigma_t F_t^T + G_t Q_t G_t^T \end{aligned}$$

が得られる．以上をまとめると，

【 算法 10.5 (期待値と共分散行列の推移則) (10.16) の状態量 \mathbf{x}_t の期待値と共分散行列

$$\bar{\mathbf{x}}_t := \langle \mathbf{x}_t \rangle, \quad \Sigma_t := \langle (\mathbf{x}_t - \bar{\mathbf{x}}_t)(\mathbf{x}_t - \bar{\mathbf{x}}_t)^T \rangle \quad (10.33)$$

は，次の推移則で時間発展する．

$$\bar{\mathbf{x}}_{t+1} = F_t \bar{\mathbf{x}}_t, \quad (10.34)$$

$$\Sigma_{t+1} = F_t \Sigma_t F_t^T + G_t Q_t G_t^T \quad (t = 0, 1, 2, \dots) \quad (10.35)$$

演習 10.1 $Q_t = O$ のとき，どうなるか考察せよ．

10.4 モンテカルロ法による数値例

$n = 2$ の数値例を示す．行列は全て定行列とし，その成分と初期値を次のようにとる．

$$F = \begin{pmatrix} 0 & 0.5 \\ -0.8 & 0 \end{pmatrix}, \quad G = \begin{pmatrix} 0.1 \\ 0.1 \end{pmatrix}, \quad Q = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \quad \mathbf{x}_0 = \begin{pmatrix} 0.1 \\ 0 \end{pmatrix} \quad (10.36)$$

10.4.1 見本路の数値計算

確率過程 $X(t, \omega)$ において，見本 ω を特定の $\bar{\omega}$ に固定すると，対応する時間の関数 $X(t, \bar{\omega})$ がピックアップされる．これを，確率過程の見本路 (sample path) という．

見本路を数値的に求めるには，状態方程式への逐次代入

$$\mathbf{x}_1 = F\mathbf{x}_0 + G\mathbf{w}_0, \quad \mathbf{x}_2 = F\mathbf{x}_1 + G\mathbf{w}_1, \quad \mathbf{x}_3 = F\mathbf{x}_2 + G\mathbf{w}_2, \quad \dots$$

により，初期値 \mathbf{x}_0 からの時間発展 \mathbf{x}_t を求めればよい．その際，ガウス白色雑音

$$\mathbf{w}_t = \begin{pmatrix} w_t^1 \\ w_t^2 \end{pmatrix} \quad (10.37)$$

の各成分 w_t^1, w_t^2 に，順次，正規乱数列 N_0, N_1, N_2, \dots を代入する．正規乱数列の

部分列もまた正規乱数列なので，代入の順序は任意でかまわない．ようにするに，

$$\begin{aligned}\omega = 1 : & \begin{cases} w_0^1 = N_0, & w_1^1 = N_1, & w_2^1 = N_2, & \cdots, & w_{15}^1 = N_{15} \\ w_0^2 = N_{16}, & w_1^2 = N_{17}, & w_2^2 = N_{18}, & \cdots, & w_{15}^2 = N_{31} \end{cases} \\ \omega = 2 : & \begin{cases} w_0^1 = N_{32}, & w_1^1 = N_{33}, & w_2^1 = N_{34}, & \cdots, & w_{15}^1 = N_{47} \\ w_0^2 = N_{48}, & w_1^2 = N_{49}, & w_2^2 = N_{50}, & \cdots, & w_{15}^2 = N_{53} \end{cases} \\ & \vdots\end{aligned}$$

としてもよいし，

$$\begin{aligned}\omega = 1 : & \begin{cases} w_0^1 = N_0, & w_1^1 = N_2, & w_2^1 = N_4, & \cdots, & w_{15}^1 = N_{30} \\ w_0^2 = N_1, & w_1^2 = N_3, & w_2^2 = N_5, & \cdots, & w_{15}^2 = N_{31} \end{cases} \\ \omega = 2 : & \begin{cases} w_0^1 = N_{32}, & w_1^1 = N_{34}, & w_2^1 = N_{36}, & \cdots, & w_{15}^1 = N_{52} \\ w_0^2 = N_{33}, & w_1^2 = N_{35}, & w_2^2 = N_{37}, & \cdots, & w_{15}^2 = N_{53} \end{cases} \\ & \vdots\end{aligned}$$

としてもよい．他の代入順でも，代入ごとに乱数が更新されていれば問題ない．

もちろん，代入順を代えると，ガウス白色雑音の成分 w_t^1, w_t^2 の時間波形は変化する（分布は同じ），得られる見本路の波形は変化する．

このようにして求めた見本路の数値例を図 10.1 に示す．見本数は 50 とした．




図 10.1 見本路の時間発展

10.4.2 平均値と共分散行列の数値計算 — モンテカルロ法

図 10.1 のように生成した複数の見本路の値を，各時刻 t において平均したものが，図 10.2 の最上段の○印である．同様に求めた分散行列の成分を 2 段目以降に示す．

このような，数値計算で生成した複数回の試行結果から，統計量を求める方法をモンテカルロ法 (Monte-Carlo method) という．

モンテカルロ法で求める平均値や共分散は標本平均であるから，乱数列 N_i の与え

方によって計算結果は変化する．この変化を小さくするには，算法 6.3 p42 の中心極限定理で学んだように，見本数を十分大きくとる必要がある．この数値例では，見本数を 5×10^4 としており，相応の計算時間を要した．

10.4.3 平均値と共分散行列 — 算法 10.5

これに対して，算法 10.5 の差分方程式を 1 回だけ解いて求めた解析解を，図 10.2 の実線で示す．この結果は解析解であるため，中心極限定理のような計算結果の不確定性は生じない．

このように，確率解析による算法 10.5 を用いると，モンテカルロ法より高精度な結果を，ごく短時間の計算で (1 回の計算で) 得ることができる．

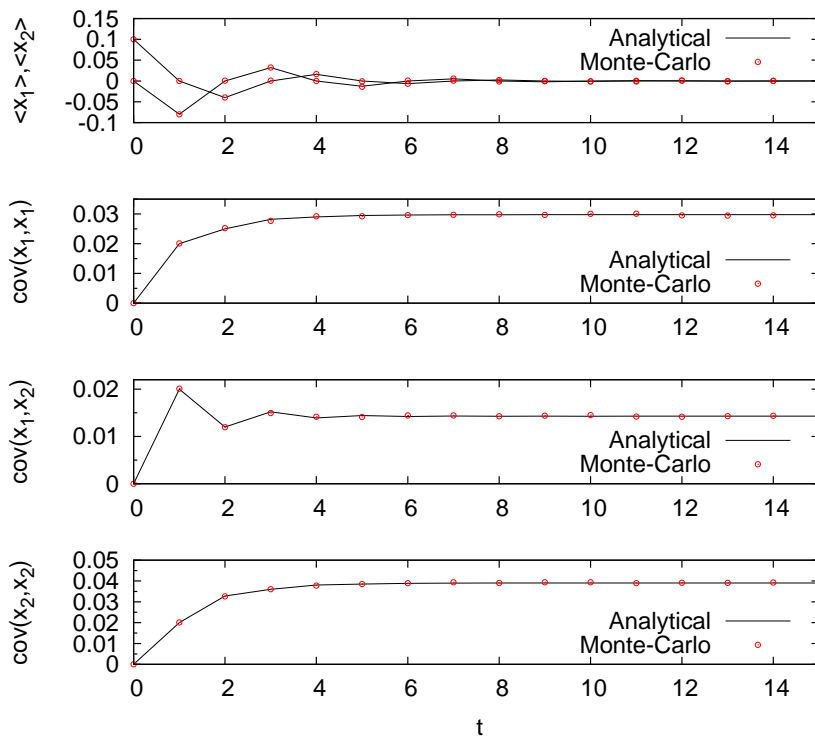


図 10.2 平均値と共分散行列の時間発展

11

カルマンフィルタ

11.1 線形確率システム

状態方程式 (10.16) p76 に，観測方程式を連立した

$$\begin{cases} \mathbf{x}_{t+1} = F_t \mathbf{x}_t + G_t \mathbf{w}_t & (\text{状態方程式}) \\ \mathbf{y}_t = H_t \mathbf{x}_t + \mathbf{v}_t & (\text{観測方程式}) \end{cases} \quad (t = 0, 1, 2, \dots) \quad (11.1)$$

を線形確率システムという．

\mathbf{x}_t	状態量	n 次元確率ベクトル
\mathbf{y}_t	観測量	p 次元確率ベクトル
\mathbf{w}_t	システム雑音	r 次元確率ベクトル
\mathbf{v}_t	観測雑音	p 次元確率ベクトル
F_t	状態推移行列	$n \times n$ 定数行列
G_t	駆動行列	$n \times r$ 定数行列
H_t	観測行列	$p \times n$ 定数行列

(a) 観測雑音に対する仮定 10.2.3 節の仮定に加えて，次の仮定をおく．

\mathbf{v}_t は p 次元ガウス白色雑音で，全ての時刻 t で，平均

$$\langle \mathbf{v}_t \rangle = \mathbf{0} \quad (11.2)$$

とする．白色雑音なので，異なる時刻の $\mathbf{v}_t, \mathbf{v}_s$ は無相関となる．

$$\langle \mathbf{v}_t \mathbf{v}_s^T \rangle = R_t \delta_{ts} \quad (11.3)$$

R_t は時刻 t の \mathbf{v}_t の共分散行列とする（同時刻の成分間の相関は否定しない）． δ_{ts} はクロネッカーのデルタである．

また，どの時刻 t の雑音 \mathbf{v}_t も初期状態 \mathbf{x}_0 と独立とする．このとき $\langle \mathbf{v}_t \rangle = \mathbf{0}$ より

$$\langle \mathbf{x}_0 \mathbf{v}_t^T \rangle \stackrel{\text{独立}}{=} \langle \mathbf{x}_0 \rangle \langle \mathbf{v}_t^T \rangle = \bar{\mathbf{x}}_0 \mathbf{0}^T = \mathbf{0} \quad \forall t \quad (11.4)$$

すなわち， $\mathbf{x}_0 \perp \mathbf{v}_t$ が成立する．これと，状態方程式の形から， \mathbf{x}_t は同時刻以降の

v_s と独立であることが分かる．これより，

$$\langle x_t v_s^T \rangle = O \quad (t \leq s) \quad (11.5)$$

すなわち， $x_t \perp v_s$ ($t \leq s$) が成立する．

(b) 観測量と雑音の独立性 その結果，以下が帰結される．観測方程式 $y_t = H_t x_t + v_t$ より，観測量 y_t は未来の観測雑音 v_s ($t < s$) と独立である．このとき，

$$\langle y_t v_s^T \rangle \stackrel{\text{独立}}{=} \langle y_t \rangle \langle v_s^T \rangle = \langle x_t \rangle 0^T = O \quad (t < s) \quad (11.6)$$

すなわち， $y_t \perp v_s$ ($t < s$) が成立する．さらに，(10.25) p77 の $x_t \perp w_s$ ($t \leq s$) より，

$$\langle y_t w_s^T \rangle = O \quad (t \leq s) \quad (11.7)$$

すなわち， $y_t \perp w_s$ ($t \leq s$) が成立する．

11.2 状態推定問題

状態量 x_s は測定できず，時刻 t までの観測量 y_0, \dots, y_t のみが測定可能とする．この状況で，測定可能な y_0, \dots, y_t から状態の推定値 \hat{x}_s を得る問題を考える．

そのために，状態量 $x_s \in \mathcal{H}^n$ のモデル空間を，時刻 t までの観測量 $y_0, y_1, \dots, y_t \in \mathcal{H}^p$ で生成する．一般に $p \leq n$ とする．

$$Y^t := \left\{ a + \sum_{i=1}^t A_i y_i \mid a \in \mathbb{R}^n, A_i \in \mathbb{R}^{n \times p} \right\} \quad (11.8)$$

これをデータ空間と呼ぼう．

推定誤差 $\|x_s - \hat{x}_s\|$ を最小化する推定値 $\hat{x}_s \in Y^t$ は， x_s の Y^t 上への直交射影

$$\hat{x}_s = \mathcal{P}(x_s | Y^t) \stackrel{\text{定義}}{\iff} x_s - \hat{x}_s \perp Y^t \quad (11.9)$$

で与えられた．また， x_s, y_t はともにガウス型と仮定したから，推定値は， y_0, \dots, y_t を条件とする x_s の条件付き期待値に一致した．

$$\hat{x}_s = \mathcal{P}(x_s | Y^t) = \mathbb{E}[x_s | y_0, \dots, y_t] \quad (11.10)$$

以下， $\mathbb{E}[x_s | y_0, \dots, y_t]$ を略して $\mathbb{E}[x_s | \mathcal{Y}^t]$ と書く．

このような \hat{x}_s の推定問題は， s, t の大小に応じて，次のように呼ばれる．

$s < t$	$t = s$	$t < s$
平滑化 (smoothing)	濾波 (filtering)	予測 (prediction)

これらを区別するため，次のような表記を導入する．

- 予測推定値 $\hat{x}_{t+1/t} := \mathcal{P}(x_{t+1} | Y^t) = \mathbb{E}[x_{t+1} | y_0, \dots, y_t]$

$$\hat{x}_{t/t-1} := \mathcal{P}(x_t | Y^{t-1}) = \mathbb{E}[x_t | y_0, \dots, y_{t-1}]$$

- 濾波推定値 $\hat{\mathbf{x}}_{t/t} := \mathcal{P}(\mathbf{x}_t | Y^t) = \mathbb{E}[\mathbf{x}_t | \mathbf{y}_0, \dots, \mathbf{y}_t]$

$$\hat{\mathbf{x}}_{t-1/t-1} := \mathcal{P}(\mathbf{x}_{t-1} | Y^{t-1}) = \mathbb{E}[\mathbf{x}_{t-1} | \mathbf{y}_0, \dots, \mathbf{y}_{t-1}]$$

11.3 カルマンフィルタの導出

11.3.1 予測推定値 $\hat{\mathbf{x}}_{t+1/t}$

(11.1) の状態方程式の両辺について, \mathcal{Y}^t に関する条件付き期待値をとると,

$$\langle \mathbf{x}_{t+1} | \mathcal{Y}^t \rangle = F_t \langle \mathbf{x}_t | \mathcal{Y}^t \rangle + G_t \langle \mathbf{w}_t | \mathcal{Y}^t \rangle \quad (11.11)$$

となるが, (11.7) の $\mathbf{y}_t \perp \mathbf{w}_s$ ($t \leq s$) より,

$$\langle \mathbf{w}_t | \mathcal{Y}^t \rangle := \langle \mathbf{w}_t | \mathbf{y}_0, \dots, \mathbf{y}_t \rangle \stackrel{\text{独立}}{=} \langle \mathbf{w}_t \rangle = \mathbf{0} \quad (11.12)$$

となる. ゆえに, まず次の結果が得られる.

$$\hat{\mathbf{x}}_{t+1/t} = F_t \hat{\mathbf{x}}_{t/t} \quad (11.13)$$

続いて, 条件付き共分散行列をとると,

$$\Sigma_{t+1/t} := \langle \mathbf{x}_{t+1} \mathbf{x}_{t+1}^T \mid \mathbf{y}_0, \dots, \mathbf{y}_t \rangle - \hat{\mathbf{x}}_{t+1/t} \hat{\mathbf{x}}_{t+1/t}^T \quad (11.14)$$

となるが, $\mathbf{y}_0, \dots, \mathbf{y}_t$ に対して, これより未来の \mathbf{x}_{t+1} は独立なので, 条件が外れて,

$$\Sigma_{t+1/t} := \langle \mathbf{x}_{t+1} \mathbf{x}_{t+1}^T \rangle - \hat{\mathbf{x}}_{t+1/t} \hat{\mathbf{x}}_{t+1/t}^T \quad (11.15)$$

となる. ゆえに, (10.31) p78 以降と同じ計算により,

$$\Sigma_{t+1/t} = F_t \Sigma_{t/t} F_t^T + G_t Q_t G_t^T \quad (11.16)$$

が得られる. 以上をまとめると,

算法 11.1 (予測推定値) 予測推定値 $\hat{\mathbf{x}}_{t+1/t}$ とその共分散行列 $\Sigma_{t+1/t}$ は, 濾波推定値 $\hat{\mathbf{x}}_{t/t}$ その共分散行列 $\Sigma_{t/t}$ で次のように表せる.

$$\begin{cases} \hat{\mathbf{x}}_{t+1/t} = F_t \hat{\mathbf{x}}_{t/t} \\ \Sigma_{t+1/t} = F_t \Sigma_{t/t} F_t^T + G_t Q_t G_t^T \end{cases} \quad (t = 0, 1, 2, \dots) \quad (11.17)$$

11.3.2 観測誤差ベクトル

観測量 $\mathbf{y}_0, \dots, \mathbf{y}_{t-1}$ を条件とする \mathbf{y}_t の条件付き期待値

$$\hat{\mathbf{y}}_{t/t-1} = \langle \mathbf{y}_t | \mathcal{Y}^{t-1} \rangle := \langle \mathbf{y}_t | \mathbf{y}_0, \dots, \mathbf{y}_{t-1} \rangle \quad (11.18)$$

と, その誤差ベクトル

$$\vec{y}_t := \mathbf{y}_t - \hat{\mathbf{y}}_{t/t-1} = \mathbf{y}_t - \langle \mathbf{y}_t | \mathcal{Y}^{t-1} \rangle \quad (11.19)$$

をとる．誤差ベクトルに (11.1) の観測方程式を代入すると，

$$\begin{aligned} \vec{y}_t &= H_t \mathbf{x}_t + \mathbf{v}_t - \langle H_t \mathbf{x}_t + \mathbf{v}_t | \mathcal{Y}^{t-1} \rangle \\ &= H_t \mathbf{x}_t + \mathbf{v}_t - H_t \langle \mathbf{x}_t | \mathcal{Y}^{t-1} \rangle + \langle \mathbf{v}_t | \mathcal{Y}^{t-1} \rangle \\ &= H_t (\mathbf{x}_t - \hat{\mathbf{x}}_{t/t-1}) + \mathbf{v}_t \quad \because \langle \mathbf{v}_t | \mathcal{Y}^{t-1} \rangle = \mathbf{0} \end{aligned} \quad (11.20)$$

$$= H_t \vec{\mathbf{x}}_{t/t-1} + \mathbf{v}_t, \quad \vec{\mathbf{x}}_{t/t-1} := \mathbf{x}_t - \hat{\mathbf{x}}_{t/t-1} \quad (11.21)$$

となる．これより，以下の結果が導かれる．

算法 11.2 観測誤差ベクトル \vec{y}_t は，ガウス白色雑音であり，次を満足する．

- (1) $\langle \vec{y}_t \rangle = \mathbf{0}$, $\langle \vec{y}_t \vec{y}_s^T \rangle = (R_t + H_t \Sigma_{t/t-1} H_t^T) \delta_{ts}$
- (2) $\vec{y}_t \perp Y^{t-1}$

► 証明 (1) は計算すれば明らか．(2) について， $\mathbf{x}_t - \hat{\mathbf{x}}_{t/t-1}$ は直交射影 $\hat{\mathbf{x}}_{t/t-1} = \mathcal{P}(\mathbf{x}_t | Y^{t-1})$ の誤差ベクトルなので， $\mathbf{x}_t - \hat{\mathbf{x}}_{t/t-1} \perp Y^{t-1}$ であり，すなわち，

$$\langle (\mathbf{x}_t - \hat{\mathbf{x}}_{t/t-1}) \mathbf{y}^T \rangle = 0 \quad \forall \mathbf{y} \in Y^{t-1}$$

となる．ゆえに，

$$\langle H_t (\mathbf{x}_t - \hat{\mathbf{x}}_{t/t-1}) \mathbf{y}^T \rangle = H_t \langle (\mathbf{x}_t - \hat{\mathbf{x}}_{t/t-1}) \mathbf{y}^T \rangle = 0 \quad \forall \mathbf{y} \in Y^{t-1}$$

となるので， $H_t (\mathbf{x}_t - \hat{\mathbf{x}}_{t/t-1}) \perp Y^{t-1}$ となる．また， $\mathbf{v}_t \perp Y^{t-1}$ は (11.6) p83 の $\mathbf{y}_t \perp \mathbf{v}_s$ ($t < s$) より明らか．

11.3.3 直和の構成

必要な集合演算を追加する．あるベクトル空間から，互いに素な部分空間 A, B :

$$A \cap B = \{\mathbf{0}\} \quad (11.22)$$

をとる (共通部分はゼロベクトルだけ)．それらの要素の和

$$\mathbf{z} = \mathbf{a} + \mathbf{b}, \quad \mathbf{a} \in A, \quad \mathbf{b} \in B \quad (11.23)$$

を，(ベクトルの) 直和という．その全体集合を

$$A \oplus B := \{ \mathbf{a} + \mathbf{b} \mid \mathbf{a} \in A, \mathbf{b} \in B \} \quad (11.24)$$

と書き，(ベクトル空間の) 直和という．直和 $\mathbf{a} + \mathbf{b} \in A \oplus B$ が，別のベクトル \mathbf{c} と直交する条件は， $\mathbf{a} \perp \mathbf{c}$ かつ $\mathbf{b} \perp \mathbf{c}$ である (一方だけ直交させても和は直交するとは限らない)．したがって，部分空間の直和 $A \oplus B$ にベクトル \mathbf{c} が直交する条件は，

$$\mathbf{c} \perp A \oplus B \quad \stackrel{\text{必要}}{\text{十分}} \quad \mathbf{c} \perp A \text{ かつ } \mathbf{c} \perp B \quad (11.25)$$

のように 2 つに分離する．その結果，直交射影も 2 つに分離して，

$$\mathcal{P}(x|A \oplus B) = \mathcal{P}(x|A) + \mathcal{P}(x|B) \quad (11.26)$$

という公式が成立する．

もう 1 つ，集合 P, Q が等しいことを次のように定義する．

$$P = Q \stackrel{\text{定義}}{\iff} \text{任意の要素 } x \text{ について } x \in P \iff x \in Q \quad (11.27)$$

例えば， $P = \{a, b, c\}$ と $Q = \{b, a, c\}$ は等しい集合だが，確かに「 $x \in P \Rightarrow x \in Q$ 」と「 $x \in P \Leftarrow x \in Q$ 」が両方向で成立する．

本題に戻る．以上を応用すると，次の算法が得られる．

算法 11.3 観測誤差ベクトル \vec{y}_t が生成するデータ空間

$$\mathcal{E} = \left\{ B\vec{y}_t \mid B \in \mathbb{R}^{n \times p} \right\} \quad (11.28)$$

について，次が成立する．

- (1) $Y^{t-1} \cap \mathcal{E} = \{\mathbf{0}\}$.
- (2) $Y^t = Y^{t-1} \oplus \mathcal{E}$

▶ 証明 (1) は $B\vec{y}_t$ を張る \mathbf{y}_t が Y^{t-1} に含まれないから明らか．(2) の「 $z \in Y^t \Rightarrow z \in Y^{t-1} \oplus \mathcal{E}$ 」を示す．任意の $z \in Y^t$ をとると，

$$z = \mathbf{a} + \sum_{i=1}^t A_i \mathbf{y}_i = \mathbf{a} + \sum_{i=1}^{t-1} A_i \mathbf{y}_i + A_t \mathbf{y}_t$$

と書ける．最後の項に $\mathbf{y}_t = \varepsilon_t - \hat{\mathbf{y}}_{t/t-1}$ を代入すると，条件付き期待値 $\hat{\mathbf{y}}_{t/t-1}$ は $\mathbf{y}_0, \dots, \mathbf{y}_{t-1}$ の線形関数なので，新たなパラメータ \mathbf{a}', A'_i, B' によって，

$$z = \mathbf{a} + \sum_{i=1}^t A_i \mathbf{y}_i = \underbrace{\mathbf{a}' + \sum_{i=1}^{t-1} A'_i \mathbf{y}_i}_{\in Y^{t-1}} + \underbrace{B' \vec{y}_t}_{\in \mathcal{E}}$$

の形式に整理できる．したがって，この z は直和 $Y^{t-1} \oplus \mathcal{E}$ の要素である．次に，「 $z \in Y^{t-1} \oplus \mathcal{E} \Rightarrow z \in Y^t$ 」を示す．任意の $z \in Y^{t-1} \oplus \mathcal{E}$ をとる．これは，

$$z = \mathbf{a} + \sum_{i=1}^{t-1} A_i \mathbf{y}_i + B\vec{y}_t$$

の形式で書ける．ここで， $\varepsilon_t = \mathbf{y}_t + \hat{\mathbf{y}}_{t/t-1}$ を代入すると，新たな \mathbf{a}'', A''_i によって，

$$z = \mathbf{a}'' + \sum_{i=1}^t A''_i \mathbf{y}_i$$

の形式に整理できる．ゆえに， z は Y^t の要素である．

11.3.4 濾波推定値 $\hat{\mathbf{x}}_{t/t}$

時刻 $t+1$ における濾波推定値は、直交射影で、

$$\hat{\mathbf{x}}_{t/t} = \mathcal{P}(\mathbf{x}_t | Y^t) = \mathcal{P}(\mathbf{x}_t | Y^{t-1} \oplus \mathcal{E}) \quad \because \text{算法 11.3 (2)} \quad (11.29)$$

と書ける．ゆえに、直交射影の公式 (11.26) により、

$$\hat{\mathbf{x}}_{t/t} = \mathcal{P}(\mathbf{x}_t | Y^{t-1}) + \mathcal{P}(\mathbf{x}_t | \mathcal{E}) = \hat{\mathbf{x}}_{t/t-1} + \langle \mathbf{x}_t | \vec{\mathbf{y}}_t \rangle \quad (11.30)$$

という結果が得られる．条件付き期待値 $\langle \mathbf{x}_t | \vec{\mathbf{y}}_t \rangle$ は、 $\vec{\mathbf{y}}_t$ の線形関数なので、適当な行列 B によって、次のように表示できる．

$$\hat{\mathbf{x}}_{t/t} = \hat{\mathbf{x}}_{t/t-1} + B \vec{\mathbf{y}}_t \quad (11.31)$$

問題は B の定め方だが、次節の方法で定めた B を、カルマンゲインという．

11.3.5 カルマンゲインの導出

関係式 (11.31) を改めて、

$$\hat{\mathbf{x}}_{t/t} = \hat{\mathbf{x}}_{t/t-1} + K_t \vec{\mathbf{y}}_t \quad (11.32)$$

と書き、濾波推定値の誤差ベクトル

$$\vec{\mathbf{x}}_{t/t} := \mathbf{x}_t - \hat{\mathbf{x}}_{t/t} \quad (11.33)$$

をとる．以下、誤差 $\|\vec{\mathbf{x}}_{t/t}\|$ を最小化する K_t を求める．

そのための条件は $\vec{\mathbf{x}}_{t/t} \perp Y^t$ であった．ただし、算法 11.3 (2) より $Y^t = Y^{t-1} \oplus \mathcal{E}$ なので、これは (11.25) より、次の条件と等価である．

$$\vec{\mathbf{x}}_{t/t} \perp Y^{t-1} \quad \text{かつ} \quad \vec{\mathbf{x}}_{t/t} \perp \mathcal{E} \quad (11.34)$$

まず、 $\vec{\mathbf{x}}_{t/t} \perp Y^{t-1}$ が示される．実際、(11.33) に (11.32) を代入すると、

$$\vec{\mathbf{x}}_{t/t} := \vec{\mathbf{x}}_{t/t-1} - K_t \vec{\mathbf{y}}_t, \quad \vec{\mathbf{x}}_{t/t-1} := \mathbf{x}_t - \hat{\mathbf{x}}_{t/t-1} \quad (11.35)$$

となる．予測推定誤差 $\vec{\mathbf{x}}_{t/t-1}$ は直交射影 $\hat{\mathbf{x}}_{t/t-1} = \mathcal{P}(\mathbf{x}_t | Y^{t-1})$ の誤差ベクトルなので、 $\vec{\mathbf{x}}_{t/t-1} \perp Y^{t-1}$ が成立する．また、算法 11.2 より $\vec{\mathbf{y}}_t \perp Y^{t-1}$ であるから、

$$\vec{\mathbf{x}}_{t/t} := \vec{\mathbf{x}}_{t/t-1} - K_t \vec{\mathbf{y}}_t \quad \perp Y^{t-1} \quad (11.36)$$

が示された．

次に、残りの条件 $\vec{\mathbf{x}}_{t/t} \perp \mathcal{E}$ を課すと、

$$\begin{aligned} 0 &= \langle \vec{\mathbf{x}}_{t/t} \vec{\mathbf{y}}_t^T \rangle = \langle (\vec{\mathbf{x}}_{t/t-1} - K_t \vec{\mathbf{y}}_t) \vec{\mathbf{y}}_t^T \rangle = \langle \vec{\mathbf{x}}_{t/t-1} \vec{\mathbf{y}}_t^T \rangle - K_t \langle \vec{\mathbf{y}}_t \vec{\mathbf{y}}_t^T \rangle \\ &= \langle \vec{\mathbf{x}}_{t/t-1} (H_t \vec{\mathbf{x}}_{t/t-1} + \mathbf{v}_t)^T \rangle - K_t \langle \vec{\mathbf{y}}_t \vec{\mathbf{y}}_t^T \rangle \quad \because (11.21) \text{ p85} \\ &= \langle \vec{\mathbf{x}}_{t/t-1} \vec{\mathbf{x}}_{t/t-1}^T \rangle H_t^T + \underbrace{\langle \vec{\mathbf{x}}_{t/t-1} \mathbf{v}_t^T \rangle}_{=0: (11.5)} - K_t \langle \vec{\mathbf{y}}_t \vec{\mathbf{y}}_t^T \rangle \end{aligned}$$

$$= \Sigma_{t/t-1} H_t^T - K_t (R_t + H_t \Sigma_{t/t-1} H_t^T) \quad \because \text{算法 11.2} \quad (11.37)$$

という関係式が得られる． K_t について解くと，

$$K_t = \Sigma_{t/t-1} H_t^T (R_t + H_t \Sigma_{t/t-1} H_t^T)^{-1} \quad (11.38)$$

が得られる．この K_t をカルマンゲインという．

最後に，(11.35) を移項した

$$\tilde{\mathbf{x}}_{t/t-1} = \tilde{\mathbf{x}}_{t/t} + K_t \tilde{\mathbf{y}}_t \quad (11.39)$$

の両辺の共分散をとると， $\tilde{\mathbf{x}}_{t/t} \perp \tilde{\mathbf{y}}_t$ ，すなわち $\langle \tilde{\mathbf{x}}_{t/t} \tilde{\mathbf{y}}_t^T \rangle = O$ に注意して，

$$\begin{aligned} \Sigma_{t/t-1} &:= \langle \tilde{\mathbf{x}}_{t/t} \tilde{\mathbf{x}}_{t/t}^T \rangle \\ &= \langle (\tilde{\mathbf{x}}_{t/t} + K_t \tilde{\mathbf{y}}_t)(\tilde{\mathbf{x}}_{t/t} + K_t \tilde{\mathbf{y}}_t)^T \rangle \\ &= \langle \tilde{\mathbf{x}}_{t/t} \tilde{\mathbf{x}}_{t/t}^T \rangle + K_t \langle \tilde{\mathbf{y}}_t \tilde{\mathbf{y}}_t^T \rangle K_t^T + \underbrace{K_t \langle \tilde{\mathbf{y}}_t \tilde{\mathbf{x}}_{t/t}^T \rangle + \langle \tilde{\mathbf{x}}_{t/t} \tilde{\mathbf{y}}_t^T \rangle K_t^T}_{=O} \\ &= \Sigma_{t/t} + K_t \langle \tilde{\mathbf{y}}_t \tilde{\mathbf{y}}_t^T \rangle K_t^T \\ &= \Sigma_{t/t} + K_t (R_t + H_t \Sigma_{t/t-1} H_t^T) K_t^T \quad \because \text{算法 11.2p85(1)} \\ &= \Sigma_{t/t} + K_t (R_t + H_t \Sigma_{t/t-1} H_t^T) K_t^T \quad (11.40) \end{aligned}$$

となるが，共分散行列の対称性 $R_t^T = R_t$ ， $\Sigma^T = \Sigma$ より，

$$\begin{aligned} K_t^T &= \left\{ (R_t + H_t \Sigma_{t/t-1} H_t^T)^{-1} \right\}^T H_t^T \Sigma_{t/t-1}^T \\ &= (R_t^T + H_t \Sigma_{t/t-1}^T H_t^T)^{-1} H_t^T \Sigma_{t/t-1}^T = (R_t + H_t \Sigma_{t/t-1} H_t^T)^{-1} H_t \Sigma_{t/t-1} \end{aligned}$$

となるので，

$$\Sigma_{t/t-1} = \Sigma_{t/t} + K_t H_t \Sigma_{t/t-1} \quad (11.41)$$

が得られる．以上をまとめると，

算法 11.4 (濾波推定値) 線形確率システムの状態量 \mathbf{x}_t の濾波推定値 $\hat{\mathbf{x}}_{t/t}$ は，


$$\begin{cases} \hat{\mathbf{x}}_{t/t} = \hat{\mathbf{x}}_{t/t-1} + K_t \nu_t = \hat{\mathbf{x}}_{t/t-1} + K_t (\mathbf{y}_t - H_t \hat{\mathbf{x}}_{t/t-1}) & (\text{推定値}) \\ K_t = \Sigma_{t/t-1} H_t^T (H_t \Sigma_{t/t-1} H_t^T + R_t)^{-1} & (\text{カルマンゲイン}) \\ \Sigma_{t/t} = (I - K_t H_t) \Sigma_{t/t-1} & (\text{推定誤差共分散}) \end{cases}$$

で得られる．ただし I は単位行列である．

11.4 カルマンフィルタ

11.4.1 基本アルゴリズム

次のような逐次計算アルゴリズムを構成できる．



これをカルマンフィルタという．

算法 11.5 (カルマンフィルタ 1) 線形確率システム：

$$\begin{cases} \mathbf{x}_{t+1} = \mathbf{F}_t \mathbf{x}_t + \mathbf{G}_t \mathbf{w}_t, & \mathbf{x}_t \in \mathbb{R}^n, \mathbf{w}_t \in \mathbb{R}^r \\ \mathbf{y}_t = \mathbf{H}_t \mathbf{x}_t + \mathbf{v}_t, & \mathbf{y}_t, \mathbf{v}_t \in \mathbb{R}^p, t = 0, 1, 2, \dots \end{cases}$$

の最小分散濾波推定値 $\hat{\mathbf{x}}_{t/t}$ は，次のように逐次計算できる^{a)}．

(0) 初期条件：

$$\hat{\mathbf{x}}_{0/-1} = \bar{\mathbf{x}}_0, \quad \Sigma_{0/-1} = \Sigma_0 \quad (11.42)$$

(1) 濾波推定： $\mathbf{y}_t, \hat{\mathbf{x}}_{t/t-1}, \Sigma_{t/t-1}$ を既知として，

$$\text{カルマンゲイン } K_t = \Sigma_{t/t-1} H_t^T (H_t \Sigma_{t/t-1} H_t^T + R_t)^{-1} \quad (11.43)$$

$$\text{濾波推定値 } \hat{\mathbf{x}}_{t/t} = \hat{\mathbf{x}}_{t/t-1} + K_t (\mathbf{y}_t - H_t \hat{\mathbf{x}}_{t/t-1}) \quad (11.44)$$

$$\text{濾波推定誤差 } \Sigma_{t/t} = (I - K_t H_t) \Sigma_{t/t-1} \quad (11.45)$$

ただし，逆行列が存在しない場合は，疑似逆行列を用いる．

(2) 予測推定：

$$\text{予測推定値 } \hat{\mathbf{x}}_{t+1/t} = \mathbf{F}_t \hat{\mathbf{x}}_{t/t} \quad (11.46)$$

$$\text{予測推定誤差 } \Sigma_{t+1/t} = \mathbf{F}_t \Sigma_{t/t} \mathbf{F}_t^T + \mathbf{G}_t \mathbf{Q}_t \mathbf{G}_t^T \quad (11.47)$$

11.4.2 離散時間リカッチ方程式

算法 11.5 の式を集約して整理することを考える．まず，濾波推定値 (11.44) を予測推定値 (11.46) に代入すると，

^{a)} 片山 [3] p90 など．

$$\begin{aligned}
\hat{\mathbf{x}}_{t+1/t} &= F_t \hat{\mathbf{x}}_{t/t} = F_t \hat{\mathbf{x}}_{t/t-1} + F_t K_t (\mathbf{y}_t - H_t \hat{\mathbf{x}}_{t/t-1}) \\
&= F_t \hat{\mathbf{x}}_{t/t-1} + F_t \Sigma_{t/t-1} H_t^T (H_t \Sigma_{t/t-1} H_t^T + R_t)^{-1} (\mathbf{y}_t - H_t \hat{\mathbf{x}}_{t/t-1})
\end{aligned} \tag{11.48}$$

となるが，予測推定値 $\hat{\mathbf{x}}_{t/t-1}$ とその誤差共分散 $\Sigma_{t/t-1}$ を改めて，

$$\begin{cases} \hat{\mathbf{x}}_t := \hat{\mathbf{x}}_{t/t-1} \\ \Sigma_t := \Sigma_{t/t-1} \end{cases} \tag{11.49}$$

と表記すると，

$$\hat{\mathbf{x}}_{t+1} = F_t \hat{\mathbf{x}}_t + F_t \underbrace{\Sigma_t H_t^T (H_t \Sigma_t H_t^T + R_t)^{-1}}_{K_t} (\mathbf{y}_t - H_t \hat{\mathbf{x}}_t) \tag{11.50}$$

という予測推定式が得られる．同様に，濾波推定誤差 (11.45) を予測推定誤差 (11.47) に代入すると，

$$\begin{aligned}
\Sigma_{t+1} &= F_t \left\{ (I - K_t H_t) \Sigma_t \right\} F_t^T + G_t Q_t G_t^T \\
&= F_t \Sigma_t F_t^T + G_t Q_t G_t^T - F_t K_t H_t \Sigma_t F_t^T
\end{aligned} \tag{11.51}$$

を得る．この式を，離散時間リカッチ方程式^{b)} という．以上をまとめると，

算法 11.6 (カルマンフィルタ 2) 線形確率システム：

$$\begin{cases} \mathbf{x}_{t+1} = F_t \mathbf{x}_t + G_t \mathbf{w}_t, & \mathbf{x}_t \in \mathbb{R}^n, \mathbf{w}_t \in \mathbb{R}^r \\ \mathbf{y}_t = H_t \mathbf{x}_t + \mathbf{v}_t, & \mathbf{y}_t, \mathbf{v}_t \in \mathbb{R}^p, t = 0, 1, 2, \dots \end{cases} \tag{11.52}$$

の最小分散濾波推定値 $\hat{\mathbf{x}}_{t/t}$ は，次のように逐次計算できる．

(0) 初期条件：

$$\hat{\mathbf{x}}_0 = \bar{\mathbf{x}}_0, \quad \Sigma_0 = \Sigma_0 \tag{11.53}$$

(1) 濾波推定： $\mathbf{y}_t, \hat{\mathbf{x}}_t, \Sigma_t$ を既知として，

$$\text{カルマンゲイン} \quad K_t = \Sigma_t H_t^T (H_t \Sigma_t H_t^T + R_t)^{-1} \tag{11.54}$$

$$\text{濾波推定値} \quad \hat{\mathbf{x}}_{t/t} = \hat{\mathbf{x}}_t + K_t (\mathbf{y}_t - H_t \hat{\mathbf{x}}_t) \tag{11.55}$$

ただし，逆行列が存在しない場合は，疑似逆行列を用いる．

(2) 予測推定：

$$\text{予測推定値} \quad \hat{\mathbf{x}}_{t+1} = F_t \hat{\mathbf{x}}_{t/t} = F_t \hat{\mathbf{x}}_t + F_t K_t (\mathbf{y}_t - H_t \hat{\mathbf{x}}_t) \tag{11.56}$$

$$\text{予測推定誤差} \quad \Sigma_{t+1} = F_t \Sigma_t F_t^T + G_t Q_t G_t^T - F_t K_t H_t \Sigma_t F_t^T \tag{11.57}$$

^{b)} 片山 [3]p92 など．

算法 11.6 のプログラム例を以下に示す .

Code 2 “KF.sci” (Scilab)

```

1  ///// Kalman filter /////
2  function [xf, xp, Pp] = KF(y,x0,P0,F,G,H,Q,R);
3      //filtering
4      K = P0*H'*pinv(H*P0*H'+R); //Kalman gain
5      /// pinv is used instead of inv
6      xf = x0 + K*( y - H*x0 ); //x_t/t <= result
7      //prediction
8      xp = F*xf; //x_{t+1}/t
9      Pp = F*P0*F' + G*Q*G' - F*K*H*P0*F'; //P_{t+1}/t
10 endfunction

```

11.4.3 定常カルマンフィルタと安定性

行列 F_t, G_t, H_t, Q_t, R_t が全て定行列であるとき, 共分散行列 Σ_t の支配方程式 (11.57) は, 定係数の差分方程式 (漸化式) となる. この差分方程式が安定なら, 定常値 $\Sigma = \lim_{t \rightarrow \infty} \Sigma_t$ が存在し, カルマンゲインも定常値 $K = \lim_{t \rightarrow \infty} K_t$ をもつ. このとき, カルマンフィルタの時間発展は, y_t に依存する予測推定値 \hat{x}_t のみとなり,

$$\hat{x}_{t+1} = F\hat{x}_t + FK(y_t - H\hat{x}_t) \quad (11.58)$$

$$\begin{cases} K = \Sigma H^T (H \Sigma H^T + R)^{-1} \\ \Sigma = F \Sigma F^T + G Q G^T - F K H \Sigma F^T \quad (\text{代数リカッチ方程式}) \end{cases} \quad (11.59)$$

という状態推定式が得られる. これを, 定常カルマンフィルタという^{○)}.

定常カルマンフィルタには大きな利点があり, (11.59) の方程式 (代数リカッチ方程式という) が事前に解ける. したがってカルマンゲイン K の成分が事前に求まるので, 状態推定器には, (11.58) のみを実装すればよい.

▶▶ 一般的な数値解析言語 (Scilab, Octave, Matlab など) は, 代数リカッチ方程式のソルバー (計算機能) を備えており, K は安直に計算できる.

推定値 \hat{x}_t の安定性を調べるため, 誤差ベクトル $\vec{x}_t := \hat{x}_t - x_t$ を復活させると, $y_t - H\hat{x}_t = Hx_t + v_t - H\hat{x}_t = H(\hat{x}_t - \vec{x}_t) + v_t - H\hat{x}_t = v_t - H\vec{x}_t$ より, 予測推定値 (11.56) は,

$$\hat{x}_{t+1} = F\hat{x}_t + FK(y_t - H\hat{x}_t) = F\hat{x}_t - FKH\vec{x}_t + FKv_t \quad (11.60)$$

となる. これと (11.52) の第 1 式より,

$$\begin{aligned} \vec{x}_{t+1} &= \hat{x}_{t+1} - x_{t+1} = F\hat{x}_t - FK_t H_t \vec{x}_t + FKv_t - Fx_t - Gw_t \\ &= F\vec{x}_t - FKH\vec{x}_t + FKv_t - Gw_t \\ \therefore \vec{x}_{t+1} &= F(I - KH)\vec{x}_t + S_t, \quad S_t := FKv_t - Gw_t \end{aligned} \quad (11.61)$$

^{○)} 片山 [3] p108 など.

が得られる． I は単位行列である．この漸化式（離散力学系）が安定ならば，推定誤差 \hat{x}_t は安定となる．すなわち，次の安定条件が得られる^{d)}．

算法 11.7 (定常カルマンフィルタの安定条件) 行列 $F(I - KH)$ の固有値の絶対値（複素数の意味での）が，全て 1 未満のとき，推定誤差 \hat{x}_t は漸近安定となる．

当然のことながら，これを満たさない条件では，推定誤差が収束しないのでカルマンフィルタは使用できない．

11.5 数値例

1 自由度振動系の状態推定の例を示す．ランダムな線形 1 自由度振動系とその観測問題を考える．

$$\frac{d}{dt} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ -k & -c \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + \begin{bmatrix} 0 \\ 1 \end{bmatrix} w(t) \quad (11.62)$$

$$y = (0, 1) \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + v(t) = x_2 + v(t) \quad (11.63)$$

$w(t)$, $v(t)$ はそれぞれ $N(0, Q)$, $N(0, R)$ のガウス白色雑音とする．すなわち，この系は不規則外乱 $w(t)$ を受けており，雑音 $v(t)$ に乱された速度 x_2 しか観測できない．

以上で導出した離散時間カルマンフィルタを用いるため，オイラー法で離散化する．

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}_{n+1} - \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}_n = \Delta t \begin{bmatrix} 0 & 1 \\ -k & -c \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}_n + \Delta t \begin{bmatrix} 0 \\ 1 \end{bmatrix} w_n \quad (11.64)$$

これから次の線形離散時間確率システムが得られる．

$$\mathbf{x}_{n+1} = \underbrace{\begin{bmatrix} 1 & \Delta t \\ -k\Delta t & 1 - c\Delta t \end{bmatrix}}_F \mathbf{x}_n + \underbrace{\begin{bmatrix} 0 \\ \Delta t \end{bmatrix}}_G w_n \quad (11.65)$$

$$y_n = \underbrace{(0, 1)}_H \mathbf{x}_n + v_n = (x_2)_n + v_n \quad (11.66)$$


図 11.1 に数値例を示す．青線は観測値，緑点は状態量の真値，赤線はカルマンフィルタによる推定値を表す．各上段は，この系の速度の観測値 y_n と真値 $(x_2)_n$ の時間応答であり，下段は相軌道である．一般に，測定値が速度のとき，これを数値的に積分して変位の測定値とすることがあるが，これが下段左の青線である．積分により y_n のゆらぎが累積するので，真値（緑点）と大きくかけ離れる．このように，速度を積分して変位を求める方法は，雑音に弱い．

^{d)} 片山 [3] p110 など．

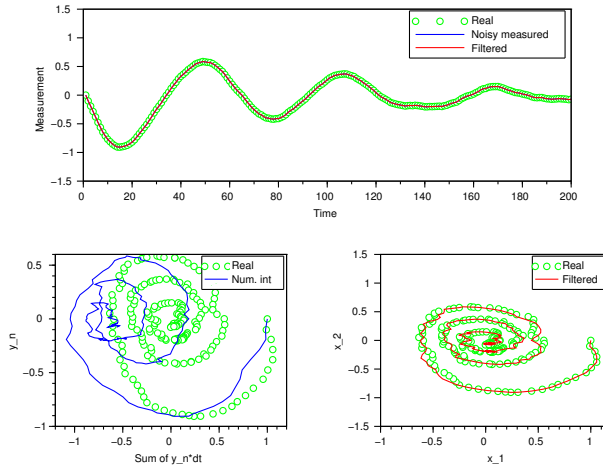
▶▶ (ジャイロセンサのドリフト) 以上の問題は, ジャイロセンサが検出する角速度から角変位を求めるときにも生じる. 例えば, 角変位が 0 のときから計測を始めて, 数値積分で角変位を推定していくと, 角変位の真値が 0 に戻っても, 推定値は 0 に戻らない. この不具合をドリフトという. その解消のために, カルマンフィルタが実用されている.

これに対して, 下段右の赤線はカルマンフィルタによる状態推定結果だが, $Q = 0, R \neq 0$ (観測雑音のみ) の場合は, 誤差 0 の状態推定が行われている. 次に $Q \neq 0, R = 0$ (システム雑音のみ) とすると推定誤差が生じるが, 推定値は観測値の近傍にある. さらに, $Q \neq 0, R \neq 0$ としても精度は思ったほど悪化しない.

$$Q = 0, R = 0.1$$



$$Q = 10^{-3}, R \approx 0 (= 10^{-16})$$



$$Q = 10^{-3}, R = 0.1$$

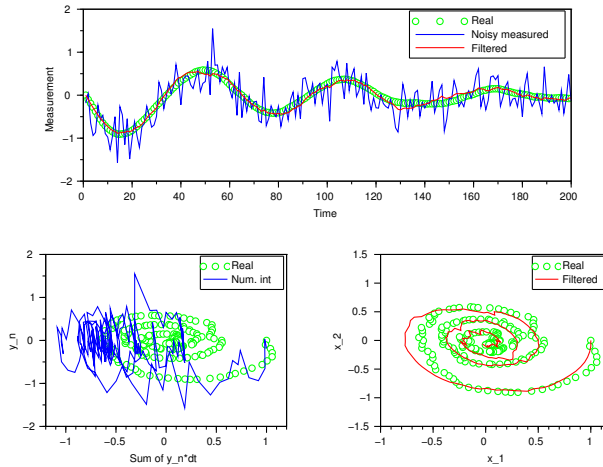


図 11.1 数値積分による変位推定 (下段左) とカルマンフィルタによる状態推定 (下段右) の比較 ($c = 0.3, k = 1, \Delta t = 0.1$) . 各上段は観測量 y_n を表す .

12

連続時間カルマンフィルタ

カルマンフィルタを，フィードバック制御に応用したい (13 章)．そのための準備として，前章で導出した離散時間の結果を，連続時間に拡張する．紙面も尽きてきたので，厳密性は犠牲にして，少々乱暴に導出する．

12.1 連続時間の状態方程式

離散時間で導いた算法 10.5 p79 を，連続時間に拡張する．

12.1.1 状態方程式

まず，時間 t を実数とする次の状態方程式を考える．

$$\dot{\mathbf{x}}(t) = A(t)\mathbf{x}(t) + D(t)\mathbf{w}(t), \quad \mathbf{x}(t) \in \mathbb{R}^n, \mathbf{w}(t) \in \mathbb{R}^r \quad (12.1)$$

$\mathbf{w}(t)$ は連続時間のガウス白色雑音で，次の性質を示す (ものとして定義される)．

$$\langle \mathbf{w}(t) \rangle = \mathbf{0}, \quad \langle \mathbf{w}(t)\mathbf{w}(s)^T \rangle = Q(t)\delta(t-s) \quad (s \geq t) \quad (12.2)$$

離散時間の場合と同様に，この性質をデルタ相関という． $\delta(t)$ はディラックのデルタ関数である． $\delta(t)$ は，面積 1 のインパルスを，面積を変えずに幅 $\rightarrow 0$ としたもので，数学的には次のように定義される．

$$\delta(t) = 0 \quad (t \neq 0), \quad \int_{-\infty}^{\infty} f(t)\delta(t-a)dt = f(a) \quad (12.3)$$

デルタ相関の仮定により，白色雑音の成分 $w_i(t)$ は，無限小時間だけ未来の自分 $w_i(t-dt)$ や過去の自分 $w_i(t+dt)$ と無相関になる．そうなる $w_i(t)$ は，いたるところ不連続な時間関数になる．すなわち， $w_i(t)$ のグラフは極度にギザギザしていて，時間方向にいくら拡大して見ても，ギザギザは消えない．

12.1.2 離散時間系との対応

時間 t を, サンプルング時間 Δt で離散化する.

$$t_k = t_0 + k\Delta t \quad (k = 0, \dots, n) \quad (12.4)$$

各時刻 t_k の状態量, 係数, 雑音を,

$$\mathbf{x}_k := \mathbf{x}(t_k), \quad A_k := A(t_k), \quad D_k := D(t_k), \quad \mathbf{w}_k := \mathbf{w}(t_k) \quad (12.5)$$

と書く. このとき, Δt が十分に小さければ, 微分の定義より,

$$\dot{\mathbf{x}}(t_k) \approx \frac{\mathbf{x}(t_k + \Delta t) - \mathbf{x}(t_k)}{\Delta t} = \frac{\mathbf{x}_{k+1} - \mathbf{x}_k}{\Delta t} \quad (12.6)$$

という近似が成立する. 状態方程式 (12.1) に代入して分母を払うと, $\mathbf{x}_{k+1} - \mathbf{x}_k = A_k \mathbf{x}_k \Delta t + D_k \mathbf{w}_k \Delta t$ すなわち,

$$\mathbf{x}_{k+1} = (I + \Delta t A_k) \mathbf{x}_k + (\Delta t D_k) \mathbf{w}_k \quad (12.7)$$

が得られる. I は単位行列である. 仮に, $\mathbf{w}(t)$ が連続な時間関数であれば, これが状態方程式の最も単純な離散化を与える (オイラー法).

しかしながら, $\mathbf{w}(t)$ が白色雑音の場合, 雑音項 $D_k \mathbf{w}_k \Delta t$ の強度が Δt に依存してしまう. なぜなら, 例えば Δt を大きくすると, $\mathbf{w}(t)$ の細かいギザギザが (12.7) に伝わらなくなる. ゆえに, 離散化した白色雑音 $\mathbf{w}_k := \mathbf{w}(t_k)$ のパワーは, もとの $\mathbf{w}(t)$ より小さくなる.

両者の関係を導く. 簡単のため, スカラ値の $w(t)$ を考える. 前節で述べたように, 連続時間の白色雑音 $w(t)$ の強度は,

$$\langle w(t)w(s) \rangle = Q(t)\delta(t-s) \quad (12.8)$$

で表せた ($Q(t)$ もスカラ). このグラフの面積 A は, $\delta(t-s)$ の面積が 1 であることから, $A = Q(t)$ である. 一方で, 離散化した $w_k := w(t_k)$ の強度は,

$$\langle w_k w_l \rangle = Q_k \delta_{kl} \quad (12.9)$$

であった. このとき, $w(t_k)$ のグラフの面積は, サンプルング時間 Δt に対して, $S = \Delta t Q_k$ となる. したがって, w_k に $w(t)$ と同等の強度を持たせるには,

$$Q(t) = S = \Delta t Q_k \quad (12.10)$$

となるような Q_k を選べばよい.

以上をまとめると, 離散時間系

$$\begin{cases} \dot{\mathbf{x}}(t) = A(t)\mathbf{x}(t) + D(t)\mathbf{w}(t), & \mathbf{x}(t) \in \mathbb{R}^n, \mathbf{w}(t) \in \mathbb{R}^r, \\ \langle \mathbf{w}(t) \rangle = \mathbf{0}, & \langle \mathbf{w}(t)\mathbf{w}(s)^T \rangle = Q(t)\delta(t-s) \end{cases} \quad (12.11)$$

は, 次の離散時間系で近似できる.

$$\begin{cases} \mathbf{x}_{k+1} = F_k \mathbf{x}_k + G_k \mathbf{w}_k, & \mathbf{x}_k \in \mathbb{R}^n, \mathbf{w}_k \in \mathbb{R}^r \\ \langle \mathbf{w}_k \rangle = \mathbf{0}, \quad \langle \mathbf{w}_k \mathbf{w}_l^T \rangle = Q_k \delta_{kl} \end{cases} \quad (12.12)$$

ただし,

$$F_k = I + \Delta t A(t_k), \quad G_k = \Delta t D(t_k), \quad Q_k = Q(t_k)/\Delta t \quad (12.13)$$

12.1.3 期待値と共分散行列の推移

算法 10.5 p79 の期待値の推移則に (12.13) の F_k を代入すると,

$$\bar{\mathbf{x}}_{k+1} = F_k \bar{\mathbf{x}}_k = (I + \Delta t A(t_k)) \bar{\mathbf{x}}_k = \bar{\mathbf{x}}_k + \Delta t A(t_k) \bar{\mathbf{x}}_k \quad (12.14)$$

より,

$$\frac{\bar{\mathbf{x}}(t_k + \Delta t) - \bar{\mathbf{x}}(t_k)}{\Delta t} = A(t_k) \bar{\mathbf{x}}(t_k) \quad (12.15)$$

となる. $\Delta t \rightarrow 0$ の極限をとり, $t = t_k$ とすると, (12.1) の期待値の推移則

$$\dot{\bar{\mathbf{x}}}(t) = A(t) \bar{\mathbf{x}}(t) \quad (12.16)$$

を得る. 同様に, 共分散行列の推移則 (10.35) p79 に (12.13) を代入すると,

$$\begin{aligned} \Sigma_{k+1} &= F_k \Sigma_k F_k^T + G_k Q_k G_k^T \\ &= (I + \Delta t A(t_k)) \Sigma_k (I + \Delta t A(t_k))^T + (\Delta t D(t_k)) \frac{Q(t_k)}{\Delta t} (\Delta t D(t_k))^T \\ &= \Sigma_k + \Delta t (A_k \Sigma_k + \Sigma_k A_k^T) + O(\Delta t^2) + \Delta t (D(t_k) Q(t_k) D(t_k)^T) \end{aligned} \quad (12.17)$$

となる. すなわち,

$$\begin{aligned} \frac{\Sigma(t_k + \Delta t) - \Sigma(t_k)}{\Delta t} &= A(t_k) \Sigma(t_k) + \Sigma(t_k) A(t_k)^T + D(t_k) Q(t_k) D(t_k)^T + O(\Delta t) \end{aligned} \quad (12.18)$$

が得られる. $\Delta t \rightarrow 0$ の極限をとり, 改めて $t = t_k$ と置くと,

$$\dot{\Sigma}(t) = A(t) \Sigma(t) + \Sigma(t) A(t)^T + D(t) Q(t) D(t)^T \quad (12.19)$$

という推移則が得られる. 以上をまとめると,

算法 12.1 (期待値と共分散行列の推移則 (連続時間)) (12.1) の状態量 $\mathbf{x}(t)$ の期待値と共分散行列

$$\bar{\mathbf{x}}(t) := \langle \mathbf{x}(t) \rangle, \quad \Sigma(t) := \langle (\mathbf{x}(t) - \bar{\mathbf{x}}(t))(\mathbf{x}(t) - \bar{\mathbf{x}}(t))^T \rangle \quad (12.20)$$

は, 次の常微分方程式に従って時間発展する.

$$\dot{\bar{\mathbf{x}}} = A(t) \bar{\mathbf{x}}(t), \quad (12.21)$$

$$\dot{\Sigma}(t) = A(t) \Sigma(t) + \Sigma(t) A(t)^T + D(t) Q(t) D(t)^T \quad (12.22)$$

12.2 連続時間確率システム

連続時間の線形確率システムを，次のように導入する．

$$\begin{cases} \dot{\mathbf{x}}(t) = A(t)\mathbf{x}(t) + D(t)\mathbf{w}(t), & \mathbf{x}(t) \in \mathbb{R}^n, \mathbf{w}(t) \in \mathbb{R}^r, \\ \mathbf{y}(t) = C(t)\mathbf{x}(t) + \mathbf{v}(t), & \mathbf{y}(t), \mathbf{v}(t) \in \mathbb{R}^p, \\ \langle \mathbf{w}(t) \rangle = \mathbf{0}, & \langle \mathbf{w}(t)\mathbf{w}(s)^T \rangle = Q(t)\delta(t-s), \\ \langle \mathbf{v}(t) \rangle = \mathbf{0}, & \langle \mathbf{v}(t)\mathbf{v}(s)^T \rangle = R(t)\delta(t-s) \quad (s \geq t) \end{cases} \quad (12.23)$$

これの離散近似を以下で与える．

$$\begin{cases} \mathbf{x}_{k+1} = F_k\mathbf{x}_k + G_k\mathbf{w}_k, & \mathbf{x}_k \in \mathbb{R}^n, \mathbf{w}_k \in \mathbb{R}^r \\ \mathbf{y}_k = H_k\mathbf{x}_k + \mathbf{v}_k, & \mathbf{y}_k, \mathbf{v}_k \in \mathbb{R}^p, k = 0, 1, 2, \dots \\ \langle \mathbf{w}_k \rangle = \mathbf{0}, & \langle \mathbf{w}_k\mathbf{w}_l^T \rangle = Q_k\delta_{kl}, \\ \langle \mathbf{v}_k \rangle = \mathbf{0}, & \langle \mathbf{v}_k\mathbf{v}_l^T \rangle = R_k\delta_{kl} \end{cases} \quad (12.24)$$

係数の対応は，次のようになる．

$$\begin{cases} F_k = I + \Delta t A(t_k), & G_k = \Delta t D(t_k), & H_k = C(t_k), \\ Q_k = Q(t_k)/\Delta t, & R_k = R(t_k)/\Delta t \end{cases} \quad (12.25)$$

12.3 Kalman–Bucy フィルタ

算法 11.6 p90 のカルマンフィルタは差分方程式で表現されているが，これらに (12.25) を代入して，微分方程式による表現を導く．このような連続時間型のカルマンフィルタを Kalman–Bucy^{a)} フィルタという．

12.3.1 カルマンゲイン

(11.54) に，係数 (12.25) を代入すると，

$$\begin{aligned} K_k &= \Sigma_k C(t_k)^T \left(C(t_k) \Sigma_k C(t_k)^T + \frac{R(t_k)}{\Delta t} \right)^{-1} \\ &= \Delta t \Sigma_k C(t_k)^T \left(\Delta t C(t_k) \Sigma_k C(t_k)^T + R(t_k) \right)^{-1} =: \Delta t K'_k \end{aligned} \quad (12.26)$$

が得られる． $\Delta t \rightarrow 0$ のとき， $K'_k \rightarrow \Sigma(t)C(t)^T R(t)^{-1}$ となる．

^{a)} かるまん・ぶーしー

12.3.2 予測推定値

(11.56) に、係数 (12.25) を代入すると、

$$\begin{aligned}\hat{\mathbf{x}}_{k+1} &= \{I + \Delta t A(t_k)\} \hat{\mathbf{x}}_k + \{I + \Delta t A(t_k)\} \Delta t K'_k \{\mathbf{y}_k - C(t_k) \hat{\mathbf{x}}_k\} \\ &= \hat{\mathbf{x}}_k + \Delta t A(t_k) \hat{\mathbf{x}}_k + \Delta t K'_k \{\mathbf{y}_k - C(t_k) \hat{\mathbf{x}}_k\} + O(\Delta t^2)\end{aligned}\quad (12.27)$$

すなわち、

$$\frac{\hat{\mathbf{x}}_{k+1} - \hat{\mathbf{x}}_k}{\Delta t} = A(t_k) \hat{\mathbf{x}}_k + K'_k \{\mathbf{y}_k - C(t_k) \hat{\mathbf{x}}_k\} + O(\Delta t) \quad (12.28)$$

となり、 $\Delta t \rightarrow 0$ の極限において、

$$\dot{\hat{\mathbf{x}}}(t) = A(t) \hat{\mathbf{x}}(t) + \Sigma(t) C(t)^T R(t)^{-1} \{(\mathbf{y}(t) - C(t) \hat{\mathbf{x}}(t))\} \quad (12.29)$$

が得られる。また、 $\Delta t \rightarrow 0$ の極限で $\hat{\mathbf{x}}_{t/t-\Delta t} \rightarrow \hat{\mathbf{x}}_{t/t}$ となるから、濾波推定値 $\hat{\mathbf{x}}(t)$ は (12.29) の解 $\hat{\mathbf{x}}(t)$ として得られることになる。

12.3.3 予測推定誤差

同じく (11.57) に代入すると、算法 12.1 の導出を参考に、

$$\begin{aligned}\Sigma_{k+1} &= F_k \Sigma_k F_k^T + G_k Q_k G_k^T - F_k K_k C(t_k) \Sigma_k F_k^T \\ &= \Sigma_k + \Delta t \{A(t_k) \Sigma_k + \Sigma_k A(t_k)^T\} + \Delta t D(t_k) Q(t_k) D(t_k)^T \\ &\quad - \{I + \Delta t A(t_k)\} \Delta t K'_k C(t_k) \Sigma_k \{I + \Delta t A(t_k)\}^T \\ &= \Sigma_k + \Delta t \{A(t_k) \Sigma_k + \Sigma_k A(t_k)^T + D(t_k) Q(t_k) D(t_k)^T \\ &\quad - K'_k C(t_k) \Sigma_k\} + O(\Delta t^2)\end{aligned}\quad (12.30)$$

より、

$$\begin{aligned}\frac{\Sigma_{k+1} - \Sigma_k}{\Delta t} &= A(t_k) \Sigma_k + \Sigma_k A(t_k)^T + D(t_k) Q(t_k) D(t_k)^T - K'_k C(t_k) \Sigma_k \\ &\quad + O(\Delta t)\end{aligned}\quad (12.31)$$

となる。ゆえに、 $\Delta t \rightarrow 0$ の極限で、次の関係が得られる。

$$\dot{\Sigma} = A(t) \Sigma + \Sigma A(t)^T + D(t) Q(t) D(t)^T - \Sigma C(t)^T R(t)^{-1} C(t) \Sigma \quad (12.32)$$

以上をまとめると、連続時間システム用のフィルタが次のように得られる^{b)}。

算法 12.2 (Kalman-Bucy フィルタ) 連続時間線形確率システム：

$$\begin{cases} \dot{\mathbf{x}} = A(t) \mathbf{x} + D(t) \mathbf{w}(t), & \mathbf{x}(t) \in \mathbb{R}^n, \mathbf{w}(t) \in \mathbb{R}^r, \\ \mathbf{y} = C(t) \mathbf{x} + \mathbf{v}(t), & \mathbf{y}(t), \mathbf{v}(t) \in \mathbb{R}^p \end{cases} \quad (12.33)$$

^{b)}加藤 [5] p137 など。

$$\begin{cases} \langle \mathbf{w}(t) \rangle = \mathbf{0}, & \langle \mathbf{w}(t) \mathbf{w}(s)^T \rangle = Q(t) \delta(t-s), \\ \langle \mathbf{v}(t) \rangle = \mathbf{0}, & \langle \mathbf{v}(t) \mathbf{v}(s)^T \rangle = R(t) \delta(t-s) \quad (s \geq t) \end{cases} \quad (12.34)$$

の最小分散濾波推定値 $\hat{\mathbf{x}}(t)$ は、次の微分方程式系の解として得られる。すなわち、既知の観測量 $\mathbf{y}(t)$ と、適当な初期条件 $\hat{\mathbf{x}}(0) = \bar{\mathbf{x}}_0$ 、 $\Sigma(0) = \Sigma_0$ に対して、

$$K(t) := \Sigma C(t)^T R(t)^{-1} \quad (\text{カルマンゲイン}) \quad (12.35a)$$

$$\dot{\hat{\mathbf{x}}} = A(t)\hat{\mathbf{x}} + K(t)(\mathbf{y} - C(t)\hat{\mathbf{x}}) \quad (\text{推定値}) \quad (12.35b)$$

$$\dot{\Sigma} = A(t)\Sigma + \Sigma A(t)^T + D(t)Q(t)D(t)^T - K(t)C(t)\Sigma \quad (\text{誤差}) \quad (12.35c)$$

算法 12.2 のプログラム例を以下に示す。

Code 3 “KBF.sci” (Scilab)

```

1 // Transformation between vector and matrix
2 function v = mat2vec( mat )
3     v = mat(:);
4 endfunction
5 function mat = vec2mat( v, n )
6     mat = matrix(v,n,n);
7 endfunction
8 // KBF differential equation
9 function dX = KBF_de(t,X,ndim,y,A,D,C,Q,R,A2)
10     xMean = X( 1:ndim ); //推定値(期待値)成分
11     xCov = X( (ndim+1):$ ); //共分散成分
12     Cov = vec2mat(xCov,n); //
13     //invR = pinv(R); K = Cov*C'*invR; //Kalman gain
14     K = Cov*C'/R; //Kalman gain: Equivalent to the above
15     KBF_gain = K;
16     dMean = A2*xMean + K*(y - C*xMean);
17     dCov = A*Cov + Cov*A' + D*Q*D' - K*C*Cov;
18     dX = [dMean; mat2vec(dCov)];
19 endfunction
20 // Kalman Bucy filter //
21 function X = KBF(y,X0,t0,dt,A,D,C,Q,R)
22     n=size(A,'r');
23     XX=ode( X0, t0, [t0,t0+dt], list(KBF_de,n,y,A,D,C,Q,R,A) );
24     X=XX(:, $); //dt 後の解
25 endfunction
26 // set initial values
27 function X0 = KBF_setX0( mean0, Cov0 )
28     X0=[mean0;mat2vec(Cov0)];
29 endfunction
30 // get mean vector
31 function x = KBF_mean( X, ndim )
32     x = X(1:ndim); //推定値(期待値)成分
33 endfunction
34 // get covariance matrix
35 function CovMat = KBF_Cov( X, ndim )
36     CovVec = x( (ndim+1):$ ); //共分散成分
37     CovMat = vec2mat( CovVec, ndim );
38 endfunction

```

12.3.4 定常 Kalman–Bucy フィルタの安定性

Kalman–Bucy フィルタについても、11.4.3 節 p91 と同様な定常フィルタが導出可能である。

行列 $A(t)$, $C(t)$, $D(t)$, $Q(t)$, $R(t)$ が全て定行列であるとき, 共分散行列 $\Sigma(t)$ の支配方程式 (12.35c) は, 定係数の常微分方程式になる. この常微分方程式が安定なら, 定常値 $\Sigma = \lim_{t \rightarrow \infty} \Sigma(t)$ が存在し, カルマンゲインも定常値 $K = \lim_{t \rightarrow \infty} K(t)$ をもつ. このとき, カルマンフィルタの時間発展は, $y(t)$ に依存する予測推定値 $\hat{x}(t)$ のみとなる. すなわち, 定常状態の $\Sigma(t)$ の時間微分は $\dot{\Sigma} = 0$ となるので,

$$\dot{\hat{x}} = A\hat{x} + K(y(t) - C\hat{x}) \quad (12.36)$$

$$\begin{cases} K := \Sigma C^T R^{-1} \\ 0 = A\Sigma + \Sigma A^T + DQD^T - KC\Sigma \end{cases} \quad (12.37) \quad (\text{代数リカッチ方程式})$$

という状態推定式が得られる. これを, 定常 Kalman-Bucy フィルタという.

カルマンフィルタのときと同様に, (12.37) は事前に解けて (これも代数リカッチ方程式という), カルマンゲイン K が事前に定まるので, 状態推定器には, (12.36) のみを実装すればよい.

▶▶ 一般的な数値解析言語 (Scilab, Octave, Matlab など) は, 代数リカッチ方程式の解法を備えている.

推定値 \hat{x} の安定性を調べるために, 誤差ベクトル $\tilde{x} := \hat{x} - x$ を導入すると, $y - C\hat{x} = Cx_t + v(t) - H\hat{x} = C(\hat{x} - \tilde{x}) + v(t) - C\hat{x}_t = v(t) - C\tilde{x}_t$ より, 推定値 (12.35b) は,

$$\dot{\hat{x}} = A\hat{x} + K(y - C\hat{x}) = A\hat{x} + K(v(t) - C\tilde{x}_t) = A\hat{x} - KC\tilde{x} + Kv(t) \quad (12.38)$$

となる. これと (12.33) の第 1 式より,

$$\begin{aligned} \dot{\tilde{x}} &= \dot{\hat{x}} - \dot{x} = A\hat{x} - KC\tilde{x} + Kv(t) - Ax - Dw(t) \\ &= A\tilde{x} - KC\tilde{x} + Kv(t) - Dw(t) \\ \therefore \dot{\tilde{x}} &= (A - KC)\tilde{x}_t + S(t), \quad S(t) := Kv(t) - Dw(t) \end{aligned} \quad (12.39)$$

が得られる. この線形システムが安定ならば, 推定誤差 \tilde{x}_t は安定となる. すなわち, 次の安定条件が得られる.


算法 12.3 (定常 Kalman-Bucy フィルタの安定条件) 行列 $(A - KC)$ の固有値実部が, 全て負値のとき, 推定誤差 \tilde{x}_t は漸近安定となる.

当然のことながら, これを満たさない条件では, 推定誤差が収束しないので Kalman-Bucy フィルタは使用できない.

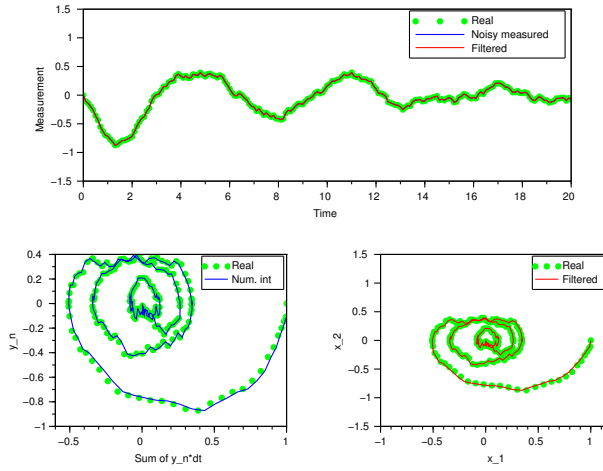
12.3.5 数値例

図 11.1 p94 と同じ問題を, 算法 12.2 で解いた結果を図 12.1 に示す.

$$Q = 0, R = 0.1$$



$$Q = 0.1, R \approx 0 (= 10^{-16})$$



$$Q = 0.1, R = 0.1$$

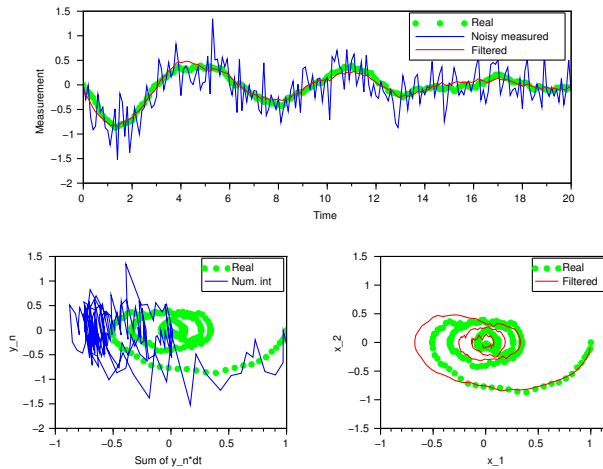


図 12.1 Kalman-Bucy フィルタによる状態推定 (下段右) . 各上段は観測 y . 下段左は数値積分による変位推定 . ($c = 0.3, k = 1, \Delta t = 0.05$)

13

LQG 制御

Kalman–Bucy フィルタを制御に応用する .

13.1 制御入力を考慮したカルマンフィルタ

算法 13.1 のシステムに , 制御入力 $u(t) \in \mathbb{R}^m$ を付加した問題を考える .

$$\dot{x} = A(t)x + B(t)u(t) + D(t)w(t), \quad x(t) \in \mathbb{R}^n, w(t) \in \mathbb{R}^r \quad (13.1)$$

$$y = C(t)x + v(t), \quad y(t), v(t) \in \mathbb{R}^p \quad (13.2)$$

ただし , $u(t)$ は , 時刻 0 から t までの観測量 y に依存すると仮定する . すなわち , 区間 $0 \leq s \leq t$ 上の $y(s)$ の時刻歴 (グラフ) を $\mathcal{Y}(t)$ と表記するとき , $u(t) := u(\mathcal{Y}(t))$ であると仮定する .

▶▶ 厳密にいうと , 確率変数 $y(s)$ ($0 \leq s \leq t$) が生成する σ 代数 $\mathcal{Y}(t)$ に関して , $u(t)$ は $\mathcal{Y}(t)$ -可測であると仮定する .

13.1.1 システムの分解

(13.1) は線形なので , 状態 $x = x(t)$ は次のように分解できる .

$$x = x_u + x_w : \begin{cases} \dot{x}_u = A(t)x_u + B(t)u(t) \\ \dot{x}_w = A(t)x_w + D(t)w(t) \end{cases} \quad (13.3)$$

確かに辺々足せば (13.1) に戻る . 同様に観測量 $y = y(t)$ も分解できる .

$$y = y_u + y_w : \begin{cases} y_u = C(t)x_u \\ y_w = C(t)x_w + v(t) \end{cases} \quad (13.4)$$

これも辺々足せば (13.2) に戻る . 以上をまとめると ,

$$x = x_u + x_w, \quad y = y_u + y_w :$$

$$\begin{cases} \dot{\mathbf{x}}_u = A(t)\mathbf{x}_u + B(t)\mathbf{u}(t) \\ \mathbf{y}_u = C(t)\mathbf{x}_u \end{cases} \quad (13.5a)$$

$$\begin{cases} \dot{\mathbf{x}}_w = A(t)\mathbf{x}_w + D(t)\mathbf{w}(t) \\ \mathbf{y}_w = C(t)\mathbf{x}_w + \mathbf{v}(t) \end{cases} \quad (13.5b)$$

という分解が成立する．

13.1.2 推定値の性質

$\mathbf{u}(t)$ は観測量の時刻歴の関数 $\mathbf{u}(t) = \mathbf{u}(\mathcal{Y}(t))$ だと仮定したので，これを入力とする (13.5a) の応答 $\mathbf{x}_u(t)$ も $\mathcal{Y}(t)$ の関数となる．このとき， $\mathcal{Y}(t)$ をデータとする $\mathbf{x}_u(t)$ の推定値は，算法 6.8 p45 条件付き期待値の性質 (2) より，

$$\hat{\mathbf{x}}_u(t) := \langle \mathbf{x}_u(t) | \mathcal{Y}(t) \rangle = \langle \mathbf{x}_u(\mathcal{Y}(t)) | \mathcal{Y}(t) \rangle = \mathbf{x}_u(\mathcal{Y}(t)) = \mathbf{x}_u(t) \quad (13.6)$$

となる．これを (13.5a) に代入すると， $\hat{\mathbf{x}}_u(t)$ の推移則

$$\dot{\hat{\mathbf{x}}}_u = \dot{\mathbf{x}}_u = A(t)\mathbf{x}_u + B(t)\mathbf{u}(t) = A(t)\hat{\mathbf{x}}_u + B(t)\mathbf{u}(t) \quad (13.7)$$

が得られる．他方， $\hat{\mathbf{x}}_w(t)$ の推移則は，(13.5b) に算法 12.2 を適用して，

$$\dot{\hat{\mathbf{x}}}_w = A(t)\hat{\mathbf{x}}_w + \Sigma_w C(t)^T R(t)^{-1} (\mathbf{y}_w - C(t)\hat{\mathbf{x}}_w) \quad (13.8)$$

$$\dot{\Sigma}_w = A(t)\Sigma_w + \Sigma_w A(t)^T + D(t)Q(t)D(t)^T - \Sigma_w C(t)^T R(t)^{-1} C(t)\Sigma_w \quad (13.9)$$

となる．(13.7) と (13.8) を辺々足して， $\mathbf{y}_u = C(t)\mathbf{x}_u = C(t)\hat{\mathbf{x}}_u$ を使うと，

$$\dot{\hat{\mathbf{x}}} = A(t)\hat{\mathbf{x}} + B(t)\mathbf{u}(t) + \Sigma_w C(t)^T R(t)^{-1} (\mathbf{y} - C(t)\hat{\mathbf{x}}) \quad (13.10)$$

が得られる．また，誤差 $\mathbf{x} - \hat{\mathbf{x}}$ の共分散は，

$$\begin{aligned} \Sigma &= \langle (\mathbf{x} - \hat{\mathbf{x}})(\mathbf{x} - \hat{\mathbf{x}})^T \rangle = \langle \mathbf{x}\mathbf{x}^T \rangle - \hat{\mathbf{x}}\hat{\mathbf{x}}^T \\ &= \langle (\mathbf{x}_u + \mathbf{x}_w)(\mathbf{x}_u + \mathbf{x}_w)^T \rangle - (\hat{\mathbf{x}}_u + \hat{\mathbf{x}}_w)(\hat{\mathbf{x}}_u + \hat{\mathbf{x}}_w)^T \end{aligned} \quad (13.11)$$

となるが， $\mathbf{x}_u = \hat{\mathbf{x}}_u$ より，

$$\begin{aligned} &= \hat{\mathbf{x}}_u \hat{\mathbf{x}}_u^T + \hat{\mathbf{x}}_u \langle \mathbf{x}_w^T \rangle + \langle \mathbf{x}_w \rangle \hat{\mathbf{x}}_u^T + \langle \mathbf{x}_w^T \mathbf{x}_w^T \rangle - (\hat{\mathbf{x}}_u + \hat{\mathbf{x}}_w)(\hat{\mathbf{x}}_u + \hat{\mathbf{x}}_w)^T \\ &= \hat{\mathbf{x}}_u \hat{\mathbf{x}}_u^T + \hat{\mathbf{x}}_u \hat{\mathbf{x}}_w^T + \hat{\mathbf{x}}_w \hat{\mathbf{x}}_u^T + \langle \mathbf{x}_w \mathbf{x}_w^T \rangle - (\hat{\mathbf{x}}_u + \hat{\mathbf{x}}_w)(\hat{\mathbf{x}}_u + \hat{\mathbf{x}}_w)^T \\ &= \langle \mathbf{x}_w \mathbf{x}_w^T \rangle - \hat{\mathbf{x}}_w \hat{\mathbf{x}}_w^T = \langle (\mathbf{x}_w - \hat{\mathbf{x}}_w)(\mathbf{x}_w - \hat{\mathbf{x}}_w)^T \rangle =: \Sigma_w \end{aligned} \quad (13.12)$$

となり， \mathbf{x}_w の誤差共分散 (13.9) に一致する．以上をまとめると，

算法 13.1 (制御入力を考慮した Kalman-Bucy フィルタ) 連続時間線形確率システム：

$$\begin{cases} \dot{\mathbf{x}}(t) = A(t)\mathbf{x}(t) + B(t)\mathbf{u}(t) + D(t)\mathbf{w}(t), & \mathbf{x}(t) \in \mathbb{R}^n, \mathbf{w}(t) \in \mathbb{R}^r, \\ \mathbf{y}(t) = C(t)\mathbf{x}(t) + \mathbf{v}(t), & \mathbf{y}(t), \mathbf{v}(t) \in \mathbb{R}^p, \mathbf{u}(t) \in \mathbb{R}^m \end{cases}$$

$$\begin{cases} \langle \mathbf{w}(t) \rangle = \mathbf{0}, & \langle \mathbf{w}(t)\mathbf{w}(s)^T \rangle = Q(t)\delta(t-s), \\ \langle \mathbf{v}(t) \rangle = \mathbf{0}, & \langle \mathbf{v}(t)\mathbf{v}(s)^T \rangle = R(t)\delta(t-s) \quad (s \geq t) \end{cases}$$

の最小分散濾波推定値 $\hat{\mathbf{x}}(t)$ は、次の微分方程式系の解として得られる。すなわち、既知の観測量 $\mathbf{y}(t)$ と、適当な初期条件 $\hat{\mathbf{x}}(0) = \bar{\mathbf{x}}_0$, $\Sigma(0) = \Sigma_0$ に対して、

$$K(t) := \Sigma C(t)^T R(t)^{-1} \quad (\text{カルマンゲイン}) \quad (13.13a)$$

$$\dot{\hat{\mathbf{x}}} = A(t)\hat{\mathbf{x}} + B(t)\mathbf{u}(t) + K(t)(\mathbf{y}(t) - C(t)\hat{\mathbf{x}}) \quad (\text{推定値}) \quad (13.13b)$$

$$\dot{\Sigma} = A(t)\Sigma + \Sigma A(t)^T + D(t)Q(t)D(t)^T - K(t)C(t)\Sigma \quad (\text{誤差}) \quad (13.13c)$$

算法 12.2 と比較すると、推定値 (13.13b) に $B(t)\mathbf{u}(t)$ が追加されるが、誤差 (13.13c) は変化しない。

13.2 LQG レギュレータ

算法 12.2 p99 の制御入力を、通常の状態フィードバック $\mathbf{u}(t) := -F\mathbf{x}(t)$ ではなく、濾波推定値 $\hat{\mathbf{x}}(t)$ のフィードバック

$$\mathbf{u}(t) := -F\hat{\mathbf{x}}(t) \quad (13.14)$$

とした制御方式を、LQG 制御 (linear quadratic Gaussian control) という。LQG 制御は、状態量 $\mathbf{x}(t)$ や観測量 $\mathbf{y}(t) = C(t)\mathbf{x}(t)$ がノイズに乱されていても、カルマンフィルタの意味で最適なフィードバック制御が期待できる。

制御入力 $\mathbf{u}(t)$ を決めるのに必要な (13.13a), (13.13b), (13.13c), (13.14) を集めて整理すると、次のようになる。

算法 13.2 (LQG 制御) 連続時間線形確率システム：

$$\begin{cases} \dot{\mathbf{x}}(t) = A(t)\mathbf{x}(t) + B(t)\mathbf{u}(t) + D(t)\mathbf{w}(t), & \mathbf{x}(t) \in \mathbb{R}^n, \mathbf{w}(t) \in \mathbb{R}^r, \\ \mathbf{y}(t) = C(t)\mathbf{x}(t) + \mathbf{v}(t), & \mathbf{y}(t), \mathbf{v}(t) \in \mathbb{R}^p, \mathbf{u}(t) \in \mathbb{R}^m \end{cases}$$

$$\begin{cases} \langle \mathbf{w}(t) \rangle = \mathbf{0}, & \langle \mathbf{w}(t)\mathbf{w}(s)^T \rangle = Q(t)\delta(t-s), \\ \langle \mathbf{v}(t) \rangle = \mathbf{0}, & \langle \mathbf{v}(t)\mathbf{v}(s)^T \rangle = R(t)\delta(t-s) \quad (s \geq t) \end{cases}$$

の最小分散濾波推定値 $\hat{x}(t)$ による状態フィードバック制御器 $u(t) = u^{\text{LQG}}(t)$ を LQG レギュレータ (linear quadratic Gaussian regulator) という . $u^{\text{LQG}}(t)$ は次のように得られる .

既知の観測量 $y(t)$ と , 適当な初期条件 $\hat{x}(0) = \bar{x}_0$, $\Sigma(0) = \Sigma_0$ に対して ,

$$u(t) = u^{\text{LQG}}(t) := -F\hat{x}(t) \quad (\text{LQG 制御器}) \quad (13.15a)$$

$$K(t) := \Sigma C(t)^T R(t)^{-1} \quad (\text{カルマンゲイン}) \quad (13.15b)$$

$$\dot{\hat{x}} = (A(t) - B(t)F)\hat{x} + K(t)(y(t) - C(t)\hat{x}) \quad (\text{推定値}) \quad (13.15c)$$

$$\dot{\Sigma} = A(t)\Sigma + \Sigma A(t)^T + D(t)Q(t)D(t)^T - K(t)C(t)\Sigma \quad (\text{誤差}) \quad (13.15d)$$

これを , LQG レギュレータ (linear quadratic Gaussian regulator) という . プログラム例を以下に示す .

Code 4 “LQG.sci” (Scilab)

```

1  ///// Kalman Bucy filter /////
2  //exec KBF.sci; //<==先に読み込む必要あり
3  ///// Least square quadratic Gaussian regulator/////
4  function X = LQG(y,X0,t0,dt,A,D,C,Q,R,B,F)
5      n=size(A,'r');
6      CL = A-B*F; //closed-loop
7      XX=ode( X0, t0, [t0,t0+dt], list(KBF_de,n,y,A,D,C,Q,R,CL) );
8      X=XX(:, $); //dt 後の解
9  endfunction
10 function u = LQG_control(F,X)
11     u = -F*KBF_mean(X);
12 endfunction

```

特に , 行列 $A(t)$, $B(t)$, $C(t)$, $D(t)$, $Q(t)$, $R(t)$ が全て定行列の場合 ,

$$\begin{cases} u(t) := -F\hat{x}(t), \\ K := \Sigma C^T R^{-1}, \\ \dot{\hat{x}} = (A - BF)\hat{x} + K(y(t) - C\hat{x}), \\ O = A\Sigma + \Sigma A^T + DQD^T - KC\Sigma \end{cases} \quad (13.16)$$

を , 定常 LQG レギュレータ (stationary LQG regulator) という .

13.3 分離定理

簡単のため , 定常 LQG レギュレータ (13.16) について考える . カルマンゲイン K は , Σ に依存し , この Σ の支配方程式 (第 4 式) はフィードバックゲイン F を含まない . すなわち , カルマンゲイン K は , フィードバックゲイン F の選択とは無関係に定まる . 最適制御理論^{a)}を参考に , 以下 , 詳しく見てみる .

^{a)}加藤 [5]p145 など .

(13.16) の $u(t) := -F\hat{x}(t)$ を, (13.1) に代入すると,

$$\dot{x} = Ax - BF\hat{x}(t) + Dw(t) \quad (13.17)$$

となる. 誤差ベクトル $\tilde{x} := \hat{x} - x$ をとって, \hat{x} を消去すると,

$$\dot{x} = (A - BF)x - BF\tilde{x} + Dw(t) \quad (13.18)$$

となる. また, $y = Cx + v(t)$ より,

$$y - C\hat{x} = Cx + v(t) - C(\tilde{x} + x) = -C\tilde{x} + v(t) \quad (13.19)$$

となるから, (13.16) の第 3 式は,

$$\dot{\hat{x}} = (A - BF)\hat{x} - KC\tilde{x} + Kv(t) \quad (13.20)$$

と書ける. (13.20) から (13.18) を辺々引くと, 誤差ベクトルの法則を得る.

$$\begin{aligned} \dot{\tilde{x}} &= (A - BF)\tilde{x} + (BF - KC)\tilde{x} - Dw(t) + Kv(t) \\ &= (A - KC)\tilde{x} - Dw(t) + Kv(t) \end{aligned} \quad (13.21)$$

以上に得られた, (13.18) と (13.21) をまとめて書くと,

$$\begin{aligned} \frac{d}{dt} \begin{pmatrix} x \\ \tilde{x} \end{pmatrix} &= \begin{pmatrix} A - BF & -BF \\ 0 & A - KC \end{pmatrix} \begin{pmatrix} x \\ \tilde{x} \end{pmatrix} + P(t) \\ \text{ただし, } P(t) &= \begin{pmatrix} D \\ -D \end{pmatrix} w(t) + \begin{pmatrix} 0 \\ K \end{pmatrix} v(t) \end{aligned} \quad (13.22)$$

を得る. 一般に, 線形システム (13.22) の安定性は, 係数行列の固有値で決まる. さらに, 係数行列は上三角のブロック行列なので, 状態ベクトル x の安定性は行列 $(A - BF)$ の固有値で定まる. また, これとは独立に, 誤差ベクトル \tilde{x} の安定性は行列 $(A - KC)$ の固有値で定まる^{b)}.

したがって, 2 つのゲイン F と K に着目すると, 状態 x の安定性は状態フィードバックゲイン F だけに依存し, 推定誤差 \tilde{x} の安定性はカルマンゲイン K だけに依存することが分かる. 換言すると, (制御と状態推定の) 分離定理と呼ばれる, 次の法則を得る^{c)}.

算法 13.3 (分離定理) 定常 LQG レギュレータ (13.16) において, 状態フィードバックゲイン F と, カルマンゲイン K は, 互いに影響を与えずに, 別々に設計することができる.

^{b)}(12.39) p101 と同じ結果に帰着したことを意味する.

^{c)}加藤 [5] p157 など.

13.4 数値例

13.4.1 1 自由度機械振動系の LQG 制御

図 1.9 p7 の制御方法を明らかにする．問題を再掲する． m は質量， k はばね定数，




図 1.1 の 1 自由度機械振動系

c は減衰係数とし，質点の実際の変位を x で表した．簡単のため， $m = 1 \text{ kg}$ とし， $u = F$ の場合を考えた（制御入力とは外力そのもの）．そして，対応する状態方程式と，次のような観測方程式を考えた．

$$\begin{cases} \dot{\mathbf{x}} = \mathbf{A}\mathbf{x} + \mathbf{B}u, & \mathbf{x} := \begin{pmatrix} x \\ \dot{x} \end{pmatrix}, \quad \mathbf{A} = \begin{pmatrix} 0 & 1 \\ -k & -c \end{pmatrix}, \quad \mathbf{B} = \begin{pmatrix} 0 \\ 1 \end{pmatrix} \\ y = \mathbf{C}\mathbf{x} = x_1 = x, & \mathbf{C} = (1, 0) \end{cases} \quad (13.23)$$

さて，図 1.1 の制御系とは，(13.23) の制御系に，システム雑音 $w(t)$ と，観測雑音 $v(t)$ を加味した次の LQG 制御系である．

$$\begin{cases} \dot{\mathbf{x}} = \mathbf{A}\mathbf{x} + \mathbf{B}u + \mathbf{D}w, & \mathbf{D} = \begin{pmatrix} 0 \\ 1 \end{pmatrix} \\ y = \mathbf{C}\mathbf{x} + v, \\ u = u^{\text{LQG}} := -\mathbf{F}\hat{\mathbf{x}}, & \mathbf{F} = (F_1, F_2) \end{cases} \quad (13.24)$$

パラメータ条件は， $m = 1$ ， $c = k = 0.1$ とした．また， $w(t)$ と $v(t)$ の分散はそれぞれ $Q = 0$ および $R = 0.01$ とした（この問題ではいずれもスカラ）．ここで，状態フィードバックゲインを $\mathbf{F} = (0, 0)$ とした制御なしの時間応答が図 1.8 p6 の濾波の結果である．図中の赤線が推定値 $\hat{x}(t)$ を表す．

また， $\mathbf{F} = (0, 0.45)$ として推定値の速度成分をフィードバックした LQG 制御の結果が，図 1.9 p7 である．図中の黒線が LQG 制御 $u(t) = u^{\text{LQG}} := -\mathbf{F}\hat{\mathbf{x}}$ を受けた質点の運動 $x(t)$ である．

13.4.2 クレーンの LQG 制御

台車型クレーンの運動方程式 台車型クレーンの運動方程式は次式で与えられる．

$$\begin{pmatrix} M + m & ml \cos \theta \\ \cos \theta & l \end{pmatrix} \begin{pmatrix} \ddot{x} \\ \ddot{\theta} \end{pmatrix} = \begin{pmatrix} ml\dot{\theta}^2 \sin \theta - c_x \dot{x} \\ -g \sin \theta - c_\theta \dot{\theta} \end{pmatrix} + \begin{pmatrix} 1 \\ 0 \end{pmatrix} q \quad (13.25)$$

x は台車の水平変位, θ は下死点からの振り子の倒れ角であり, q は台車の推進力である. M, m はそれぞれ台車と振り子の質量, l は振り子長である. また, 重力加速度を $g = 9.8$ とする.

(13.25) を加速度について解き, 状態量を $\mathbf{x} = (x_1, x_2, x_3, x_4)^T \equiv (x, \dot{x}, \theta, \dot{\theta})^T$ とおいて 1 階化すると, 次のような状態空間表示が得られる.

$$\dot{\mathbf{x}} = \mathbf{f}(\mathbf{x}) + \mathbf{g}(\mathbf{x})q, \quad (13.26)$$

$$\mathbf{f}(\mathbf{x}) := \begin{pmatrix} x_2 \\ l\{-c_x x_2 + mlx_4^2 \sin x_3 + m(c_\theta x_4 + g \sin x_3) \cos x_3\}/\Delta \\ x_4 \\ \{(c_x x_2 - mlx_4^2 \sin x_3) \cos x_3 - (M+m)(c_\theta x_4 + g \sin x_3)\}/\Delta \end{pmatrix}, \quad (13.27)$$

$$\mathbf{g}(\mathbf{x}) := \begin{pmatrix} 0 \\ l/\Delta \\ 0 \\ -\cos x_3/\Delta \end{pmatrix}, \quad \Delta := Ml + ml(1 - \cos^2 x_3) \quad (13.28)$$

下死点での静止状態 $x_1 = x_2 = x_3 = x_4 = 0$ のまわりで線形化すると,

$$\dot{\mathbf{x}} = \mathbf{A}\mathbf{x} + \mathbf{B}q, \quad (13.29)$$

$$\mathbf{A} := \begin{pmatrix} 0 & 1 & 0 & 0 \\ 0 & -c_x \frac{1}{M} & g \frac{m}{M} & c_\theta \frac{m}{M} \\ 0 & 0 & 0 & 1 \\ 0 & c_x \frac{1}{Ml} & -g \frac{M+m}{Ml} & -c_\theta \frac{M+m}{Ml} \end{pmatrix}, \quad \mathbf{B} := \begin{pmatrix} 0 \\ \frac{1}{M} \\ 0 \\ -\frac{1}{Ml} \end{pmatrix} \quad (13.30)$$

という線形化方程式を得る.

制御モデル 制御入力 $u(t)$ を台車の推進力 q としたものに, システム雑音と観測雑音を加味した, 次の制御系を考える. (T は転置)

$$\dot{\mathbf{x}} = \mathbf{A}\mathbf{x} + \mathbf{B}u(t) + \mathbf{D}w(t), \quad \mathbf{D} = (0, 0, 0, 1)^T \quad (13.31)$$

$$\mathbf{y} = \mathbf{C}\mathbf{x} + \mathbf{v}(t), \quad \mathbf{C} = \begin{pmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} \quad (13.32)$$

ただし, $u(t), w(t) \in \mathbb{R}$, $\mathbf{v}(t) \in \mathbb{R}^2$ である. この制御系においては,

$$\mathbf{y} = \mathbf{C}\mathbf{x} = (x_2, x_4)^T = (\dot{x}, \dot{\theta})^T \quad (13.33)$$

であるから, 台車の水平変位 x と, 振り子の角度 θ が測定されない.

数値積分による状態推定 そこでまずは, 初等的に, データ処理的な状態推定を試してみる. 観測量 $\mathbf{y}(t)$ の測定時系列

$$\mathbf{y}_i := \mathbf{y}(t_i), \quad t_i := t_0 + i\Delta t \quad (i = 0, 1, 2, \dots) \quad (13.34)$$

を考える. Δt はサンプリング間隔である. $\mathbf{y}(t)$ の成分は速度および角速度であるから, 数学的には, 時間積分すれば変位と角度が復元できる.

$$z(t) := \begin{pmatrix} x(t) \\ \theta(t) \end{pmatrix} = y(t_0) + \int_{t_0}^t y(s) ds \quad (13.35)$$

そこで、この積分を離散化した次の推定式を考える。

$$z_n = z(t_n) \approx y_0 + \sum_{k=1}^n y_k \Delta t \quad (13.36)$$

このようなデータ処理を数値積分 (NI: numerical integration) という。これにより、時刻 $t = t_n$ の状態量を、次のように推定する。

$$x^*(t_n) = x_n^* := \begin{pmatrix} (z_n)_1 \\ (y_n)_1 \\ (z_n)_2 \\ (y_n)_2 \end{pmatrix} \quad (13.37)$$

ここで、ベクトル X の i 成分を $(X)_i$ と表記した。

図 13.1 は、得られた x^* による状態フィードバック制御

$$u(t) := -F x^*, \quad F = (F_1, F_2, F_3, F_4) \quad (13.38)$$

の結果である。パラメータ条件は $M = 2/3$, $m = 1/3$, $l = 2$, $g = 9.8$, $c_x = 0.5$, $c_\theta = 0.2$ とした。雑音の分散共分散は、

$$Q = 0 \approx 0, \quad R = \begin{pmatrix} 0.1 & 0 \\ 0 & 0.1 \end{pmatrix} \quad (13.39)$$

と設定した。すなわち、システム雑音は考慮せず、観測雑音のみを考慮した。図 13.1 の緑線が状態 x であり、青線が数値積分による推定値 x^* である。状態と推定値が大きくかけ離れており、制御が完全に破綻している様子が見てとれる。これは数値積分による累積誤差が原因である。

これに対して、図 13.2 は LQG 制御の結果である。緑線が状態 x であり、赤線が算法 13.2 p105 の LQG 制御時の最小分散推定値 \hat{x} である。上段が台車の相軌道 (x, \dot{x}) を表す。台車変位 x について、目標値 $x = 0$ から若干の偏差が見られる。しかし、 x の真値を用いない制御にしては、驚くほど良い性能が得られている。また、下段は振り子の相軌道 $(\theta, \dot{\theta})$ である。状態と推定値に若干の違いが見られるものの、LQG の推定値 (赤) は、状態 (緑) によく追従している。




図 13.1 数値積分による PD 制御の結果: 緑が状態, 青が推定値




図 13.2 Kalman-Bucy フィルタによる LQG 制御の結果: 緑が状態, 赤が推定値

関連図書

- [1] 久米均, 統計解析への出発, 岩波書店, 1989 .
- [2] アタナシアス・パボリス (中山ほか訳), 確率とランダム変数 (パボリス応用確率論), 東海大学出版会, (1992).
- [3] 片山徹, 新版 応用カルマンフィルタ, 朝倉書店, 2000 .
- [4] 津野義道, Kalman-Bucy のフィルター理論, 共立出版, 2006 .
- [5] 加藤寛一郎, 最適制御入門, 東京大学出版会, 1987 .
- [6] C. W. Gardiner, “Handbook of Stochastic Methods for Physics, Chemistry and the Natural Science,” Second Edition, Springer, (1985).
- [7] M. Matsumoto and T. Nishimura, “Mersenne Twister: A 623-dimensionally equidistributed uniform pseudorandom number generator,” ACM Trans. on Modeling and Computer Simulation Vol. 8, No. 1, January pp.3-30 (1998)

本書の内容は, 著者が上記の本で勉強したものである. もっときちんと本文中で引用しなければならないのだが, どの本で何を勉強したか忘れてしまっており, 今回は時間切れなので次回更新までお待ち下さい.